Zürcher Hochschule für Angewandte Wissenschaften
Departement School of Engineering

BERICHT

Swiss Household Data

Autoren:
Phineas Berdelis &
Valentín Schwarz

Verantwortliche:
Christoph Hofer &
Martina Schwegler

Eingereicht am
24. April 2026

Modul:
Data Processing with R

Abstract

Hintergrund. Das Swiss Household Panel (SHP) befragt seit 1999 jährlich dieselben Personen zu ihren Lebensbedingungen und bildet damit eine der wichtigsten Datenquellen zur sozialen Entwicklung in der Schweiz. Im Rahmen von Praktikum 2 des Moduls Data Processing with R an der ZHAW wird aus den Rohdaten ein bereinigter Paneldatensatz aufgebaut, der als Grundlage für die deskriptive Analyse des Vertrauens in den Bundesrat dient.

Methodik. Mit R werden die benötigten SHP-Dateien aus der SPSS-ZIP-Datei eingelesen, zusammengeführt und auf volljährige Personen sowie auf die Befragungsjahre mit Erhebung der Zielvariable PP04 (Vertrauen in den Bundesrat) gefiltert. Fehlende Werte werden systematisch ausgewertet; für die Variable mit dem höchsten Missing-Anteil wird der letzte bekannte Wert derselben Person aus einer früheren Welle übernommen. Zur Plausibilisierung wird der Datensatz mit Referenzzahlen des Bundesamts für Statistik (STATPOP 2023) verglichen. Als zusätzliche Einflussgrösse wird der Zivilstand (CIVSTA) aufgenommen und geprüft, ob verheiratete Personen ein höheres Vertrauen berichten als ledige, getrennte oder geschiedene Personen.

Ergebnisse. Der aufbereitete Datensatz umfasst 162 593 Personenjahre über 16 Wellen von 1999 bis 2023. Das mittlere Vertrauen in den Bundesrat steigt von 5,74 im Jahr 1999 auf 6,76 im Jahr 2020 und sinkt anschliessend auf 6,36 im Jahr 2023. Die Verteilungen nach Geschlecht und Kanton stimmen gut mit den BFS-Referenzzahlen überein; jüngere Personen sind leicht untervertreten, die Altersgruppe der 45 bis 59 Jährigen ist leicht übervertreten. Verheiratete vertrauen dem Bundesrat im Mittel mit 5,96 stärker als Ledige (5,86), Getrennte (5,61) oder Geschiedene (5,49).

Diskussion. Die Hypothese wird teilweise gestützt. Die Unterschiede nach Zivilstand sind gering, die Richtung entspricht aber der Erwartung. Einschränkend wirken die selektive Panelattrition, fehlende Werte in einzelnen Variablen und der Umstand, dass die Angaben auf Selbstauskünften beruhen. Ein sinnvoller nächster Schritt wäre eine Längsschnittanalyse, die individuelle Unterschiede zwischen Personen kontrolliert und die vom SHP bereitgestellten Gewichte einbezieht.

Inhaltsverzeichnis

Abstract **ii**

Abkürzungsverzeichnis **iv**

1 Einleitung **1**
1.1 Ausgangslage und Zielsetzung 1
1.2 Hypothese 2

2 Methodik **3**
2.1 Projektmanagement und Projektplan 3
2.2 Beschreibung der Daten, Beschaffung und Storage 4
2.2.1 Datenquelle und Beschaffung 4
2.2.2 Ordnerstruktur und Storage 4
2.2.3 Verwendete Dateien 5
2.2.4 Datenkatalog 5
2.2.5 Übersicht der R-Skripte 6
2.2.6 Datenaufbereitung: Merging und Filtering 6
2.2.7 Datenqualität: Fehlende Werte 8
2.2.8 Plausibilität: Vergleich mit BFS-Daten 9

3 Ergebnisse **10**
3.1 Deskriptive Auswertung 10
3.1.1 Zeitliche Entwicklung des Vertrauens in den Bundesrat 10
3.1.2 Vertrauen nach soziodemografischen Merkmalen 11
3.2 Auswertung der Hypothese 12

4 Diskussion **13**
4.1 Kritische Reflexion der Ergebnisse 13
4.2 Limitationen 13
4.3 Nächste Schritte 14

A Datenkatalog **15**

B R-Skripte **16**
B.1 Hilfsfunktion zum Einlesen von SPSS-Dateien 16
B.2 Merging der Datensätze 16
B.3 Konstruktion der Variable NAT 16
B.4 Imputation mit LOCF 17
B.5 BFS-Daten einlesen 17

Literatur **18**

Abkürzungsverzeichnis

LAH	**L**ist **A**bbreviations **H**ere
WSF	**W**hat (it) **S**tands **F**or

Kapitel 1

Einleitung

1.1 Ausgangslage und Zielsetzung

Das Swiss Household Panel, abgekürzt SHP, ist eine seit 1999 jährlich durchgeführte Panelbefragung. Sie wird vom Schweizerischen Kompetenzzentrum für Sozialwissenschaften FORS in Lausanne koordiniert und erfasst Lebensbedingungen, soziale Einbettung, politische Einstellungen und subjektive Bewertungen der Befragten über mehrere Erhebungswellen hinweg [**FORS2024**]. Die Stichprobe beruht auf einer zufälligen Auswahl von Privathaushalten in der gesamten Schweiz und wird durch Auffrischungsstichproben (SHP II 2004, SHP III 2013 und SHP IV 2020) regelmässig ergänzt, um selektive Panelattrition auszugleichen. Dank der jährlichen Erhebung derselben Personen erlaubt das SHP nicht nur Querschnittsvergleiche, sondern auch längsschnittliche Analysen individueller Veränderungen über die Zeit. Für die vorliegende Arbeit stellt das SHP damit eine der umfassendsten Datenquellen zur Untersuchung sozialer und politischer Entwicklungen in der Schweiz dar.

Die übergeordnete Fragestellung dieses Praktikums lautet, wie sich das Vertrauen der Schweizer Wohnbevölkerung in den Bundesrat seit 1999 entwickelt hat und ob sich zwischen verschiedenen Untergruppen systematische Unterschiede zeigen. Die Zielvariable `PP04` misst das Vertrauen in den Bundesrat auf einer elfstufigen Skala von 0 (kein Vertrauen) bis 10 (volles Vertrauen). Die Variable wird im SHP in unregelmässigen Abständen erhoben, erstmals 1999 und zuletzt 2023.

Der vorliegende Bericht dokumentiert Praktikum 2 des Moduls Data Processing with R an der ZHAW. Ausgehend von den SHP-Rohdaten wird ein bereinigter Paneldatensatz auf Personen-Jahr-Ebene aufgebaut, der sämtliche aufgabenseitig vorgegebenen Variablen enthält sowie eine zusätzliche, vom Projektteam ausgewählte Einflussgrösse. Der Bericht beschreibt die Planung der Arbeitsschritte, die Beschaffung und Ablage der Rohdaten, die Datenaufbereitung, die Prüfung der Datenqualität, die Plausibilisierung mit externen Referenzdaten und die deskriptive Auswertung.

Das Projekt folgt dem IMRD-Schema (Introduction, Materials and Methods, Results, Discussion): Nach dieser Einleitung werden in Kapitel 2 das Projektmanagement, die Datenbeschaffung, die Datenaufbereitung sowie die Prüfung der Datenqualität und Plausibilität beschrieben. Kapitel 3 präsentiert die deskriptiven Ergebnisse und die Auswertung der Hypothese. Kapitel 4 diskutiert die Befunde kritisch, benennt die methodischen Grenzen und skizziert mögliche nächste Schritte. Der Anhang

enthält einen vollständigen Datenkatalog sowie ausgewählte Auszüge aus dem R-Code.

Ein besonderes Augenmerk liegt auf der Reproduzierbarkeit der Datenaufbereitung. Alle Verarbeitungsschritte werden ausgehend von der ursprünglichen ZIP-Datei in R programmiert, dokumentiert und in einem öffentlich nachvollziehbaren Projektverzeichnis abgelegt. Eine Drittperson kann den Datenaufbereitungsprozess mit den im Repository hinterlegten Skripten eigenständig nachvollziehen.

1.2 Hypothese

Neben den in der Aufgabenstellung vorgegebenen Variablen verlangt das Praktikum die Aufnahme einer zusätzlichen, vom Projektteam gewählten Einflussgrösse. Als ergänzende Variable wird der Zivilstand (`CIVSTA`) aufgenommen. Der Zivilstand strukturiert die unmittelbare Lebenswelt einer Person, prägt den Alltag durch soziale Einbettung oder Trennungserfahrungen und steht damit in einem plausiblen Zusammenhang mit dem Vertrauen in staatliche Institutionen. In der soziologischen Literatur wird wiederholt darauf verwiesen, dass verheiratete Personen tendenziell höhere Werte für generalisiertes Vertrauen und Lebenszufriedenheit aufweisen, während Trennungs- und Scheidungserfahrungen mit niedrigerem institutionellen Vertrauen assoziiert sind.

Auf dieser Grundlage wird die folgende Hypothese formuliert:

> Verheiratete Personen weisen im Durchschnitt ein höheres Vertrauen in den Bundesrat auf als ledige, getrennte oder geschiedene Personen.

Die Hypothese wird in Kapitel 3 deskriptiv anhand der gruppenspezifischen Mittelwerte und Mediane von `PP04` überprüft. Zusätzlich wird die zeitliche Entwicklung des Vertrauens je Zivilstandsgruppe dargestellt, um zu beurteilen, ob die allfälligen Unterschiede über den gesamten Beobachtungszeitraum stabil sind oder ob sie sich in bestimmten Phasen verstärken oder verringern.

Kapitel 2

Methodik

2.1 Projektmanagement und Projektplan

Die Arbeit wurde innerhalb einer Zweiergruppe arbeitsteilig organisiert. Die Gruppe umfasst Phineas Berdelis und Valentín Schwarz. Die Bearbeitung war auf vier Wochen angelegt und orientiert sich an der in der Aufgabenstellung vorgegebenen Gliederung.

TABELLE 2.1: Projektplan mit Meilensteinen und Verantwortlichkeiten

Woche	Meilenstein	Tätigkeiten und Verantwortlichkeiten
1	Planung, Datenbeschaffung	Sichtung der Aufgabenstellung und des SHP User Guide. Registrierung bei SWISSUbase und Download der Rohdaten. Festlegung der Ordnerstruktur und Erstellung des Git-Repositories. Auswahl der zusätzlichen Einflussvariable `CIVSTA`. Gemeinsame Arbeit, Koordination durch beide Teammitglieder.
2	Datenaufbereitung	Programmierung der Skripte zum Entpacken, Einlesen, Bereinigen, Mergen und Filtern der SHP-Dateien. Konstruktion der Zielvariablen. Speicherung des aufbereiteten Datensatzes. Hauptverantwortung Programmierung: Berdelis; Review und Dokumentation: Schwarz.
3	Qualität, Plausibilität, Auswertung	Analyse fehlender Werte und LOCF-Imputation. Plausibilitätsvergleich mit BFS-Referenzdaten. Deskriptive Auswertung der Zielvariable nach Untergruppen. Hypothesenprüfung zum Zivilstand. Hauptverantwortung Auswertung: Schwarz; Review und Dokumentation: Berdelis.
4	Bericht, Abschluss	Zusammenführung der Teilergebnisse in diesem Bericht. Redaktion, Schlusskontrolle, Abgabe. Gemeinsame Arbeit.

Die Koordination erfolgte über kurze, regelmässige Abstimmungen. Der Programmcode wird mit Git versioniert und über ein gemeinsames Repository geteilt. Zur Qualitätssicherung wurde jedes Skript vor dem Zusammenführen in den Hauptzweig vom jeweils anderen Teammitglied gesichtet. Der Bericht wird in LaTeX verfasst; die Vorlage basiert auf dem ZHAW-Template für studentische Arbeiten.

2.2 Beschreibung der Daten, Beschaffung und Storage

2.2.1 Datenquelle und Beschaffung

Die Rohdaten stammen aus dem Swiss Household Panel (SHP), das vom Schweizerischen Kompetenzzentrum für Sozialwissenschaften FORS in Lausanne betrieben wird [**FORS2024**]. Verwendet wird die Version 14.5 des Datensatzes (Referenznummer 6097), bezogen über die Forschungsdatenplattform SWISSUbase (`https://www.swissubase.ch/`). Der Zugriff erfolgt nach Anmeldung mit der akademischen edu-ID und Zustimmung zu den Nutzungsbedingungen von FORS, die eine Verwendung ausschliesslich zu Forschungs- und Lehrzwecken vorsehen.

Von SWISSUbase wurde das vollständige Datenpaket im SPSS-Format (`Data_SPSS.zip`) heruntergeladen und unverändert im Projektverzeichnis unter `data/raw/` abgelegt. Zusätzlich wurde der SHP User Guide in der Fassung *Voorpostel et al. (2021)* bezogen und unter `docs/` zur Dokumentation hinterlegt [**Voorpostel2018**]. Die Rohdaten werden nicht verändert; sämtliche Aufbereitungsschritte erzeugen daraus abgeleitete Datensätze in einem separaten Verzeichnis.

Die für die Plausibilisierung verwendeten Referenzzahlen zur ständigen Wohnbevölkerung werden direkt über die API des Bundesamts für Statistik im PX-Format eingelesen [1]. Auf diese Weise ist jederzeit nachvollziehbar, welcher Stand der BFS-Daten in den Vergleich eingeflossen ist.

2.2.2 Ordnerstruktur und Storage

Das Projektverzeichnis ist funktional gegliedert und trennt Rohdaten, aufbereitete Daten, Programmcode und Dokumentation. Tabelle 2.2 gibt einen Überblick über die verwendete Struktur.

TABELLE 2.2: Ordnerstruktur des Projektrepositories

Verzeichnis	Inhalt
`data/raw/`	Unveränderte SHP-Rohdaten im SPSS-Format sowie die Datei `metadata.yaml` mit Angaben zu Version und Bezugsquelle. Ebenfalls hier abgelegt ist das entpackte Arbeitsverzeichnis `data_unzipped/`.
`data/processed/`	Aus der Aufbereitung erzeugte Zwischen- und Enddatensätze im CSV- und RDS-Format.
`src/`	R-Markdown-Skripte für Datenaufbereitung und Auswertung sowie die aus ihnen erzeugten PDF-Berichte.
`docs/`	Dokumentation: Aufgabenstellung, SHP User Guide sowie das LaTeX-Projekt für den vorliegenden technischen Bericht unter `docs/bericht/`.
`figures/`	Ausgabeverzeichnis für Grafiken, sofern diese ausserhalb der R-Markdown-Berichte verwendet werden.
`README.md`	Kurzbeschreibung des Repositories, Hinweise zur Reproduktion der Aufbereitung.

Der gesamte Programmcode wird mit Git versioniert. Das Repository ist privat und nur den beiden Teammitgliedern und dem Dozenten zugänglich. Grosse Binärdateien (insbesondere die Rohdaten und abgeleitete RDS-Dateien) werden über

`.gitignore` von der Versionierung ausgeschlossen, um das Repository schlank zu halten und urheberrechtliche Anforderungen von FORS einzuhalten. Die Rohdaten verbleiben ausschliesslich lokal. Alle Ergebnisse lassen sich mit den im Repository hinterlegten R-Skripten aus der ursprünglichen ZIP-Datei reproduzieren.

2.2.3 Verwendete Dateien

Für die Aufgabe werden vier Dateien des SHP-Datensatzes verwendet. Es handelt sich um zwei Long-Files, die Beobachtungen über mehrere Wellen hinweg in einer gestapelten Form enthalten, sowie um zwei Master-Files mit zeitinvarianten Informationen zur Person beziehungsweise zur sozialen Herkunft. Die Long-Files wurden den klassischen jahrspezifischen Dateien vorgezogen, weil sie das Stapeln der Wellen überflüssig machen und damit die Aufbereitung deutlich vereinfachen.

TABELLE 2.3: Verwendete Dateien des SHP-Datensatzes

Datei	Schlüssel	Inhalt
`SHPLONG_P_USER.sav`	`idpers`, `year`, `idhous`	Personenbezogene Variablen je Welle: Vertrauen in den Bundesrat (`pp04`), politische Selbsteinstufung (`pp10`), Bildung (`educat`), eigene Kinder (`ownkid`), Nationalität (`nat_1_`, `nat_2_`, `nat_3_`), gesundheitliche Einschränkung (`pc19/pc19a`), Zivilstand (`civsta`).
`SHPLONG_H_USER.sav`	`idhous`, `year`	Haushaltsbezogene Variablen je Welle: Kanton (`canton`), Netto-Haushaltseinkommen (`ihtyn`), Haushaltsgrösse (`nbpers`).
`SHP_MP.sav`	`IDPERS`	Zeitinvariante Masterdaten pro Person: Geburtsjahr (`BIRTHY`), Geschlecht (`SEX`).
`SHP_SO.sav`	`IDPERS`	Daten zur sozialen Herkunft: finanzielle Probleme in der Jugend (`PO58`).

Abbildung 2.1 fasst schematisch zusammen, über welche Schlüsselvariablen die vier Dateien zusammengeführt werden. Alle Verknüpfungen erfolgen als `LEFT JOIN` ausgehend von `SHPLONG_P_USER`, sodass die Ausgangsmenge der Personen-Jahr-Beobachtungen erhalten bleibt.

2.2.4 Datenkatalog

Der aufbereitete Datensatz liegt auf Personen-Jahr-Ebene vor. Jede Zeile beschreibt eine volljährige Person in einem Jahr, in dem `PP04` erhoben wurde. Der Datensatz

```
SHPLONG_P_USER  (idpers, year, idhous, pp04, ...)
       |
       |  LEFT JOIN on (idhous, year)
       v
SHPLONG_H_USER  (idhous, year, canton, ihtyn, nbpers)
       |
       |  LEFT JOIN on idpers
       v
SHP_MP          (IDPERS, BIRTHY, SEX)
       |
       |  LEFT JOIN on idpers
       v
SHP_SO          (IDPERS, PO58)
       |
       v
 Filter: year in {1999..2009, 2011, 2014, 2017, 2020, 2023}
 Filter: AGE = year - BIRTHY >= 18
 Konstruktion: BIRTHYGEN, SEX, CIVSTA, CANTON, EDUCAT,
               HASKID, NAT, PC19, NETHHINCPP, PO58, COMPLETE
       |
       v
 panel_final (Personen-Jahr-Ebene)
```

ABBILDUNG 2.1: Schema zum Zusammenführen der vier SHP-Dateien zu einem Paneldatensatz.

umfasst 162 593 Beobachtungen auf 17 Variablen. Ein vollständiger Datenkatalog mit Wertebereichen, Quelldateien und Rekodierungsregeln findet sich in Anhang A. Tabelle 2.4 fasst die Variablen vorab zusammen.

2.2.5 Übersicht der R-Skripte

Die Datenverarbeitung ist auf zwei R-Markdown-Skripte aufgeteilt. Das erste Skript (`Datenaufbereitung.Rmd`) übernimmt Entpacken, Einlesen, Bereinigung, Merging, Filtering, Variablenkonstruktion und Speicherung. Das zweite Skript (`Datenqualitaet_Plausibilisierung_Auswertung.Rmd`) setzt auf dem erzeugten Datensatz auf und führt die Missing-Analyse, die Imputation, den BFS-Plausibilitätsvergleich sowie die deskriptive Auswertung durch.

An R-Paketen kommen `tidyverse` (Datenmanipulation und Visualisierung), `foreign` (SPSS-Import), `zoo` (LOCF-Imputation), `pxR` (Einlesen der BFS-Daten im PX-Format), `knitr` (Berichterstellung) und `scales` (Achsenformatierung) zum Einsatz. Die Auswahl dieser Pakete orientiert sich an den Empfehlungen der Modulunterlagen.

2.2.6 Datenaufbereitung: Merging und Filtering

Die Aufbereitung des Paneldatensatzes folgt einer festen Abfolge von Arbeitsschritten, die vollständig aus R heraus gesteuert werden. Die Reihenfolge entspricht dem in Abbildung 2.1 dargestellten Schema.

TABELLE 2.4: Variablen des aufbereiteten Datensatzes (Kurzfassung)

Variable	Inhalt
IDPERS	Personen-ID (Integer).
IDHOUS	Haushalts-ID (Integer).
YEAR	Befragungsjahr (1999–2023, nur Jahre mit PP04).
PP04	Zielvariable: Vertrauen in den Bundesrat, 0–10.
BIRTHY	Geburtsjahr.
BIRTHYGEN	Konstruierte Geburtskohorte in Zehnjahresabschnitten.
SEX	Geschlecht (männlich, weiblich, andere).
CANTON	Wohnkanton (26 Kürzel).
EDUCAT	Höchste abgeschlossene Ausbildung (11 Stufen).
HASKID	Mindestens ein eigenes Kind (ja/nein).
NAT	Nationalitätengruppe (CH, CH+Andere, Andere).
PC19	Langfristige gesundheitliche Einschränkung (ja/nein).
PP10	Politische Selbsteinstufung links–rechts, 0–10.
NETHHINCPP	Netto-Haushaltseinkommen pro Kopf (CHF pro Jahr).
PO58	Finanzielle Probleme in der Jugend (ja/nein).
COMPLETE	Kennzeichen vollständiger Beobachtungen (TRUE/FALSE).
CIVSTA	Zivilstand (zusätzliche Einflussvariable).

TABELLE 2.5: Erstellte R-Skripte

Skript	Inhalt
Datenaufbereitung.Rmd	Entpacken, Einlesen SPSS, Bereinigung, Merging, Filtering, Variablenkonstruktion, Speicherung.
Datenqualitaet_ Plausibilisierung_ Auswertung.Rmd	Missing-Analyse, Imputation, BFS-Vergleich, deskriptive Auswertung, Hypothesenprüfung.

Im ersten Schritt wird die SPSS-ZIP-Datei in ein Arbeitsverzeichnis entpackt und die vier benötigten Dateien mit `foreign::read.spss()` eingelesen. Mit dem Argument `use.missings = FALSE` werden die SHP-spezifischen Missing-Codes, darunter -1 (inapplicable), -2 (no answer), -3 (does not know) und -7 (filter error), automatisch in `NA` überführt. Alle relevanten Variablen werden anschliessend in numerische Typen umgewandelt, um einheitliche Datentypen sicherzustellen. Verbliebene negative Codes, die nicht bereits als `NA` erkannt wurden, werden in einem zusätzlichen Bereinigungsschritt ebenfalls auf `NA` gesetzt.

Im zweiten Schritt wird ein Jahrfilter angewendet. Behalten werden ausschliesslich die 16 Wellen, in denen die Zielvariable `PP04` erhoben wurde, nämlich 1999 bis 2009, 2011, 2014, 2017, 2020 und 2023. Die übrigen Wellen enthalten keine Vertrauensfrage und tragen zur Analyse nichts bei.

Im dritten Schritt werden die vier Dateien schrittweise über Left Joins zusammengeführt. Das Long-File der Personen wird zuerst mit dem Long-File der Haushalte über die Schlüssel `idhous` und `year` verbunden, sodass jede Personenbeobachtung die zugehörigen Haushaltsinformationen desselben Jahres erhält. Anschliessend werden die zeitinvarianten Angaben aus `SHP_MP` (Geburtsjahr, Geschlecht) und aus `SHP_SO` (finanzielle Probleme in der Jugend, kodiert in `PO58`) über die

Personen-ID angehängt. Der Left Join stellt sicher, dass keine Personenbeobachtung aus dem Personen-Long-File verloren geht.

Im vierten Schritt wird der Erwachsenenfilter gesetzt. Behalten werden nur Beobachtungen, bei denen das rechnerische Alter `YEAR` − `BIRTHY` mindestens 18 Jahre beträgt. Im fünften Schritt werden die Zielvariablen gemäss Aufgabenstellung konstruiert. Die Nationalität wird aus bis zu drei Codes zu den Kategorien `CH`, `CH+Andere` und `Andere` verdichtet, wobei der Schweizer Code (756 bzw. 8100) als Entscheidungskriterium dient. Die Variable `HASKID` wird aus der Anzahl eigener Kinder abgeleitet, `BIRTHYGEN` aus deren Geburtsjahr als Intervall in Zehnjahresschritten. Das pro Kopf berechnete Netto-Haushaltseinkommen `NETHHINCPP` ergibt sich als Quotient aus dem jährlichen Haushaltseinkommen `ihtyn` und der Haushaltsgrösse `nbpers`. Zum Abschluss wird ein `COMPLETE`-Flag gesetzt, das angibt, ob in einer Zeile alle 15 inhaltlichen Variablen gefüllt sind.

Im sechsten Schritt wird der aufbereitete Datensatz sowohl als CSV- wie auch als RDS-Datei unter `data/processed/` gespeichert. Er umfasst 162 593 Personenjahre auf 17 Variablen und bildet die gemeinsame Grundlage für alle nachfolgenden Auswertungen.

2.2.7 Datenqualität: Fehlende Werte

Die Prüfung der Datenqualität konzentriert sich auf fehlende Werte. Tabelle 2.6 zeigt für jedes Erhebungsjahr die Anzahl der Beobachtungen sowie den Anteil jener Zeilen, bei denen mindestens eine der 15 inhaltlichen Variablen fehlt.

TABELLE 2.6: Anteil Datensätze mit mindestens einem Missing pro Jahr

Jahr	n	$n_{\text{miss.}}$	%	Jahr	n	$n_{\text{miss.}}$	%
1999	9 633	4 621	48.0	2005	9 055	8 617	95.2
2000	8 719	8 366	95.9	2006	8 706	8 268	95.0
2001	8 168	7 887	96.6	2007	8 478	8 036	94.8
2002	8 019	7 750	96.6	2008	8 376	7 882	94.1
2003	7 837	7 545	96.3	2009	8 119	7 615	93.8
2004	7 593	7 226	95.2	2011	14 030	11 746	83.7
				2014	14 943	11 414	76.4
				2017	12 999	9 139	70.3
				2020	10 953	6 265	57.2
				2023	10 965	5 649	51.5

Auffällig ist der sprunghafte Anstieg des Missing-Anteils von 48 % im Jahr 1999 auf über 95 % ab dem Jahr 2000. Die Auswertung der Missings pro Variable und Jahr zeigt, dass dieser Anstieg massgeblich auf die Variable `PC19` (langfristige gesundheitliche Einschränkung) zurückzuführen ist. `PC19` wird im SHP nur in den Jahren 1999, 2004, 2009, 2011, 2014, 2017, 2020 und 2023 erhoben. In den übrigen Jahren fehlt die Angabe vollständig, was nach Konstruktion zu einem Anteil unvollständiger Fälle von nahezu 100 % führt. Ab 2011 fällt der Missing-Anteil allmählich, was mit den Auffrischungsstichproben (Refreshment Samples SHP III 2013 und SHP IV 2020) und der damit verbundenen besseren Abdeckung der Zielvariable `PC19` zusammenhängt.

Für die Imputation wird die Variable mit dem höchsten Missing-Anteil im jeweiligen Zieljahr ausgewählt und mit dem Verfahren Last Observation Carried Forward (LOCF) behandelt. Für jede Person wird dabei der letzte gültige Wert aus einer früheren Welle übernommen. Das Verfahren ist konservativ und unterstellt, dass sich der Zustand zwischen zwei Erhebungen nicht verändert. Nach der Imputation wird das `COMPLETE`-Flag neu berechnet, wodurch der Anteil vollständiger Fälle für das jeweilige Zieljahr steigt.

2.2.8 Plausibilität: Vergleich mit BFS-Daten

Zur Einschätzung der Stichprobenqualität werden die Verteilungen nach Geschlecht, Altersgruppe und Kanton mit Referenzzahlen des Bundesamts für Statistik verglichen. Als Referenz dient die ständige Wohnbevölkerung der Schweiz im Jahr 2023 gemäss STATPOP [1]. Die BFS-Daten werden über die offene BFS-API direkt aus R im PX-Format geladen, was die Reproduktion des Vergleichs erleichtert. Verglichen werden jeweils drei Verteilungen: der gesamte SHP-Datensatz, die Teilmenge der vollständigen Fälle und die BFS-Referenz.

Geschlecht. Im SHP liegen alle Fälle bei 48,1 % Männern und 51,9 % Frauen. Die BFS-Referenz weist 49,7 % Männer und 50,3 % Frauen aus. Nach dem Entfernen unvollständiger Fälle steigt der Frauenanteil auf 52,6 %. Der Unterschied zur Referenz ist gering und entspricht dem bekannten, leicht erhöhten Frauenanteil in Haushaltsbefragungen. Eine systematische Verzerrung ist nicht erkennbar.

Altersgruppen. Bei den Altersgruppen sind die Abweichungen deutlicher. Die Gruppe 18 bis 29 Jahre ist im SHP mit 18,1 % aller Fälle leicht über, bei den vollständigen Fällen hingegen deutlich unter der BFS-Referenz von 16,5 % vertreten (nur 11,2 %). Die Altersgruppe 45 bis 59 ist im SHP mit 29,2 % gegenüber 25,7 % in der BFS-Referenz leicht übervertreten. Das Muster entspricht der bekannten Panelattrition: Jüngere Befragte steigen häufiger aus der Studie aus, während mittlere und ältere Altersgruppen im Panel bleiben.

Kantone. Die Kantonsverteilung im SHP entspricht weitgehend der BFS-Referenz. Die bevölkerungsreichsten Kantone Zürich, Bern und Waadt sind in beiden Quellen am stärksten vertreten. Geringe Abweichungen bei kleineren Kantonen lassen sich durch die geschichtete Stichprobenziehung des SHP erklären, die einzelne Regionen gezielt übergewichtet, damit auch für kleinere Kantone belastbare Fallzahlen vorliegen.

Insgesamt bildet der SHP-Datensatz die Schweizer Wohnbevölkerung hinsichtlich Geschlecht und Kanton gut ab. Bei den Altersgruppen ist die für Panels typische Unterrepräsentation jüngerer und Überrepräsentation mittlerer Personen zu beachten. Für repräsentative Schätzungen kämen die vom SHP bereitgestellten Längsschnittgewichte in Frage; für die hier dokumentierte deskriptive Auswertung werden sie nicht verwendet.

Kapitel 3

Ergebnisse

3.1 Deskriptive Auswertung

3.1.1 Zeitliche Entwicklung des Vertrauens in den Bundesrat

Die Zielgrösse der Arbeit ist das Vertrauen der volljährigen Schweizer Wohnbevölkerung in den Bundesrat, gemessen mit der Variable `PP04` auf einer Skala von 0 (kein Vertrauen) bis 10 (volles Vertrauen). Tabelle 3.1 fasst Mittelwert und Median für die 16 Erhebungsjahre zusammen.

TABELLE 3.1: Mittleres und medianes Vertrauen in den Bundesrat nach Jahr

Jahr	$\bar{x}$	Median	Jahr	$\bar{x}$	Median
1999	5,74	6	2006	5,50	6
2000	5,93	6	2007	5,51	6
2001	5,92	6	2008	5,67	6
2002	5,62	6	2009	5,39	5
2003	5,44	6	2011	5,77	6
2004	5,28	5	2014	5,98	6
2005	5,39	5	2017	6,31	7
			2020	6,76	7
			2023	6,36	7

Über den gesamten Beobachtungszeitraum zeigt sich ein insgesamt steigender Trend. Zu Beginn der Erhebung im Jahr 1999 liegt das mittlere Vertrauen bei 5,74 Skalenpunkten. In den frühen 2000er Jahren sinkt es leicht ab und erreicht 2004 mit 5,28 den tiefsten Wert des Beobachtungszeitraums. Ab 2005 setzt eine allmähliche Erholung ein, die sich ab 2011 deutlich beschleunigt. 2017 überschreitet der Mittelwert erstmals den Wert 6,0, und der Median steigt von 6 auf 7.

Den Höchstwert erreicht das Vertrauen im Jahr 2020 mit einem Mittelwert von 6,76. Der Anstieg fällt zeitlich mit dem Ausbruch der Coronapandemie zusammen und entspricht dem in der politischen Soziologie dokumentierten Muster, wonach institutionelles Vertrauen in akuten Krisen vorübergehend steigt. 2023 liegt der Mittelwert bei 6,36. Er bleibt damit klar über dem Niveau der frühen 2000er Jahre, ist gegenüber 2020 aber zurückgegangen. Der Median verharrt bei 7, was bedeutet, dass die Mehrheit der Befragten ein überdurchschnittliches Vertrauen in den Bundesrat berichtet.

3.1.2 Vertrauen nach soziodemografischen Merkmalen

Zur Einordnung der zeitlichen Entwicklung wird `PP04` zusätzlich nach mehreren soziodemografischen Gruppen aufgeschlüsselt. Die folgenden Abschnitte fassen die zentralen Befunde aus den entsprechenden Grafiken zusammen.

Geschlecht. Die Verläufe von Männern und Frauen sind über den gesamten Beobachtungszeitraum fast parallel. Frauen berichten ein leicht höheres mittleres Vertrauen, die Differenz bewegt sich je nach Jahr zwischen 0,1 und 0,4 Skalenpunkten. Der Befund passt zu internationalen Befunden, wonach Frauen in Europa ein geringfügig höheres generalisiertes Vertrauen in Institutionen berichten. Der pandemiebedingte Höchstwert 2020 tritt in beiden Gruppen im gleichen Ausmass auf.

Geburtskohorte. Die Aufschlüsselung nach Geburtskohorten zeigt ein klares Niveaugefälle. Ältere Kohorten, insbesondere Jahrgänge vor 1950, berichten durchgehend ein höheres Vertrauen als jüngere. Die Kohorte 2000 bis 2009, die erst ab etwa 2018 in den Daten erscheint, startet im unteren Bereich des Wertebereichs. Trotz unterschiedlicher Niveaus zeigen alle Kohorten denselben allgemeinen Aufwärtstrend. Die Unterschiede können sowohl auf Alterseffekte (ältere Personen vertrauen tendenziell mehr) als auch auf Kohorteneffekte (unterschiedliche politische Sozialisation) zurückgehen. Eine Trennung dieser Effekte ist mit rein deskriptiven Mitteln nicht möglich.

Nationalität. Personen mit ausschliesslich Schweizer Pass und Personen mit doppelter Staatsbürgerschaft unterscheiden sich im mittleren Vertrauen nur geringfügig. Die kleinere Gruppe mit ausschliesslich ausländischer Staatsangehörigkeit berichtet ein leicht höheres Vertrauen, was angesichts der geringeren Fallzahl mit entsprechender Unsicherheit verbunden ist. Eine inhaltlich plausible Deutung ist ein positiver Vergleichseffekt gegenüber dem Herkunftsland.

Eigene Kinder. Personen mit und ohne eigene Kinder unterscheiden sich im Vertrauen nur wenig. Personen mit Kindern liegen leicht höher, was mit einer tendenziell stärkeren Einbettung in lokale Strukturen wie Schule oder Vereine in Verbindung gebracht werden kann, auf dieser Datenbasis aber nicht belegbar ist.

Gesundheitliche Einschränkung. Die deutlichste Differenz zeigt sich bei der Variable `PC19`. Personen mit einer langfristigen gesundheitlichen Einschränkung berichten durchgehend ein klar niedrigeres Vertrauen als Personen ohne Einschränkung. Die Differenz beträgt in mehreren Jahren über einen Skalenpunkt und ist über den Beobachtungszeitraum stabil. Der Befund ist mit einer häufigeren, im Einzelnen potenziell negativen Erfahrung im Umgang mit Sozialversicherungen und Gesundheitswesen vereinbar.

Zivilstand. Die Unterschiede nach Zivilstand werden im folgenden Abschnitt ausführlich besprochen. Auffällig ist, dass die höchsten Werte in der kleinen Gruppe der eingetragenen Partnerschaften und die niedrigsten bei Geschiedenen beobachtet werden. Die Rangfolge bleibt über die Jahre hinweg weitgehend stabil.

3.2 Auswertung der Hypothese

Die in Abschnitt 1.2 formulierte Hypothese besagt, dass verheiratete Personen ein höheres Vertrauen in den Bundesrat aufweisen als ledige, getrennte oder geschiedene Personen. Tabelle 3.2 fasst die deskriptiven Kennwerte nach Zivilstand zusammen, sortiert nach absteigendem Mittelwert.

TABELLE 3.2: Vertrauen in den Bundesrat nach Zivilstand

Zivilstand	$\bar{x}$ PP04	Median	n
Eingetragene Partnerschaft	6,51	7	218
Aufgelöste Partnerschaft	6,36	6	11
Verheiratet	5,96	6	95 195
Verwitwet	5,94	6	7 384
Ledig	5,86	6	45 062
Getrennt	5,61	6	2 145
Geschieden	5,49	6	12 488

Verheiratete Personen weisen mit einem Mittelwert von 5,96 tatsächlich ein höheres mittleres Vertrauen auf als ledige (5,86), getrennte (5,61) und geschiedene Personen (5,49). Die Richtung des Zusammenhangs stimmt mit der Hypothese überein.

Die Grösse der Unterschiede fällt jedoch je nach Vergleichsgruppe verschieden aus. Die Differenz zwischen Verheirateten und Ledigen beträgt nur 0,10 Skalenpunkte und ist damit klein. Deutlicher ist der Abstand zu Geschiedenen mit 0,47 Skalenpunkten und zu Getrennten mit 0,35 Skalenpunkten. Dies legt nahe, dass nicht die Ehe an sich, sondern die Erfahrung einer Trennung oder Scheidung mit einem niedrigeren Vertrauen einhergeht.

Der hohe Wert bei Personen in eingetragener Partnerschaft (6,51) liegt über allen übrigen Gruppen. Da die Kategorie mit $n = 218$ jedoch klein ist, ist dieser Wert nur eingeschränkt belastbar. Die Kategorie „aufgelöste Partnerschaft“ mit $n = 11$ ist statistisch nicht auswertbar und dient hier nur der Vollständigkeit.

Im zeitlichen Verlauf zeigen alle Zivilstandsgruppen denselben allgemeinen Aufwärtstrend. Die Rangfolge der Gruppen bleibt dabei weitgehend stabil: Geschiedene und Getrennte liegen durchgehend unter dem Gesamtdurchschnitt, Verheiratete leicht darüber.

Insgesamt lässt sich die Hypothese teilweise bestätigen. Die Richtung entspricht der Erwartung, die absoluten Unterschiede sind aber gering. Gegen eine kausale Interpretation spricht, dass die Analyse rein deskriptiv ist und Drittvariablen wie Alter, Einkommen und Bildung nicht kontrolliert werden. Der beobachtete Zusammenhang ist daher als Assoziation, nicht als Wirkung des Zivilstands zu verstehen.

Kapitel 4

Diskussion

4.1 Kritische Reflexion der Ergebnisse

Die deskriptive Analyse weist über zwei Jahrzehnte einen steigenden Trend beim Vertrauen in den Bundesrat aus. Der Befund passt zum internationalen Bild, wonach das institutionelle Vertrauen in der Schweiz im europäischen Vergleich hoch ist und über die letzten Jahre tendenziell zugenommen hat. Der markante Höchstwert im Jahr 2020 fällt zeitlich mit dem Beginn der Coronapandemie zusammen und ist mit dem in der politischen Soziologie dokumentierten Muster eines vorübergehenden Vertrauensanstiegs in akuten Krisen vereinbar. Der anschliessende Rückgang auf 6,36 im Jahr 2023 deutet darauf hin, dass dieser Effekt nur begrenzt anhält.

Die Hypothese zum Zivilstand wird durch die Daten teilweise gestützt. Verheiratete Personen berichten ein höheres Vertrauen als Geschiedene und Getrennte; die Differenz zu Ledigen ist hingegen klein. Inhaltlich deutet das darauf hin, dass weniger der Familienstand an sich, sondern eher die mit Trennung und Scheidung verbundenen Erfahrungen mit dem Institutionenvertrauen in Zusammenhang stehen. Diese Deutung bleibt jedoch vorläufig. Die Analyse ist rein deskriptiv, Drittvariablen wie Alter, Einkommen oder Bildung werden nicht kontrolliert.

Unter den soziodemografischen Merkmalen sticht die langfristige gesundheitliche Einschränkung (`PC19`) als stärkster Prädiktor heraus. Der Abstand zwischen Personen mit und ohne Einschränkung ist über den gesamten Beobachtungszeitraum stabil und übersteigt die Unterschiede nach Geschlecht, Nationalität oder Kinderstatus deutlich. Gesundheit und Institutionenvertrauen hängen damit in den SHP-Daten enger zusammen als die meisten klassischen soziodemografischen Merkmale.

4.2 Limitationen

Bei der Interpretation sind mehrere Einschränkungen zu beachten.

Erstens unterliegt das SHP einer selektiven Panelattrition. Der Vergleich mit den BFS-Daten zeigt, dass jüngere Altersgruppen in späteren Wellen untervertreten sind, während mittlere und ältere Altersgruppen im Panel bleiben. Da ältere Personen im Mittel ein höheres Vertrauen berichten, werden ungewichtete Mittelwerte tendenziell leicht nach oben verzerrt.

Zweitens schränkt der hohe Anteil fehlender Werte die Analysebasis ein, insbesondere bei der in ausgewählten Jahren erhobenen Variable `PC19`. Die eingesetzte

LOCF-Imputation ist konservativ und unterstellt, dass sich der gesundheitliche Zustand zwischen zwei Erhebungen nicht verändert. Systematische Verschlechterungen oder Verbesserungen bleiben dadurch unsichtbar. Komplexere Verfahren wie Multiple Imputation könnten die Unsicherheit angemessener abbilden, liegen aber ausserhalb des Rahmens der vorliegenden Arbeit.

Drittens beruhen die Vertrauenswerte auf subjektiven Selbsteinschätzungen. Solche Angaben können durch soziale Erwünschtheit, Interviewereffekte oder aktuelle Stimmungslagen beeinflusst sein. Zudem ist die Skala von 0 bis 10 ordinal. Mittelwerte sind deshalb streng genommen nur eingeschränkt interpretierbar, wenngleich sie in der Praxis ein nützliches Vergleichsmass liefern.

Viertens beschränkt sich die Auswertung auf deskriptive Statistiken und grafische Darstellungen. Kausale Aussagen, etwa ob eine Scheidung das Vertrauen senkt oder ob Personen mit niedrigem Vertrauen häufiger geschieden sind, sind auf dieser Grundlage nicht zulässig.

4.3 Nächste Schritte

Aufbauend auf dem dokumentierten Datensatz bieten sich mehrere Folgeanalysen an. Eine Fixed-Effects-Regression auf Personenebene könnte den Einfluss zeitveränderlicher Merkmale wie Zivilstandswechsel oder Einkommensänderungen auf das Vertrauen isolieren und zugleich für zeitinvariante individuelle Heterogenität kontrollieren. Der Einsatz der vom SHP bereitgestellten Längsschnittgewichte würde die Repräsentativität der Schätzungen verbessern und die durch die Panelattrition entstandene Verzerrung verringern. Schliesslich wäre die Einbeziehung weiterer Variablen, etwa der Sprachregion, des Erwerbsstatus oder der politischen Partizipation, geeignet, das Bild der Determinanten des Institutionenvertrauens in der Schweiz zu schärfen.

Anhang A

Datenkatalog

Variable	Wertebereich	Quelle	Rekodierung
IDPERS	> 0	SHPLONG_P	unverändert
IDHOUS	> 0	SHPLONG_P	unverändert
YEAR	1999–2023	SHPLONG_P	16 Wellen mit PP04
PP04	0–10	SHPLONG_P	neg. Codes $\rightarrow$ NA
BIRTHY	1904–2005	SHP_MP	neg. Codes $\rightarrow$ NA
BIRTHYGEN	7 Kohorten	Konstruiert	Intervalle
SEX	m/w/a	SHP_MP	1$\rightarrow$m, 2$\rightarrow$w, 3$\rightarrow$a
CANTON	26 Kürzel	SHPLONG_H	Code $\rightarrow$ Kürzel
EDUCAT	11 Stufen	SHPLONG_P	Code 0–10 $\rightarrow$ Text
HASKID	ja/nein	SHPLONG_P	ownkid ≥ 1 $\rightarrow$ ja
NAT	CH/CH+A/Andere	SHPLONG_P	Aus 3 Nat.-Codes
PC19	ja/nein	SHPLONG_P	1$\rightarrow$ja, 2$\rightarrow$nein
PP10	0–10	SHPLONG_P	neg. Codes $\rightarrow$ NA
NETHHINCPP	> 0 (CHF)	SHPLONG_H	ihtyn/nbpers
PO58	ja/nein	SHP_SO	1$\rightarrow$ja, 2$\rightarrow$nein
COMPLETE	TRUE/FALSE	Konstruiert	kein Missing
CIVSTA	7 Auspr.	SHPLONG_P	1–7 $\rightarrow$ Klartext

Anhang B

R-Skripte

Die vollständigen R-Markdown-Skripte befinden sich im Verzeichnis `src/` des Projektrepositories.

B.1 Hilfsfunktion zum Einlesen von SPSS-Dateien

LISTING B.1: Einlesen einer SPSS-Datei

```
read_spss_file <- function(path) {
  foreign::read.spss(
    file = path,
    to.data.frame = TRUE,
    use.value.labels = FALSE,
    use.missings = FALSE
  ) |>
  tibble::as_tibble()
}
```

B.2 Merging der Datensätze

LISTING B.2: Zusammenführung der vier Quelldateien

```
panel_joined <- p_long_clean |>
  left_join(h_long_clean, by = c("idhous", "year")) |>
  left_join(mp_clean, by = c("idpers" = "IDPERS")) |>
  left_join(so_clean, by = c("idpers" = "IDPERS"))
```

B.3 Konstruktion der Variable NAT

LISTING B.3: Verdichtung der Nationalitätsvariablen

```
is_swiss <- function(x) x %in% c(8100, 756)

panel_adults <- panel_adults |>
  mutate(
    n_ch = as.integer(replace_na(is_swiss(nat_1_), FALSE)) +
           as.integer(replace_na(is_swiss(nat_2_), FALSE)) +
           as.integer(replace_na(is_swiss(nat_3_), FALSE)),
    n_nat = as.integer(!is.na(nat_1_)) +
            as.integer(!is.na(nat_2_)) +
            as.integer(!is.na(nat_3_)),
    NAT = case_when(
      n_ch >= 1 & n_nat == n_ch ~ "CH",
      n_ch >= 1 & n_nat > n_ch  ~ "CH+Andere",
```

```
      n_ch == 0 & n_nat >= 1    ~ "Andere",
      TRUE                       ~ NA_character_
    )
  )
```

B.4 Imputation mit LOCF

LISTING B.4: Last Observation Carried Forward für PC19

```
panel_imputed <- panel_final %>%
  dplyr::arrange(IDPERS, YEAR) %>%
  dplyr::group_by(IDPERS) %>%
  dplyr::mutate(
    PC19 = zoo::na.locf(PC19, na.rm = FALSE)
  ) %>%
  dplyr::ungroup()
```

B.5 BFS-Daten einlesen

LISTING B.5: Einlesen der BFS-Referenzdaten via pxR

```
bfs_raw <- pxR::read.px(
  filename = "https://dam-api.bfs.admin.ch/hub/api/dam/assets/36021707/
    master",
  encoding = "utf-8"
)
bfs_tbl <- as.data.frame(bfs_raw)
```

Literatur

[1] Bundesamt für Statistik. *Ständige und nichtständige Wohnbevölkerung nach Kanton, Geschlecht, Zivilstand und Alter*. STAT-TAB, STATPOP. 2023. URL: https://www.bfs.admin.ch/asset/de/px-x-0102010000_102.