Praktikum 2 – Woche 3: Datenqualität, Plausibilisierung und Auswertung

Name / Gruppe

2026-04-17

Contents

Ziel von Woche 3 **2**

Zusätzliche Einflussvariable und Hypothese **2**

Pakete **2**

Daten laden **3**

Eingangskontrolle . . . 3

Hilfsvariablen für Woche 3 **4**

1. Datenqualität bezüglich fehlender Werte **4**

1.1 Anzahl Datensätze mit mindestens einem Missing pro Jahr . . . 4

1.2 Missing Values pro Jahr und Variable . . . 6

1.3 Zielvariable und Zieljahr bestimmen . . . 7

1.4 Imputation mit dem neuesten verfügbaren früheren Personenwert . . . 8

1.5 `COMPLETE` nach der Imputation neu berechnen . . . 8

1.6 Missing-Struktur nach der Imputation kontrollieren . . . 9

2. Plausibilität der Daten **10**

2.1 Verteilungen innerhalb des SHP: vor und nach Entfernen unvollständiger Fälle . . . 10

Geschlecht . . . 10

Altersgruppen . . . 11

Kanton . . . 12

2.2 BFS-Daten einlesen . . . 12

2.3 BFS-Daten inspizieren . . . 14

2.4 BFS-Referenzjahr . . . 20

2.5 BFS Geschlecht . . . 20

2.6 BFS Alter . . . 22
2.7 BFS Kantone . . . 24

3. Auswertung **27**
3.1 Zeitliche Entwicklung des Vertrauens in den Bundesrat . . . 27
3.2 Zusätzliche Grafiken nach Untergruppen . . . 29
Grafik 1: nach Geschlecht . . . 29
Grafik 2: nach Geburtskohorte . . . 29
Grafik 3: nach Nationalität . . . 30
Grafik 4: nach Kindern . . . 31
Grafik 5: nach gesundheitlicher Einschränkung . . . 32
Grafik 6: nach Zivilstand . . . 33
3.3 Zusatzhypothese zu `CIVSTA` . . . 34

Daten für Woche 3 speichern **35**

Hinweise für den Bericht **35**

Ziel von Woche 3

In Woche 3 werden drei Dinge bearbeitet:

1. **Datenqualität bezüglich fehlender Werte**
2. **Plausibilität der Daten**
3. **Auswertung**

Gemäss Aufgabenstellung werden dabei: - pro Jahr die Datensätze mit mindestens einem fehlenden Wert bestimmt, - pro Jahr und Variable die Missing Values gezählt, - eine Variable mit sehr hohem Missing-Anteil identifiziert, - die Missing Values dieser Variable in einem Jahr mit dem neuesten verfügbaren früheren Personenwert ersetzt, - die Verteilungen von Geschlecht, Altersgruppen und Kanton mit BFS-Daten verglichen, - die zeitliche Entwicklung von `PP04` dargestellt, - mindestens fünf zusätzliche Grafiken nach Untergruppen erstellt, - und die zusätzliche Einflussvariable `CIVSTA` ausgewertet.

Zusätzliche Einflussvariable und Hypothese

Als zusätzliche Einflussvariable wird **`CIVSTA` (Zivilstand)** verwendet.

Hypothese: Das Vertrauen in den Bundesrat unterscheidet sich nach Zivilstand. Es wird erwartet, dass verheiratete Personen im Durchschnitt ein höheres Vertrauen in den Bundesrat aufweisen als ledige, getrennte oder geschiedene Personen.

Pakete

```r
library(tidyverse)
library(zoo)
library(pxR)
library(knitr)
```

Daten laden

```r
data_path_csv <- "../data/processed/shp_panel_week2_longfiles.csv"

if (!file.exists(data_path_csv)) {
  stop("CSV-Datei nicht gefunden: ", data_path_csv)
}

panel_final <- readr::read_csv(data_path_csv)

glimpse(panel_final)
```

```
## Rows: 162,593
## Columns: 17
## $ IDPERS     <dbl> 4101, 4102, 4101, 4102, 4102, 4101, 4102, 4101, 4101, 4102,~
## $ IDHOUS     <dbl> 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41,~
## $ YEAR       <dbl> 1999, 1999, 2000, 2000, 2001, 2001, 2002, 2002, 2003, 2003,~
## $ PP04       <dbl> 4, 10, 5, 10, 8, 5, 8, 6, 6, 8, 8, 4, 7, NA, 7, 6, 7, 7, 7,~
## $ BIRTHY     <dbl> 1965, 1968, 1965, 1968, 1968, 1965, 1968, 1965, 1965, 1968,~
## $ BIRTHYGEN  <chr> "[1960,1970)", "[1960,1970)", "[1960,1970)", "[1960,1970)",~
## $ SEX        <chr> "männlich", "weiblich", "männlich", "weiblich", "weiblich",~
## $ CANTON     <chr> "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE",~
## $ EDUCAT     <chr> "Technische oder berufliche Schule", "Obligatorische Schule~
## $ HASKID     <chr> "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja",~
## $ NAT        <chr> "CH", "CH+Andere", "CH", "CH", "CH", "CH", "CH", "CH", "CH"~
## $ PC19       <chr> "nein", "ja", NA, NA, NA, NA, NA, NA, NA, NA, "ja", "nein",~
## $ PP10       <dbl> 4, 5, 4, NA, 3, 7, 4, 4, 4, 5, 5, 6, 6, 4, 4, 4, 5, 4, 5, 4~
## $ NETHHINCPP <dbl> 23140, 23140, 16940, 16940, 18140, 18140, 17480, 17480, 190~
## $ PO58       <chr> "nein", "ja", "nein", "ja", "ja", "nein", "ja", "nein", "ne~
## $ COMPLETE   <lgl> TRUE, TRUE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE~
## $ CIVSTA     <chr> "verheiratet", "verheiratet", "verheiratet", "verheiratet",~
```

```r
dim(panel_final)
```

```
## [1] 162593     17
```

Eingangskontrolle

```r
required_vars <- c(
  "IDPERS", "IDHOUS", "YEAR", "PP04",
  "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP",
```

```
  "PO58", "COMPLETE", "CIVSTA"
)

setdiff(required_vars, names(panel_final))
```

```
## character(0)
```

Hilfsvariablen für Woche 3

```
panel_final <- panel_final %>%
  dplyr::mutate(
    AGE = YEAR - BIRTHY,
    AGEGROUP_CURRENT = dplyr::case_when(
      AGE >= 18 & AGE < 30 ~ "18-29",
      AGE >= 30 & AGE < 45 ~ "30-44",
      AGE >= 45 & AGE < 60 ~ "45-59",
      AGE >= 60 & AGE < 75 ~ "60-74",
      AGE >= 75            ~ "75+",
      TRUE ~ NA_character_
    )
  )

panel_final %>%
  dplyr::count(AGEGROUP_CURRENT, sort = TRUE)
```

```
## # A tibble: 5 x 2
##   AGEGROUP_CURRENT     n
##   <chr>            <int>
## 1 45-59            47463
## 2 30-44            41198
## 3 60-74            32013
## 4 18-29            29414
## 5 75+              12505
```

1. Datenqualität bezüglich fehlender Werte

1.1 Anzahl Datensätze mit mindestens einem Missing pro Jahr

```
missing_rows_by_year <- panel_final %>%
  dplyr::group_by(YEAR) %>%
  dplyr::summarise(
    n_total = dplyr::n(),
    n_incomplete = sum(!COMPLETE, na.rm = TRUE),
    share_incomplete = n_incomplete / n_total,
    .groups = "drop"
  )

missing_rows_by_year
```

```
## # A tibble: 16 x 4
##     YEAR n_total n_incomplete share_incomplete
##    <dbl>   <int>        <int>            <dbl>
##  1  1999    9633         4621            0.480
##  2  2000    8719         8366            0.960
##  3  2001    8325         8200            0.985
##  4  2002    7127         7055            0.990
##  5  2003    6344         6280            0.990
##  6  2004   10759         5465            0.508
##  7  2005    8556         4064            0.475
##  8  2006    8379         3741            0.446
##  9  2007    8575         3709            0.433
## 10  2008    8562         3698            0.432
## 11  2009    8860         3741            0.422
## 12  2011    8989         3689            0.410
## 13  2014   14565         9618            0.660
## 14  2017   11509         4495            0.391
## 15  2020   20220        10307            0.510
## 16  2023   13471         6010            0.446
```

```r
missing_rows_by_year %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = share_incomplete)) +
  ggplot2::geom_col() +
  ggplot2::scale_y_continuous(labels = scales::percent_format()) +
  ggplot2::labs(
    title = "Anteil unvollständiger Datensätze pro Jahr",
    x = "Jahr",
    y = "Anteil mit mindestens einem Missing"
  )
```

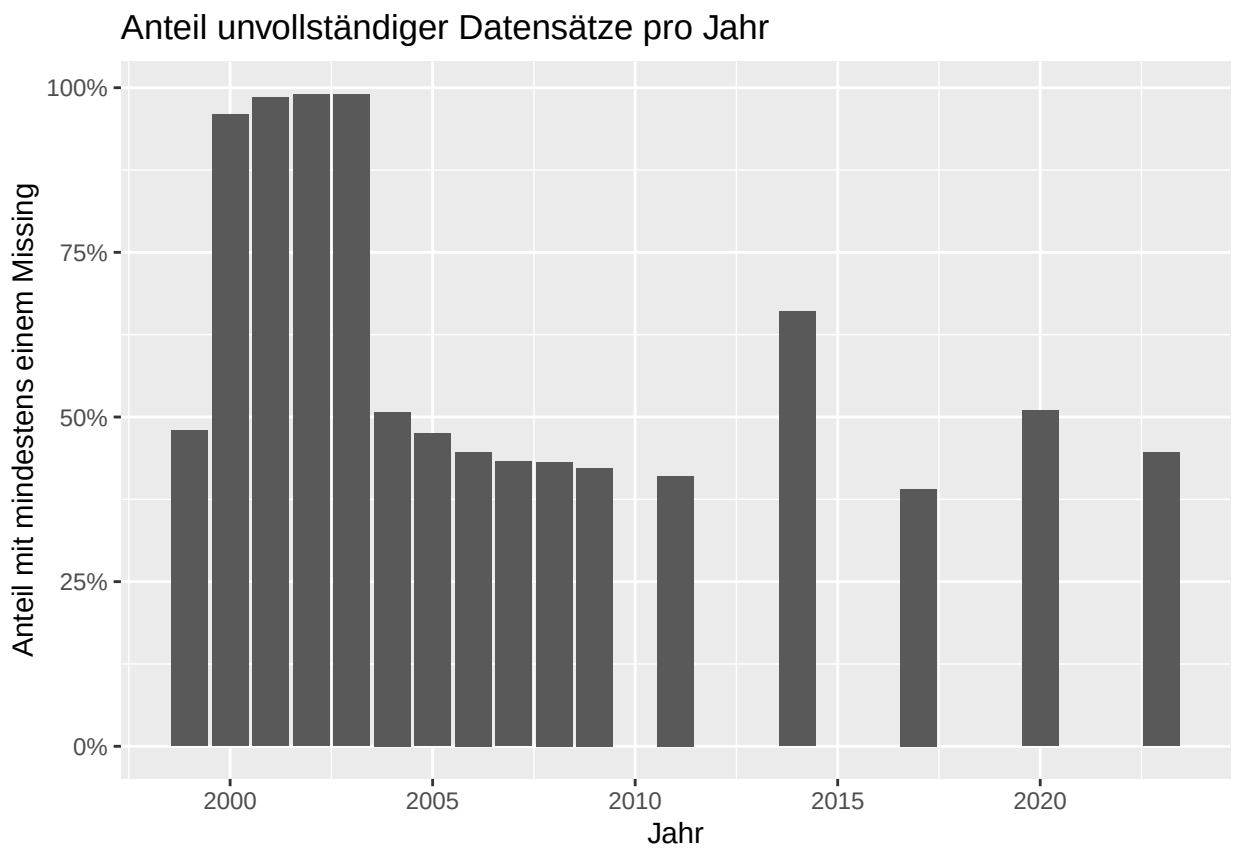

1.2 Missing Values pro Jahr und Variable

```
analysis_vars <- c(
  "PP04", "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP", "PO58",
  "CIVSTA"
)

missing_by_var_year <- panel_final %>%
  dplyr::mutate(
    dplyr::across(dplyr::all_of(analysis_vars), as.character)
  ) %>%
  tidyr::pivot_longer(
    cols = dplyr::all_of(analysis_vars),
    names_to = "variable",
    values_to = "value"
  ) %>%
  dplyr::group_by(YEAR, variable) %>%
  dplyr::summarise(
    n_total = dplyr::n(),
    n_missing = sum(is.na(value)),
    share_missing = n_missing / n_total,
    .groups = "drop"
  ) %>%
```

```r
  dplyr::arrange(dplyr::desc(share_missing), YEAR, variable)

missing_by_var_year
```

```
## # A tibble: 208 x 5
##     YEAR variable n_total n_missing share_missing
##    <dbl> <chr>      <int>     <int>         <dbl>
##  1  2003 PC19        6344      6262         0.987
##  2  2002 PC19        7127      7023         0.985
##  3  2001 PC19        8325      8130         0.977
##  4  2000 PC19        8719      8174         0.937
##  5  2014 PP04       14565      7919         0.544
##  6  2004 PP10       10759      4301         0.400
##  7  2001 PP10        8325      3114         0.374
##  8  2005 PP10        8556      3190         0.373
##  9  2020 PP10       20220      7344         0.363
## 10  1999 PP10        9633      3473         0.361
## # i 198 more rows
```

```r
missing_over_90 <- missing_by_var_year %>%
  dplyr::filter(share_missing > 0.9) %>%
  dplyr::arrange(dplyr::desc(share_missing), YEAR, variable)

missing_over_90
```

```
## # A tibble: 4 x 5
##    YEAR variable n_total n_missing share_missing
##   <dbl> <chr>      <int>     <int>         <dbl>
## 1  2003 PC19        6344      6262         0.987
## 2  2002 PC19        7127      7023         0.985
## 3  2001 PC19        8325      8130         0.977
## 4  2000 PC19        8719      8174         0.937
```

1.3 Zielvariable und Zieljahr bestimmen

```r
if (nrow(missing_over_90) > 0) {
  target_info <- missing_over_90 %>%
    dplyr::slice(1) %>%
    dplyr::mutate(selection_rule = ">90% Missing")
} else {
  target_info <- missing_by_var_year %>%
    dplyr::slice(1) %>%
    dplyr::mutate(selection_rule = "höchster Missing-Anteil, aber nicht >90%")
}

target_info
```

```
## # A tibble: 1 x 6
##    YEAR variable n_total n_missing share_missing selection_rule
##   <dbl> <chr>      <int>     <int>         <dbl> <chr>
## 1  2003 PC19        6344      6262         0.987 >90% Missing
```

1.4 Imputation mit dem neuesten verfügbaren früheren Personenwert

```
fill_from_past <- function(data, varname, target_year) {
  varname <- as.character(varname)
  target_year <- as.integer(target_year)

  data <- data[order(data$IDPERS, data$YEAR), ]

  split_data <- split(data, data$IDPERS)

  split_data <- lapply(split_data, function(df_person) {
    x <- df_person[[varname]]

    last_seen <- NA
    filled <- x

    for (i in seq_along(x)) {
      if (!is.na(x[i])) {
        last_seen <- x[i]
      } else if (df_person$YEAR[i] == target_year && !is.na(last_seen)) {
        filled[i] <- last_seen
      }
    }

    df_person[[varname]] <- filled
    df_person
  })

  dplyr::bind_rows(split_data) %>%
    dplyr::arrange(IDPERS, YEAR)
}
```

```
panel_imputed <- panel_final

target_var  <- as.character(target_info$variable[[1]])
target_year <- as.integer(target_info$YEAR[[1]])

target_var
```

```
## [1] "PC19"
```

```
target_year
```

```
## [1] 2003
```

```
panel_imputed <- fill_from_past(panel_imputed, target_var, target_year)
```

1.5 COMPLETE nach der Imputation neu berechnen

```r
complete_vars <- c(
  "PP04", "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP", "PO58", "CIVSTA"
)

panel_imputed <- panel_imputed %>%
  dplyr::mutate(
    COMPLETE = !dplyr::if_any(
      dplyr::all_of(complete_vars),
      is.na
    )
  )

panel_imputed %>%
  dplyr::count(COMPLETE)
```

```
## # A tibble: 2 x 2
##   COMPLETE     n
##   <lgl>    <int>
## 1 FALSE    89550
## 2 TRUE     73043
```

1.6 Missing-Struktur nach der Imputation kontrollieren

```r
missing_by_var_year_after <- panel_imputed %>%
  dplyr::mutate(
    dplyr::across(dplyr::all_of(analysis_vars), as.character)
  ) %>%
  tidyr::pivot_longer(
    cols = dplyr::all_of(analysis_vars),
    names_to = "variable",
    values_to = "value"
  ) %>%
  dplyr::group_by(YEAR, variable) %>%
  dplyr::summarise(
    n_total = dplyr::n(),
    n_missing = sum(is.na(value)),
    share_missing = n_missing / n_total,
    .groups = "drop"
  ) %>%
  dplyr::arrange(dplyr::desc(share_missing), YEAR, variable)

missing_by_var_year_after
```

```
## # A tibble: 208 x 5
##     YEAR variable n_total n_missing share_missing
##    <dbl> <chr>      <int>     <int>         <dbl>
##  1  2002 PC19        7127      7023         0.985
##  2  2001 PC19        8325      8130         0.977
##  3  2000 PC19        8719      8174         0.937
```

```
## 4 2014 PP04 14565 7919 0.544
## 5 2004 PP10 10759 4301 0.400
## 6 2001 PP10 8325 3114 0.374
## 7 2005 PP10 8556 3190 0.373
## 8 2020 PP10 20220 7344 0.363
## 9 1999 PP10 9633 3473 0.361
## 10 2000 PP10 8719 3115 0.357
## # i 198 more rows
```

```
comparison_missing <- missing_by_var_year %>%
  dplyr::rename(
    n_missing_before = n_missing,
    share_missing_before = share_missing
  ) %>%
  dplyr::select(YEAR, variable, n_missing_before, share_missing_before) %>%
  dplyr::left_join(
    missing_by_var_year_after %>%
      dplyr::rename(
        n_missing_after = n_missing,
        share_missing_after = share_missing
      ) %>%
      dplyr::select(YEAR, variable, n_missing_after, share_missing_after),
    by = c("YEAR", "variable")
  )

comparison_missing %>%
  dplyr::filter(variable == target_var, YEAR == target_year)
```

```
## # A tibble: 1 x 6
##    YEAR variable n_missing_before share_missing_before n_missing_after
##   <dbl> <chr>               <int>                <dbl>           <int>
## 1  2003 PC19                 6262                0.987            1189
## # i 1 more variable: share_missing_after <dbl>
```

2. Plausibilität der Daten

```
panel_all <- panel_imputed

panel_complete <- panel_imputed %>%
  dplyr::filter(COMPLETE)
```

2.1 Verteilungen innerhalb des SHP: vor und nach Entfernen unvollständiger Fälle

Geschlecht

```
sex_all <- panel_all %>%
  dplyr::filter(SEX %in% c("männlich", "weiblich")) %>%
```

```r
  dplyr::count(SEX) %>%
  dplyr::mutate(
    dataset = "Alle Fälle",
    share = n / sum(n)
  )

sex_complete <- panel_complete %>%
  dplyr::filter(SEX %in% c("männlich", "weiblich")) %>%
  dplyr::count(SEX) %>%
  dplyr::mutate(
    dataset = "Nur vollständige Fälle",
    share = n / sum(n)
  )

sex_compare <- dplyr::bind_rows(sex_all, sex_complete)

sex_compare
```

```
## # A tibble: 4 x 4
##   SEX          n dataset                share
##   <chr>    <int> <chr>                  <dbl>
## 1 männlich 78220 Alle Fälle             0.481
## 2 weiblich 84369 Alle Fälle             0.519
## 3 männlich 34600 Nur vollständige Fälle 0.474
## 4 weiblich 38442 Nur vollständige Fälle 0.526
```

Altersgruppen

```r
age_all <- panel_all %>%
  dplyr::count(AGEGROUP_CURRENT) %>%
  dplyr::mutate(
    dataset = "Alle Fälle",
    share = n / sum(n)
  )

age_complete <- panel_complete %>%
  dplyr::count(AGEGROUP_CURRENT) %>%
  dplyr::mutate(
    dataset = "Nur vollständige Fälle",
    share = n / sum(n)
  )

age_compare <- dplyr::bind_rows(age_all, age_complete)

age_compare
```

```
## # A tibble: 10 x 4
##    AGEGROUP_CURRENT     n dataset                 share
##    <chr>            <int> <chr>                   <dbl>
##  1 18-29            29414 Alle Fälle             0.181
##  2 30-44            41198 Alle Fälle             0.253
```

```
##  3 45-59            47463 Alle Fälle             0.292
##  4 60-74            32013 Alle Fälle             0.197
##  5 75+              12505 Alle Fälle             0.0769
##  6 18-29             8193 Nur vollständige Fälle 0.112
##  7 30-44            18777 Nur vollständige Fälle 0.257
##  8 45-59            23191 Nur vollständige Fälle 0.317
##  9 60-74            16752 Nur vollständige Fälle 0.229
## 10 75+               6130 Nur vollständige Fälle 0.0839
```

Kanton

```r
canton_all <- panel_all %>%
  dplyr::filter(!is.na(CANTON)) %>%
  dplyr::count(CANTON) %>%
  dplyr::mutate(
    dataset = "Alle Fälle",
    share = n / sum(n)
  )

canton_complete <- panel_complete %>%
  dplyr::filter(!is.na(CANTON)) %>%
  dplyr::count(CANTON) %>%
  dplyr::mutate(
    dataset = "Nur vollständige Fälle",
    share = n / sum(n)
  )

canton_compare <- dplyr::bind_rows(canton_all, canton_complete)

canton_compare
```

```
## # A tibble: 52 x 4
##    CANTON     n dataset      share
##    <chr>  <int> <chr>        <dbl>
##  1 AG     13745 Alle Fälle 0.0845
##  2 AI       238 Alle Fälle 0.00146
##  3 AR      1302 Alle Fälle 0.00801
##  4 BE     20217 Alle Fälle 0.124
##  5 BL      5692 Alle Fälle 0.0350
##  6 BS      3268 Alle Fälle 0.0201
##  7 FR      6121 Alle Fälle 0.0376
##  8 GE      7046 Alle Fälle 0.0433
##  9 GL       880 Alle Fälle 0.00541
## 10 GR      3512 Alle Fälle 0.0216
## # i 42 more rows
```

2.2 BFS-Daten einlesen

```r
bfs_raw <- tryCatch(
  read.px(
```

```r
    filename = "https://dam-api.bfs.admin.ch/hub/api/dam/assets/36021707/master",
    encoding = "utf-8"
  ),
  error = function(e) NULL
)

head(bfs_raw)
```

```
## $AXIS.VERSION
## $AXIS.VERSION$value
## [1] "2010"
##
##
## $CHARSET
## $CHARSET$value
## [1] "ANSI"
##
##
## $CODEPAGE
## $CODEPAGE$value
## [1] "iso-8859-15"
##
##
## $CODES
## $CODES$Jahr
##  [1] "2010" "2011" "2012" "2013" "2014" "2015" "2016" "2017" "2018" "2019"
## [11] "2020" "2021" "2022" "2023" "2024"
##
## $CODES$Kanton
##  [1] "8100" "ZH"   "BE"   "LU"   "UR"   "SZ"   "OW"   "NW"   "GL"   "ZG"
## [11] "FR"   "SO"   "BS"   "BL"   "SH"   "AR"   "AI"   "SG"   "GR"   "AG"
## [21] "TG"   "TI"   "VD"   "VS"   "NE"   "GE"   "JU"   "-9"
##
## $CODES$Bevölkerungstyp
## [1] "1" "2"
##
## $CODES$Geschlecht
## [1] "-99999" "1"      "2"
##
## $CODES$Zivilstand
## [1] "-99999" "1"      "2"      "3"      "4"      "-9"
##
## $CODES$Alter
##   [1] "-99999" "0"      "1"      "2"      "3"      "4"      "5"      "6"
##   [9] "7"      "8"      "9"      "10"     "11"     "12"     "13"     "14"
##  [17] "15"     "16"     "17"     "18"     "19"     "20"     "21"     "22"
##  [25] "23"     "24"     "25"     "26"     "27"     "28"     "29"     "30"
##  [33] "31"     "32"     "33"     "34"     "35"     "36"     "37"     "38"
##  [41] "39"     "40"     "41"     "42"     "43"     "44"     "45"     "46"
##  [49] "47"     "48"     "49"     "50"     "51"     "52"     "53"     "54"
##  [57] "55"     "56"     "57"     "58"     "59"     "60"     "61"     "62"
##  [65] "63"     "64"     "65"     "66"     "67"     "68"     "69"     "70"
##  [73] "71"     "72"     "73"     "74"     "75"     "76"     "77"     "78"
```

```
##  [81] "79"     "80"     "81"     "82"     "83"     "84"     "85"     "86"
##  [89] "87"     "88"     "89"     "90"     "91"     "92"     "93"     "94"
##  [97] "95"     "96"     "97"     "98"     "99"     "100"
##
##
## $CODES.en.
## $CODES.en.$Year
## [1] "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\"2018\",\"2019\",\"2020\
##
## $CODES.en.$Canton
## [1] "8100\",\"ZH\",\"BE\",\"LU\",\"UR\",\"SZ\",\"OW\",\"NW\",\"GL\",\"ZG\",\"FR\",\"SO\",\"BS\",\"BL
##
## $CODES.en.$Population.type
## [1] "1\",\"2"
##
## $CODES.en.$Sex
## [1] "-99999\",\"1\",\"2"
##
## $CODES.en.$Marital.status
## [1] "-99999\",\"1\",\"2\",\"3\",\"4\",\"-9"
##
## $CODES.en.$Age
## [1] "-99999\",\"0\",\"1\",\"2\",\"3\",\"4\",\"5\",\"6\",\"7\",\"8\",\"9\",\"10\",\"11\",\"12\",\"13\
##
##
## $CODES.fr.
## $CODES.fr.$Année
## [1] "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\"2018\",\"2019\",\"2020\
##
## $CODES.fr.$Canton
## [1] "8100\",\"ZH\",\"BE\",\"LU\",\"UR\",\"SZ\",\"OW\",\"NW\",\"GL\",\"ZG\",\"FR\",\"SO\",\"BS\",\"BL
##
## $CODES.fr.$Type.de.population
## [1] "1\",\"2"
##
## $CODES.fr.$Sexe
## [1] "-99999\",\"1\",\"2"
##
## $CODES.fr.$État.civil
## [1] "-99999\",\"1\",\"2\",\"3\",\"4\",\"-9"
##
## $CODES.fr.$Âge
## [1] "-99999\",\"0\",\"1\",\"2\",\"3\",\"4\",\"5\",\"6\",\"7\",\"8\",\"9\",\"10\",\"11\",\"12\",\"13\
```

2.3 BFS-Daten inspizieren

```r
if (!is.null(bfs_raw)) {
  try(str(bfs_raw, max.level = 2), silent = TRUE)
  try(names(bfs_raw), silent = TRUE)
  bfs_tbl <- tryCatch(as.data.frame(bfs_raw), error = function(e) NULL)
} else {
  bfs_tbl <- NULL
```

```
}
```

```
## List of 100
##  $ AXIS.VERSION    :List of 1
##   ..$ value: chr "2010"
##  $ CHARSET         :List of 1
##   ..$ value: chr "ANSI"
##  $ CODEPAGE        :List of 1
##   ..$ value: chr "iso-8859-15"
##  $ CODES           :List of 6
##   ..$ Jahr           : chr [1:15] "2010" "2011" "2012" "2013" ...
##   ..$ Kanton         : chr [1:28] "8100" "ZH" "BE" "LU" ...
##   ..$ Bevölkerungstyp: chr [1:2] "1" "2"
##   ..$ Geschlecht     : chr [1:3] "-99999" "1" "2"
##   ..$ Zivilstand     : chr [1:6] "-99999" "1" "2" "3" ...
##   ..$ Alter          : chr [1:102] "-99999" "0" "1" "2" ...
##  $ CODES.en.       :List of 6
##   ..$ Year           : chr "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\"2
##   ..$ Canton         : chr "8100\",\"ZH\",\"BE\",\"LU\",\"UR\",\"SZ\",\"OW\",\"NW\",\"GL\",\"ZG\",\"B
##   ..$ Population.type: chr "1\",\"2"
##   ..$ Sex            : chr "-99999\",\"1\",\"2"
##   ..$ Marital.status : chr "-99999\",\"1\",\"2\",\"3\",\"4\",\"-9"
##   ..$ Age            : chr "-99999\",\"0\",\"1\",\"2\",\"3\",\"4\",\"5\",\"6\",\"7\",\"8\",\"9\",\"10
##  $ CODES.fr.       :List of 6
##   ..$ Année             : chr "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\"
##   ..$ Canton            : chr "8100\",\"ZH\",\"BE\",\"LU\",\"UR\",\"SZ\",\"OW\",\"NW\",\"GL\",\"ZG\"
##   ..$ Type.de.population: chr "1\",\"2"
##   ..$ Sexe              : chr "-99999\",\"1\",\"2"
##   ..$ État.civil        : chr "-99999\",\"1\",\"2\",\"3\",\"4\",\"-9"
##   ..$ Âge               : chr "-99999\",\"0\",\"1\",\"2\",\"3\",\"4\",\"5\",\"6\",\"7\",\"8\",\"9\",\
##  $ CODES.it.       :List of 6
##   ..$ Anno               : chr "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\
##   ..$ Cantone            : chr "8100\",\"ZH\",\"BE\",\"LU\",\"UR\",\"SZ\",\"OW\",\"NW\",\"GL\",\"ZG\
##   ..$ Tipo.di.popolazione: chr "1\",\"2"
##   ..$ Sesso              : chr "-99999\",\"1\",\"2"
##   ..$ Stato.civile       : chr "-99999\",\"1\",\"2\",\"3\",\"4\",\"-9"
##   ..$ Età                : chr "-99999\",\"0\",\"1\",\"2\",\"3\",\"4\",\"5\",\"6\",\"7\",\"8\",\"9\"
##  $ CONTACT         :List of 1
##   ..$ value: chr "Sektion Demografie und Migration, +41 58 463 67 11, E-Mail: info.dem@bfs.admin.ch"
##  $ CONTACT.en.     :List of 1
##   ..$ value: chr "Section Demography and Migration, +41 58 463 67 11, email: info.dem@bfs.admin.ch"
##  $ CONTACT.fr.     :List of 1
##   ..$ value: chr "Section Démographie et migration, +41 58 463 67 11, e-mail: info.dem@bfs.admin.ch"
##  $ CONTACT.it.     :List of 1
##   ..$ value: chr "Sezione Demografia e migrazione, +41 58 463 67 11, e-mail: info.dem@bfs.admin.ch"
##  $ CONTENTS        :List of 1
##   ..$ value: chr "Ständige und nichtständige Wohnbevölkerung"
##  $ CONTENTS.en.    :List of 1
##   ..$ value: chr "Permanent and non permanent resident population"
##  $ CONTENTS.fr.    :List of 1
##   ..$ value: chr "Population résidante permanente et non permanente"
##  $ CONTENTS.it.    :List of 1
##   ..$ value: chr "Popolazione residente permanente e non permanente"
```

```
##  $ CREATION.DATE   :List of 1
##   ..$ value: chr "20110822 11:23"
##  $ DATA            :List of 1
##   ..$ value:'data.frame':    1542240 obs. of  7 variables:
##  $ DATABASE        :List of 1
##   ..$ value: chr "BFS - STAT-TAB / Bundesamt für Statistik, 2010 Neuchâtel / Schweiz / © Bundesamt fu
##  $ DATABASE.en.    :List of 1
##   ..$ value: chr "FSO - STAT-TAB / Federal Statistical Office, 2010 Neuchâtel / Switzerland / © Feder
##  $ DATABASE.fr.    :List of 1
##   ..$ value: chr "OFS - STAT-TAB / Office fédéral de la statistique, 2010 Neuchâtel / Suisse / © Offi
##  $ DATABASE.it.    :List of 1
##   ..$ value: chr "UST - STAT-TAB / Ufficio federale di statistica, 2010 Neuchâtel / Svizzera / © Uffi
##  $ DATASYMBOL1     :List of 1
##   ..$ value: chr "-"
##  $ DATASYMBOL1.en. :List of 1
##   ..$ value: chr "-"
##  $ DATASYMBOL1.fr. :List of 1
##   ..$ value: chr "-"
##  $ DATASYMBOL1.it. :List of 1
##   ..$ value: chr "-"
##  $ DATASYMBOL4     :List of 1
##   ..$ value: chr "*"
##  $ DATASYMBOL4.en. :List of 1
##   ..$ value: chr "*"
##  $ DATASYMBOL4.fr. :List of 1
##   ..$ value: chr "*"
##  $ DATASYMBOL4.it. :List of 1
##   ..$ value: chr "*"
##  $ DATASYMBOL5     :List of 1
##   ..$ value: chr "()"
##  $ DATASYMBOL5.en. :List of 1
##   ..$ value: chr "()"
##  $ DATASYMBOL5.fr. :List of 1
##   ..$ value: chr "()"
##  $ DATASYMBOL5.it. :List of 1
##   ..$ value: chr "()"
##  $ DATASYMBOL6     :List of 1
##   ..$ value: chr "X"
##  $ DATASYMBOL6.en. :List of 1
##   ..$ value: chr "X"
##  $ DATASYMBOL6.fr. :List of 1
##   ..$ value: chr "X"
##  $ DATASYMBOL6.it. :List of 1
##   ..$ value: chr "X"
##  $ DECIMALS        :List of 1
##   ..$ value: chr "0"
##  $ DESCRIPTION     :List of 1
##   ..$ value: chr "Ständige und nichtständige Wohnbevölkerung nach Kanton, Geschlecht, Zivilstand und
##  $ DESCRIPTION.en. :List of 1
##   ..$ value: chr "Permanent and non-permanent resident population by canton, sex, marital status and
##  $ DESCRIPTION.fr. :List of 1
##   ..$ value: chr "Population résidante permanente et non permanente selon le canton, le sexe, l'état
##  $ DESCRIPTION.it. :List of 1
##   ..$ value: chr "Popolazione residente permanente e non permanente secondo il Cantone, il sesso, lo
```

```
##  $ ELIMINATION     :List of 4
##   ..$ Kanton    : chr "Schweiz"
##   ..$ Geschlecht: chr "Geschlecht - Total"
##   ..$ Zivilstand: chr "Zivilstand - Total"
##   ..$ Alter     : chr "Alter - Total"
##  $ ELIMINATION.en. :List of 4
##   ..$ Canton        : chr "Switzerland"
##   ..$ Sex           : chr "Sex - total"
##   ..$ Marital.status: chr "Marital status - total"
##   ..$ Age           : chr "Age - total"
##  $ ELIMINATION.fr. :List of 4
##   ..$ Canton    : chr "Suisse"
##   ..$ Sexe      : chr "Sexe - total"
##   ..$ État.civil: chr "État civil - total"
##   ..$ Âge       : chr "Âge - total"
##  $ ELIMINATION.it. :List of 4
##   ..$ Cantone     : chr "Svizzera"
##   ..$ Sesso       : chr "Sesso - totale"
##   ..$ Stato.civile: chr "Stato civile - totale"
##   ..$ Età         : chr "Età - totale"
##  $ HEADING         :List of 1
##   ..$ value: chr "Alter"
##  $ HEADING.en.     :List of 1
##   ..$ value: chr "Age"
##  $ HEADING.fr.     :List of 1
##   ..$ value: chr "Âge"
##  $ HEADING.it.     :List of 1
##   ..$ value: chr "Età"
##  $ LANGUAGE        :List of 1
##   ..$ value: chr "de"
##  $ LANGUAGES       :List of 1
##   ..$ value: chr "de\",\"fr\",\"it\",\"en"
##  $ LAST.UPDATED    :List of 1
##   ..$ value: chr "20250827 08:30"
##  $ LINK            :List of 1
##   ..$ value: chr "https://www.bfs.admin.ch/asset/de/px-x-0102010000_102"
##  $ LINK.en.        :List of 1
##   ..$ value: chr "https://www.bfs.admin.ch/asset/en/px-x-0102010000_102"
##  $ LINK.fr.        :List of 1
##   ..$ value: chr "https://www.bfs.admin.ch/asset/fr/px-x-0102010000_102"
##  $ LINK.it.        :List of 1
##   ..$ value: chr "https://www.bfs.admin.ch/asset/it/px-x-0102010000_102"
##  $ MATRIX          :List of 1
##   ..$ value: chr "px-x-0102010000_102"
##  $ NOTE            :List of 3
##   ..$ value     : chr "<B>Metainformation:</B>#Letzte Änderungen: Neuer Datensatz (Jahr 2024)#Stand d
##   ..$ Kanton    : chr "Ohne Angabe: Personen im Asylprozess (Ausweise F, N, S und nicht zugewiesen),
##   ..$ Zivilstand: chr "Ohne Angabe: Beinhaltet zusätzlich Personen in aufgelöster Partnerschaft, für
##  $ NOTE.en.        :List of 3
##   ..$ value         : chr "<B>Meta information:</B>#Last modified: New data set (year 2024)#Data upda
##   ..$ Canton        : chr "No indication: persons in the asylum system (F, N, S permits and unalloca
##   ..$ Marital.status: chr "No indication: Includes also persons with dissolved partnership, unknown w
##  $ NOTE.fr.        :List of 3
##   ..$ value     : chr "<B>Métainformation:</B>#Dernière modification: nouvelles données (année 2024)#
```

```
##   ..$ Canton    : chr "Sans indication: personnes dans le processus d'asile (livrets F, N, S et non a
##   ..$ État.civil: chr "Sans indication: Inclut également les personnes avec partenariat dissous dont
##  $ NOTE.it.        :List of 3
##   ..$ value       : chr "<B>Metainformazione:</B>#Ultima modifica: nuovi dati (anno 2024)#Stato della
##   ..$ Cantone     : chr "Senza indicazione: persone nel processo di asilo (permessi F, N, S e non ass
##   ..$ Stato.civile: chr "Senza indicazione: Include anche le unioni domestiche sciolte, per le quali
##  $ REFPERIOD       :List of 1
##   ..$ value: chr "2024,2023,2022,2021,2020,2019,2018,2017,2016,2015,2014,2013,2012,2011,2010"
##  $ REFPERIOD.en.   :List of 1
##   ..$ value: chr "2024,2023,2022,2021,2020,2019,2018,2017,2016,2015,2014,2013,2012,2011,2010"
##  $ REFPERIOD.fr.   :List of 1
##   ..$ value: chr "2024,2023,2022,2021,2020,2019,2018,2017,2016,2015,2014,2013,2012,2011,2010"
##  $ REFPERIOD.it.   :List of 1
##   ..$ value: chr "2024,2023,2022,2021,2020,2019,2018,2017,2016,2015,2014,2013,2012,2011,2010"
##  $ SHOWDECIMALS    :List of 1
##   ..$ value: chr "0"
##  $ SOURCE          :List of 1
##   ..$ value: chr "BFS - Statistik der Bevölkerung und der Haushalte - © BFS"
##  $ SOURCE.en.      :List of 1
##   ..$ value: chr "FSO - Population and Households Statistics - © FSO"
##  $ SOURCE.fr.      :List of 1
##   ..$ value: chr "OFS - Statistique de la population et des ménages - © OFS"
##  $ SOURCE.it.      :List of 1
##   ..$ value: chr "UST - Statistica della popolazione e delle economie domestiche - © UST"
##  $ STUB            :List of 1
##   ..$ value: chr [1:5] "Jahr" "Kanton" "Bevölkerungstyp" "Geschlecht" ...
##  $ STUB.en.        :List of 1
##   ..$ value: chr "Year\",\"Canton\",\"Population type\",\"Sex\",\"Marital status"
##  $ STUB.fr.        :List of 1
##   ..$ value: chr "Année\",\"Canton\",\"Type de population\",\"Sexe\",\"État civil"
##  $ STUB.it.        :List of 1
##   ..$ value: chr "Anno\",\"Cantone\",\"Tipo di popolazione\",\"Sesso\",\"Stato civile"
##  $ SUBJECT.AREA    :List of 1
##   ..$ value: chr "01 - Bevölkerung"
##  $ SUBJECT.AREA.en.:List of 1
##   ..$ value: chr "01 - Population"
##  $ SUBJECT.AREA.fr.:List of 1
##   ..$ value: chr "01 - Population"
##  $ SUBJECT.AREA.it.:List of 1
##   ..$ value: chr "01 - Popolazione"
##  $ SUBJECT.CODE    :List of 1
##   ..$ value: chr "01"
##  $ SURVEY          :List of 1
##   ..$ value: chr "Statistik der Bevölkerung und der Haushalte (STATPOP)"
##  $ SURVEY.en.      :List of 1
##   ..$ value: chr "Population and Households Statistics (STATPOP)"
##  $ SURVEY.fr.      :List of 1
##   ..$ value: chr "Statistique de la population et des ménages (STATPOP)"
##  $ SURVEY.it.      :List of 1
##   ..$ value: chr "Statistica della popolazione e delle economie domestiche (STATPOP)"
##  $ TIMEVAL         :List of 1
##   ..$ Jahr: chr "TLIST(A1),\"2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\
##  $ TIMEVAL.en.     :List of 1
##   ..$ Year: chr "TLIST(A1),\"2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\
```

```
##  $ TIMEVAL.fr.     :List of 1
##   ..$ Année: chr "TLIST(A1),\"2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\
##  $ TIMEVAL.it.     :List of 1
##   ..$ Anno: chr "TLIST(A1),\"2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\
##  $ TITLE           :List of 1
##   ..$ value: chr "Ständige und nichtständige Wohnbevölkerung nach Jahr, Kanton, Bevölkerungstyp, Gesc
##  $ TITLE.en.       :List of 1
##   ..$ value: chr "Permanent and non permanent resident population by Year, Canton, Population type, S
##  $ TITLE.fr.       :List of 1
##   ..$ value: chr "Population résidante permanente et non permanente selon Année, Canton, Type de popu
##  $ TITLE.it.       :List of 1
##   ..$ value: chr "Popolazione residente permanente e non permanente da Anno, Cantone, Tipo di popolaz
##  $ UNITS           :List of 1
##   ..$ value: chr "Person"
##  $ UNITS.en.       :List of 1
##   ..$ value: chr "Person"
##  $ UNITS.fr.       :List of 1
##   ..$ value: chr "Personne"
##  $ UNITS.it.       :List of 1
##   ..$ value: chr "Persona"
##  $ VALUES          :List of 6
##   ..$ Jahr           : chr [1:15] "2010" "2011" "2012" "2013" ...
##   ..$ Kanton         : chr [1:28] "Schweiz" "Zürich" "Bern / Berne" "Luzern" ...
##   ..$ Bevölkerungstyp: chr [1:2] "Ständige Wohnbevölkerung" "Nichtständige Wohnbevölkerung"
##   ..$ Geschlecht     : chr [1:3] "Geschlecht - Total" "Mann" "Frau"
##   ..$ Zivilstand     : chr [1:6] "Zivilstand - Total" "Ledig" "Verheiratet, in eingetragener Partners
##   ..$ Alter          : chr [1:102] "Alter - Total" "0 Jahre" "1 Jahr" "2 Jahre" ...
##  $ VALUES.en.      :List of 6
##   ..$ Year           : chr "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\",\"2
##   ..$ Canton         : chr "Switzerland\",\"Zürich\",\"Bern / Berne\",\"Luzern\",\"Uri\",\"Schwyz\",\
##   ..$ Population.type: chr "Permanent resident population\",\"Non permanent resident population"
##   ..$ Sex            : chr "Sex - total\",\"Male\",\"Female"
##   ..$ Marital.status : chr "Marital status - total\",\"Single\", \"Married, in a registered partnersh
##   ..$ Age            : chr "Age - total\",\"0 years\",\"1 year\",\"2 years\",\"3 years\",\"4 years\"
##  $ VALUES.fr.      :List of 6
##   ..$ Année             : chr "2010\",\"2011\",\"2012\",\"2013\",\"2014\",\"2015\",\"2016\",\"2017\"
##   ..$ Canton            : chr "Suisse\",\"Zürich\",\"Bern / Berne\",\"Luzern\",\"Uri\",\"Schwyz\",\"0
##   ..$ Type.de.population: chr "Population résidante permanente\", \"Population résidante non permanen
##   ..$ Sexe              : chr "Sexe - total\",\"Homme\",\"Femme"
##   ..$ État.civil        : chr "État civil - total\",\"Célibataire\", \"Marié, lié par un partenariat
##   ..$ Âge               : chr "Âge - total\",\"0 an\",\"1 an\",\"2 ans\",\"3 ans\",\"4 ans\",\"5 ans\
##   [list output truncated]
##  - attr(*, "class")= chr "px"
```

```r
head(bfs_tbl)
```

```
##           Alter         Zivilstand         Geschlecht          Bevölkerungstyp
## 1 Alter - Total Zivilstand - Total Geschlecht - Total Ständige Wohnbevölkerung
## 2       0 Jahre Zivilstand - Total Geschlecht - Total Ständige Wohnbevölkerung
## 3        1 Jahr Zivilstand - Total Geschlecht - Total Ständige Wohnbevölkerung
## 4       2 Jahre Zivilstand - Total Geschlecht - Total Ständige Wohnbevölkerung
## 5       3 Jahre Zivilstand - Total Geschlecht - Total Ständige Wohnbevölkerung
## 6       4 Jahre Zivilstand - Total Geschlecht - Total Ständige Wohnbevölkerung
##    Kanton Jahr   value
```

```
## 1 Schweiz 2010 7870134
## 2 Schweiz 2010   78031
## 3 Schweiz 2010   79351
## 4 Schweiz 2010   78793
## 5 Schweiz 2010   77708
## 6 Schweiz 2010   76746
```

2.4 BFS-Referenzjahr

```r
bfs_year_ref <- 2023L
bfs_year_ref
```

```
## [1] 2023
```

2.5 BFS Geschlecht

```r
bfs_sex <- bfs_tbl %>%
  dplyr::filter(
    as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
    as.character(Alter) == "Alter - Total",
    as.character(Zivilstand) == "Zivilstand - Total",
    as.character(Kanton) == "Schweiz",
    as.integer(as.character(Jahr)) == bfs_year_ref,
    as.character(Geschlecht) != "Geschlecht - Total"
  ) %>%
  dplyr::mutate(
    SEX = dplyr::case_when(
      as.character(Geschlecht) == "Mann" ~ "männlich",
      as.character(Geschlecht) == "Frau" ~ "weiblich",
      TRUE ~ NA_character_
    )
  ) %>%
  dplyr::filter(!is.na(SEX)) %>%
  dplyr::group_by(SEX) %>%
  dplyr::summarise(
    n = sum(value, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  dplyr::mutate(
    dataset = "BFS",
    share = n / sum(n)
  )

bfs_sex
```

```
## # A tibble: 2 x 4
##   SEX            n dataset share
##   <chr>      <dbl> <chr>   <dbl>
## 1 männlich 4451532 BFS     0.497
## 2 weiblich 4510726 BFS     0.503
```

```r
sex_compare_full <- dplyr::bind_rows(
  sex_all,
  sex_complete,
  bfs_sex
)

sex_compare_full
```

```
## # A tibble: 6 x 4
##   SEX            n dataset                share
##   <chr>      <dbl> <chr>                  <dbl>
## 1 männlich   78220 Alle Fälle             0.481
## 2 weiblich   84369 Alle Fälle             0.519
## 3 männlich   34600 Nur vollständige Fälle 0.474
## 4 weiblich   38442 Nur vollständige Fälle 0.526
## 5 männlich 4451532 BFS                    0.497
## 6 weiblich 4510726 BFS                    0.503
```

```r
sex_compare_full %>%
  ggplot2::ggplot(ggplot2::aes(x = SEX, y = share, fill = dataset)) +
  ggplot2::geom_col(position = "dodge") +
  ggplot2::scale_y_continuous(labels = scales::percent_format()) +
  ggplot2::labs(
    title = paste("Geschlechtsverteilung: SHP vs. BFS (", bfs_year_ref, ")", sep = ""),
    x = "Geschlecht",
    y = "Anteil"
  )
```

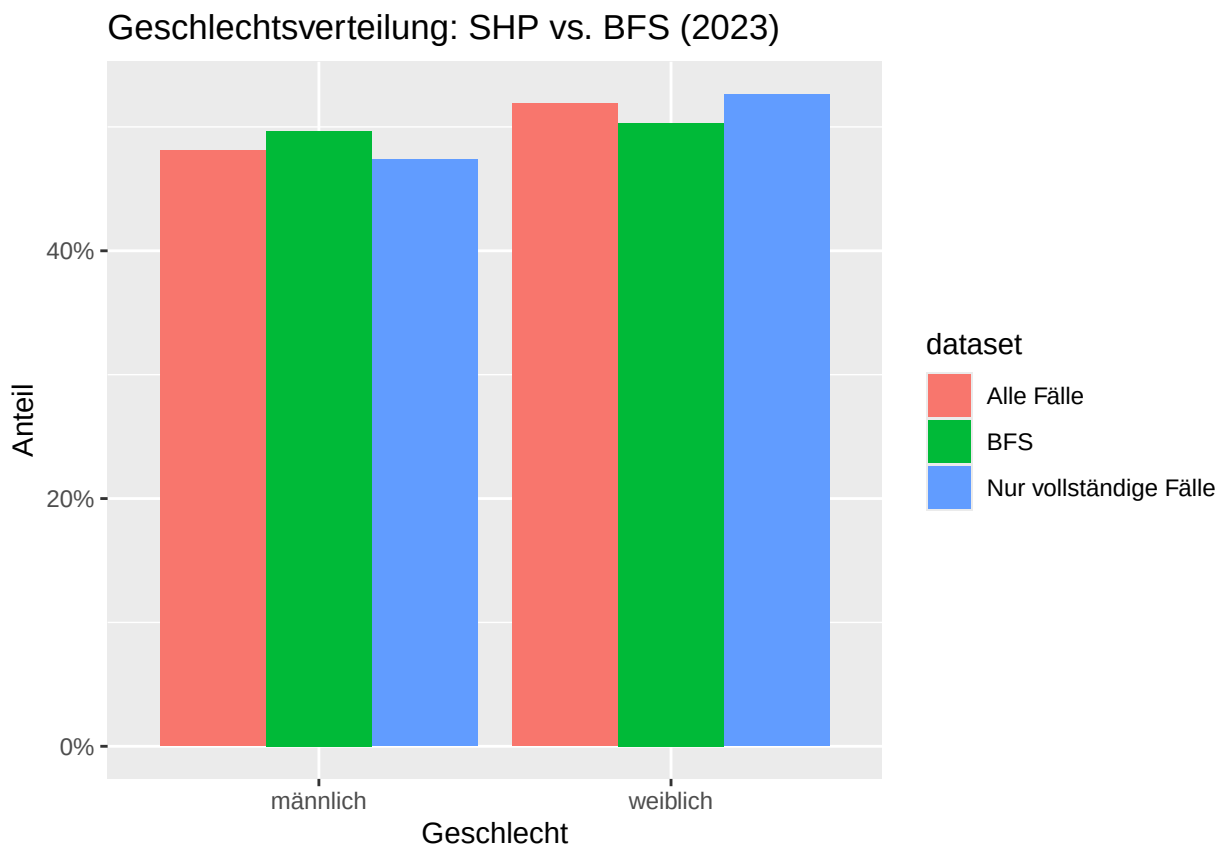

2.6 BFS Alter

```
bfs_age <- bfs_tbl %>%
  dplyr::filter(
    as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
    as.character(Geschlecht) == "Geschlecht - Total",
    as.character(Zivilstand) == "Zivilstand - Total",
    as.character(Kanton) == "Schweiz",
    as.integer(as.character(Jahr)) == bfs_year_ref,
    as.character(Alter) != "Alter - Total"
  ) %>%
  dplyr::mutate(
    age_num = readr::parse_number(as.character(Alter))
  ) %>%
  dplyr::filter(!is.na(age_num), age_num >= 18) %>%
  dplyr::mutate(
    AGEGROUP_CURRENT = dplyr::case_when(
      age_num >= 18 & age_num < 30 ~ "18-29",
      age_num >= 30 & age_num < 45 ~ "30-44",
      age_num >= 45 & age_num < 60 ~ "45-59",
      age_num >= 60 & age_num < 75 ~ "60-74",
      age_num >= 75 ~ "75+",
      TRUE ~ NA_character_
    )
```

```r
  ) %>%
  dplyr::group_by(AGEGROUP_CURRENT) %>%
  dplyr::summarise(
    n = sum(value, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  dplyr::mutate(
    dataset = "BFS",
    share = n / sum(n)
  )

bfs_age
```

```
## # A tibble: 5 x 4
##   AGEGROUP_CURRENT       n dataset share
##   <chr>              <dbl> <chr>   <dbl>
## 1 18-29            1210585 BFS     0.165
## 2 30-44            1936195 BFS     0.263
## 3 45-59            1892401 BFS     0.257
## 4 60-74            1450755 BFS     0.197
## 5 75+               862469 BFS     0.117
```

```r
age_compare_full <- dplyr::bind_rows(
  age_all,
  age_complete,
  bfs_age
)

age_compare_full
```

```
## # A tibble: 15 x 4
##    AGEGROUP_CURRENT       n dataset                 share
##    <chr>              <dbl> <chr>                   <dbl>
##  1 18-29              29414 Alle Fälle             0.181
##  2 30-44              41198 Alle Fälle             0.253
##  3 45-59              47463 Alle Fälle             0.292
##  4 60-74              32013 Alle Fälle             0.197
##  5 75+                12505 Alle Fälle             0.0769
##  6 18-29               8193 Nur vollständige Fälle 0.112
##  7 30-44              18777 Nur vollständige Fälle 0.257
##  8 45-59              23191 Nur vollständige Fälle 0.317
##  9 60-74              16752 Nur vollständige Fälle 0.229
## 10 75+                 6130 Nur vollständige Fälle 0.0839
## 11 18-29            1210585 BFS                    0.165
## 12 30-44            1936195 BFS                    0.263
## 13 45-59            1892401 BFS                    0.257
## 14 60-74            1450755 BFS                    0.197
## 15 75+               862469 BFS                    0.117
```

```r
age_compare_full %>%
  ggplot2::ggplot(ggplot2::aes(x = AGEGROUP_CURRENT, y = share, fill = dataset)) +
  ggplot2::geom_col(position = "dodge") +
```

```r
  ggplot2::scale_y_continuous(labels = scales::percent_format()) +
  ggplot2::labs(
    title = paste("Altersverteilung: SHP vs. BFS (", bfs_year_ref, ")", sep = ""),
    x = "Altersgruppe",
    y = "Anteil"
  )
```

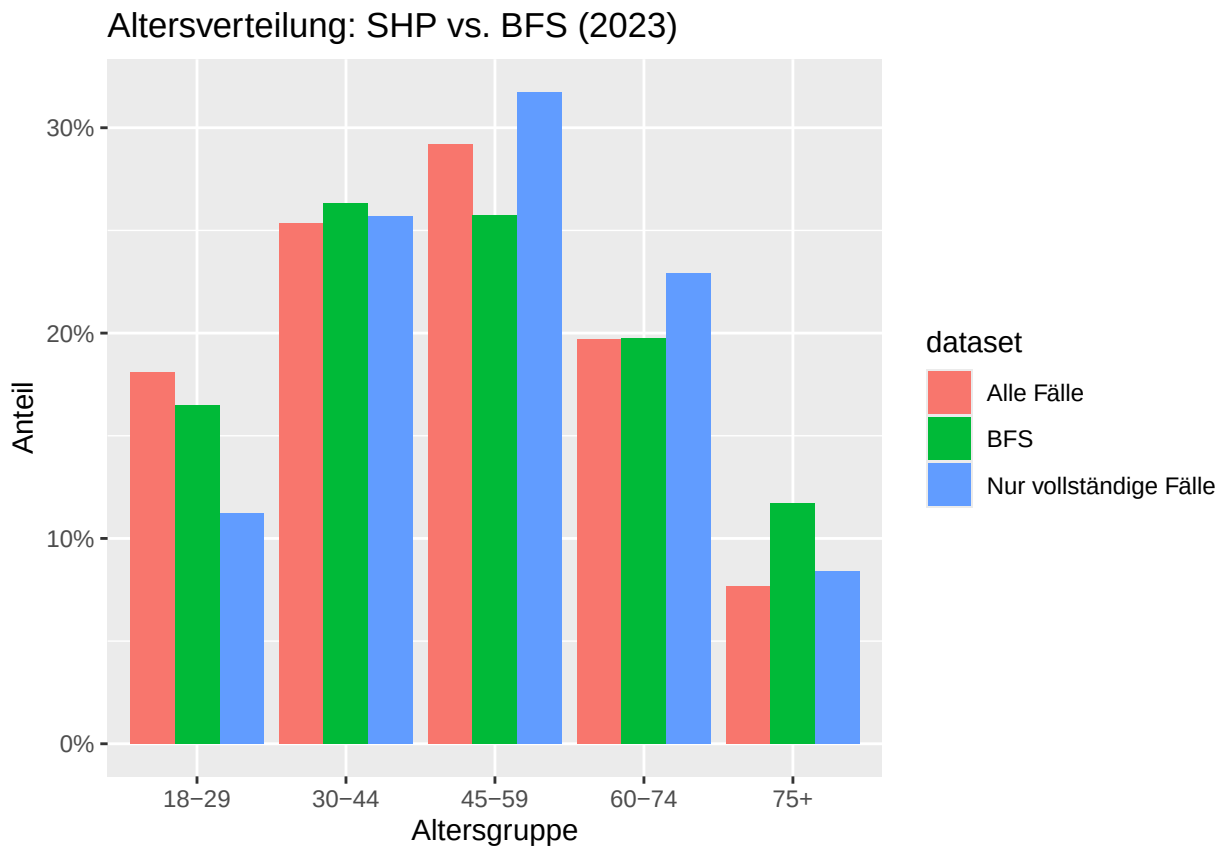

2.7 BFS Kantone

```r
bfs_canton_map <- c(
  "Zürich" = "ZH",
  "Bern / Berne" = "BE",
  "Luzern" = "LU",
  "Uri" = "UR",
  "Schwyz" = "SZ",
  "Obwalden" = "OW",
  "Nidwalden" = "NW",
  "Glarus" = "GL",
  "Zug" = "ZG",
  "Fribourg / Freiburg" = "FR",
  "Solothurn" = "SO",
  "Basel-Stadt" = "BS",
  "Basel-Landschaft" = "BL",
```

```r
  "Schaffhausen" = "SH",
  "Appenzell Ausserrhoden" = "AR",
  "Appenzell Innerrhoden" = "AI",
  "St. Gallen" = "SG",
  "Graubünden / Grigioni / Grischun" = "GR",
  "Aargau" = "AG",
  "Thurgau" = "TG",
  "Ticino" = "TI",
  "Vaud" = "VD",
  "Valais / Wallis" = "VS",
  "Neuchâtel" = "NE",
  "Genève" = "GE",
  "Jura" = "JU"
)
```

```r
bfs_canton <- bfs_tbl %>%
  dplyr::filter(
    as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
    as.character(Alter) == "Alter - Total",
    as.character(Geschlecht) == "Geschlecht - Total",
    as.character(Zivilstand) == "Zivilstand - Total",
    as.integer(as.character(Jahr)) == bfs_year_ref,
    as.character(Kanton) != "Schweiz"
  ) %>%
  dplyr::mutate(
    CANTON = dplyr::recode(as.character(Kanton), !!!bfs_canton_map, .default = NA_character_)
  ) %>%
  dplyr::filter(!is.na(CANTON)) %>%
  dplyr::group_by(CANTON) %>%
  dplyr::summarise(
    n = sum(value, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  dplyr::mutate(
    dataset = "BFS",
    share = n / sum(n)
  )

bfs_canton
```

```
## # A tibble: 26 x 4
##    CANTON       n dataset   share
##    <chr>    <dbl> <chr>     <dbl>
##  1 AG      726894 BFS     0.0811
##  2 AI       16585 BFS     0.00185
##  3 AR       56495 BFS     0.00630
##  4 BE     1063533 BFS     0.119
##  5 BL      298837 BFS     0.0333
##  6 BS      200031 BFS     0.0223
##  7 FR      341537 BFS     0.0381
##  8 GE      524410 BFS     0.0585
##  9 GL       42056 BFS     0.00469
## 10 GR      204888 BFS     0.0229
```

```
## # i 16 more rows
```

```r
canton_compare_full <- dplyr::bind_rows(
  canton_all,
  canton_complete,
  bfs_canton
)

canton_compare_full
```

```
## # A tibble: 78 x 4
##    CANTON     n dataset      share
##    <chr>  <dbl> <chr>        <dbl>
##  1 AG     13745 Alle Fälle 0.0845
##  2 AI       238 Alle Fälle 0.00146
##  3 AR      1302 Alle Fälle 0.00801
##  4 BE     20217 Alle Fälle 0.124
##  5 BL      5692 Alle Fälle 0.0350
##  6 BS      3268 Alle Fälle 0.0201
##  7 FR      6121 Alle Fälle 0.0376
##  8 GE      7046 Alle Fälle 0.0433
##  9 GL       880 Alle Fälle 0.00541
## 10 GR      3512 Alle Fälle 0.0216
## # i 68 more rows
```

```r
canton_compare_full %>%
  ggplot2::ggplot(ggplot2::aes(x = reorder(CANTON, share), y = share, fill = dataset)) +
  ggplot2::geom_col(position = "dodge") +
  ggplot2::coord_flip() +
  ggplot2::scale_y_continuous(labels = scales::percent_format()) +
  ggplot2::labs(
    title = paste("Kantonsverteilung: SHP vs. BFS (", bfs_year_ref, ")", sep = ""),
    x = "Kanton",
    y = "Anteil"
  )
```

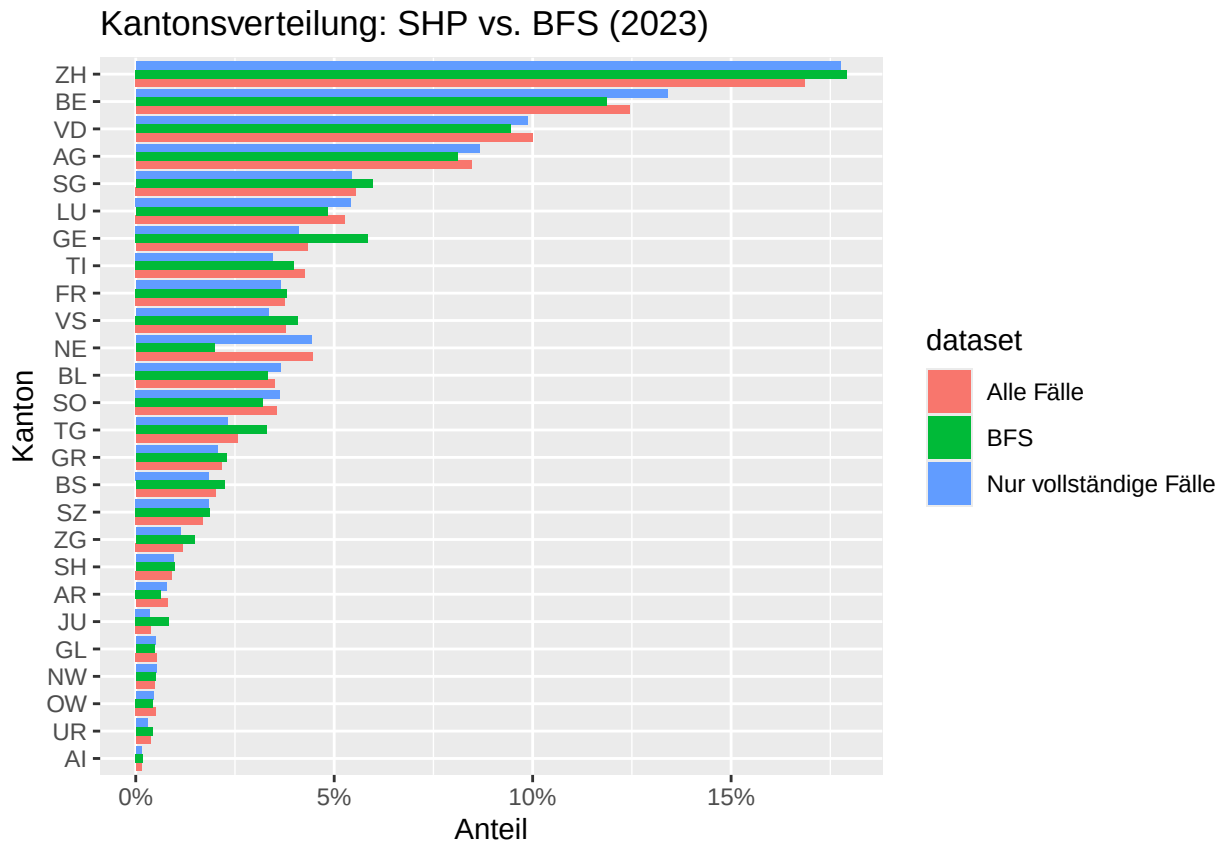

3. Auswertung

3.1 Zeitliche Entwicklung des Vertrauens in den Bundesrat

```
trust_over_time <- panel_imputed %>%
  dplyr::group_by(YEAR) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    .groups = "drop"
  )

trust_over_time
```

```
## # A tibble: 16 x 3
##      YEAR mean_PP04 median_PP04
##     <dbl>     <dbl>       <dbl>
##  1   1999      5.74           6
##  2   2000      5.93           6
##  3   2001      5.92           6
##  4   2002      5.62           6
##  5   2003      5.44           6
##  6   2004      5.28           5
```

```
##  7  2005      5.39           5
##  8  2006      5.50           6
##  9  2007      5.51           6
## 10  2008      5.67           6
## 11  2009      5.39           5
## 12  2011      5.77           6
## 13  2014      5.98           6
## 14  2017      6.31           7
## 15  2020      6.76           7
## 16  2023      6.36           7
```

```
trust_over_time %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04)) +
  ggplot2::geom_line() +
  ggplot2::geom_point() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat über die Zeit",
    x = "Jahr",
    y = "Mittleres Vertrauen (PP04)"
  )
```

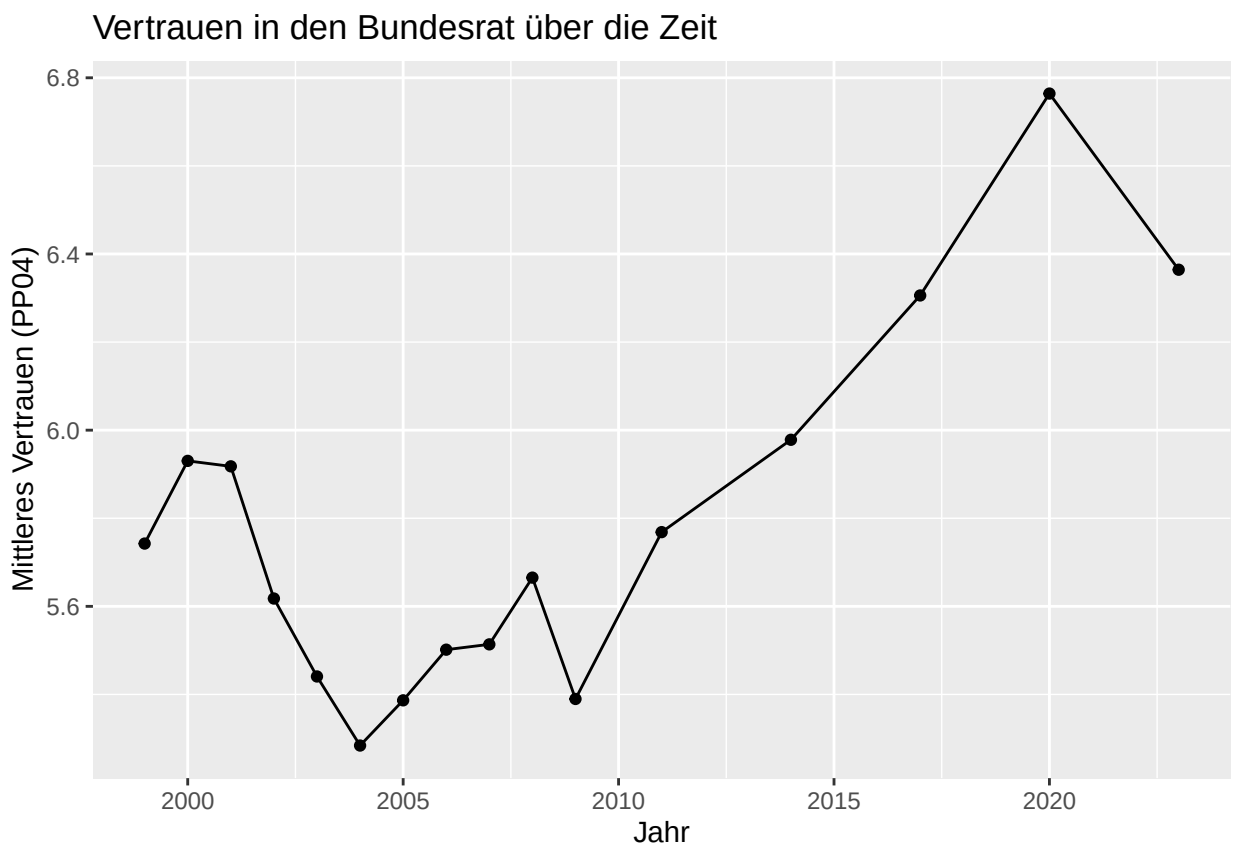

3.2 Zusätzliche Grafiken nach Untergruppen

Grafik 1: nach Geschlecht

```
panel_imputed %>%
  dplyr::filter(!is.na(SEX)) %>%
  dplyr::group_by(YEAR, SEX) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04, color = SEX)) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat nach Geschlecht",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

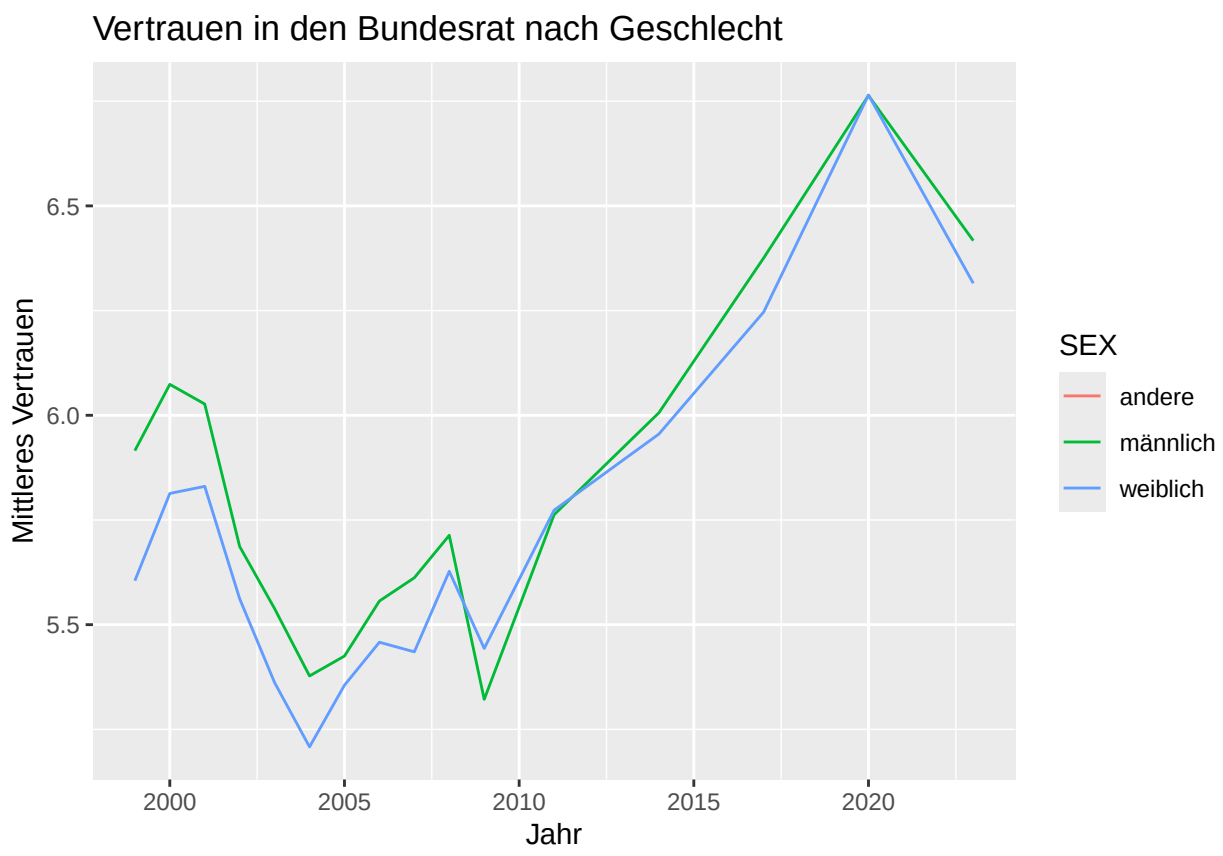

Grafik 2: nach Geburtskohorte

```
panel_imputed %>%
  dplyr::filter(!is.na(BIRTHYGEN)) %>%
```

```
  dplyr::group_by(YEAR, BIRTHYGEN) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04, color = BIRTHYGEN)) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat nach Geburtskohorte",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

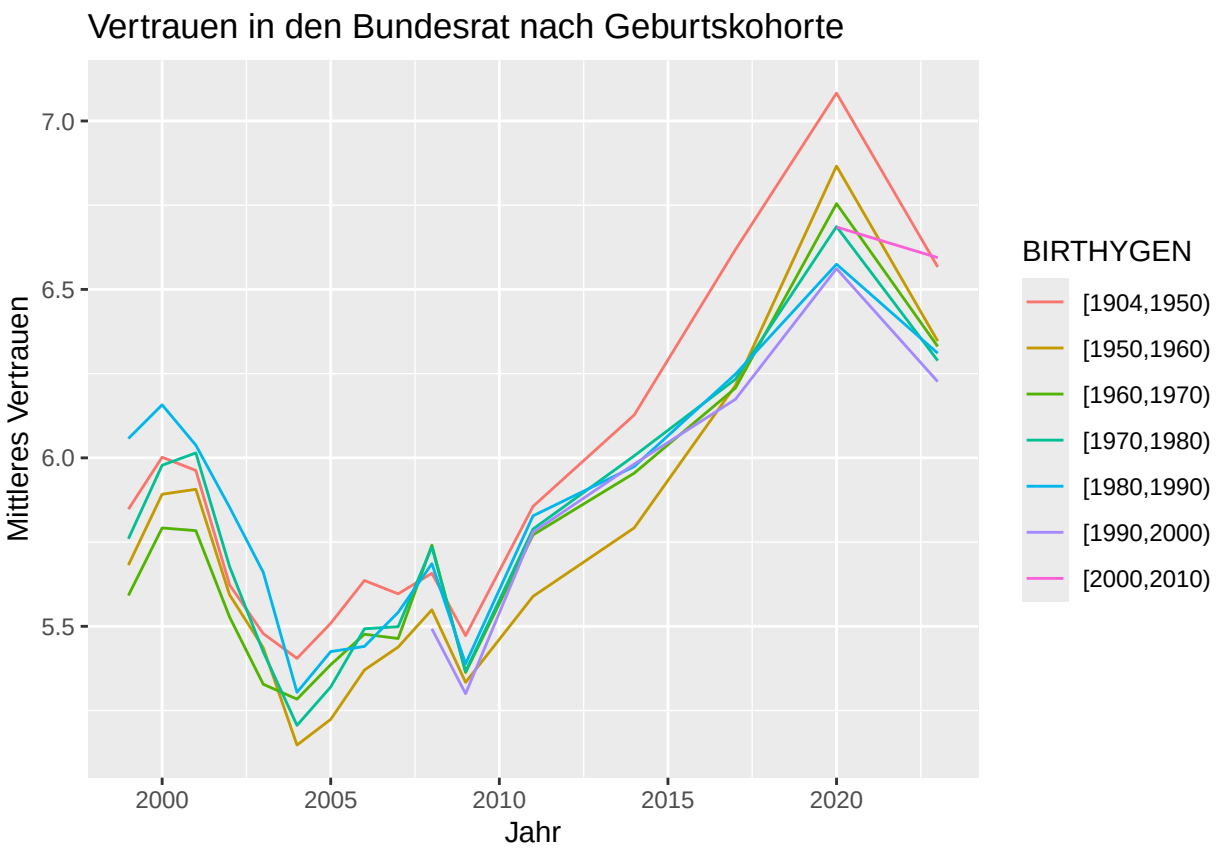

Grafik 3: nach Nationalität

```
panel_imputed %>%
  dplyr::filter(!is.na(NAT)) %>%
  dplyr::group_by(YEAR, NAT) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04, color = NAT)) +
```

```
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat nach Nationalität",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

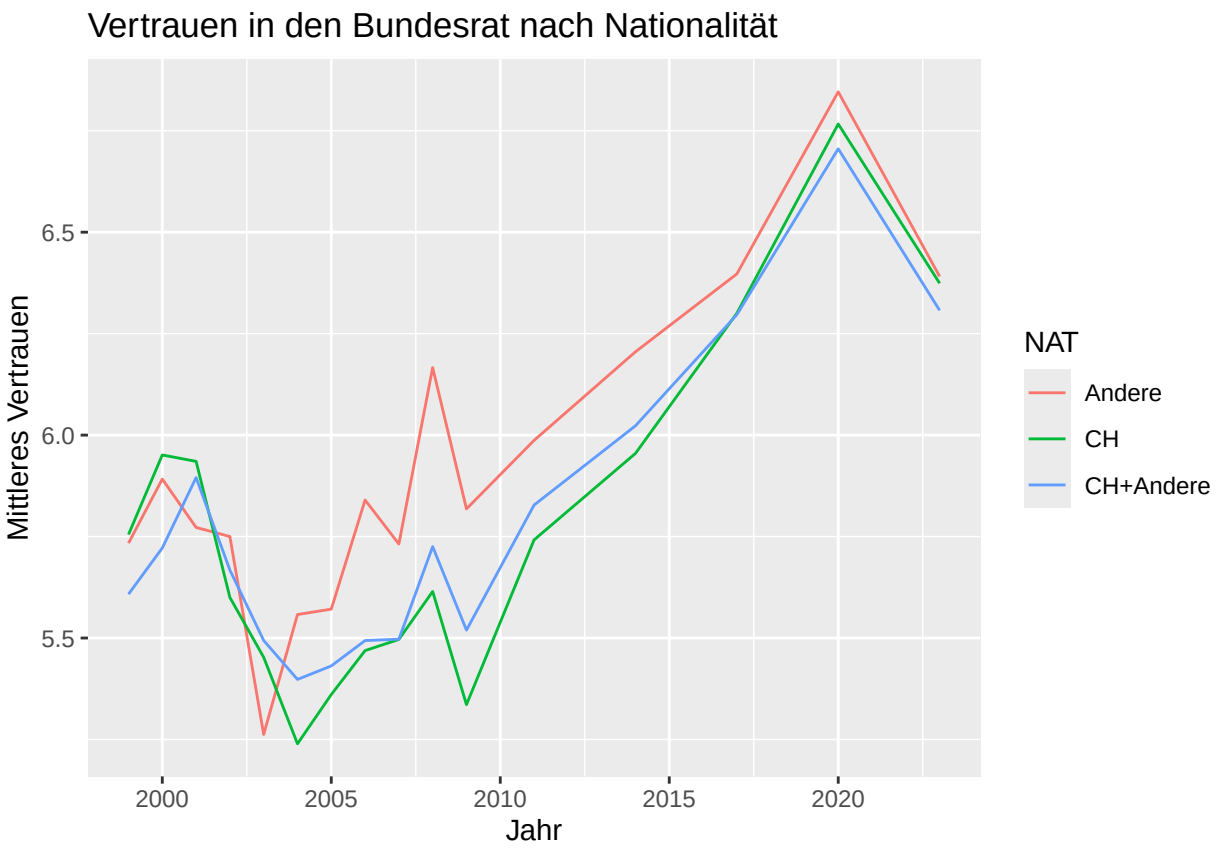

Grafik 4: nach Kindern

```
panel_imputed %>%
  dplyr::filter(!is.na(HASKID)) %>%
  dplyr::group_by(YEAR, HASKID) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04, color = HASKID)) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat nach HASKID",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

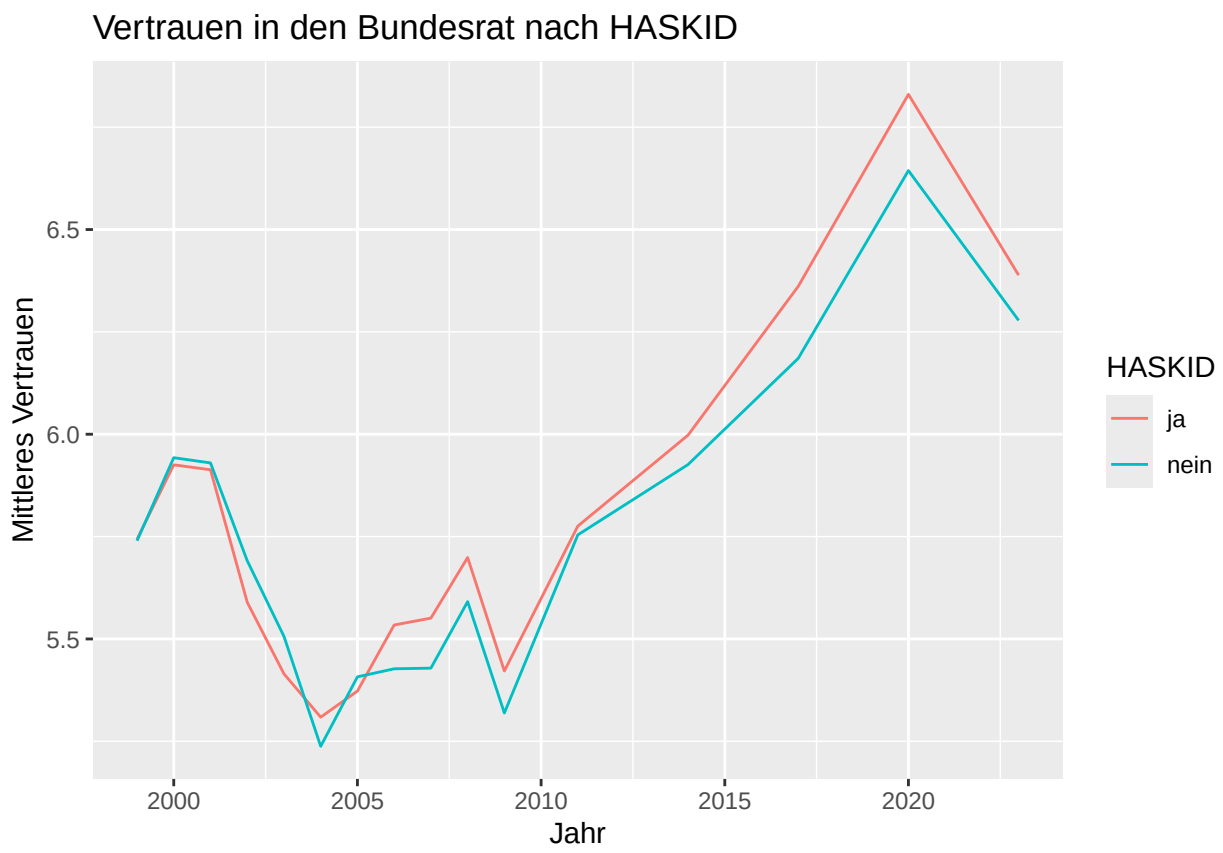

Grafik 5: nach gesundheitlicher Einschränkung

```
panel_imputed %>%
  dplyr::filter(!is.na(PC19)) %>%
  dplyr::group_by(YEAR, PC19) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04, color = PC19)) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat nach gesundheitlicher Einschränkung",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

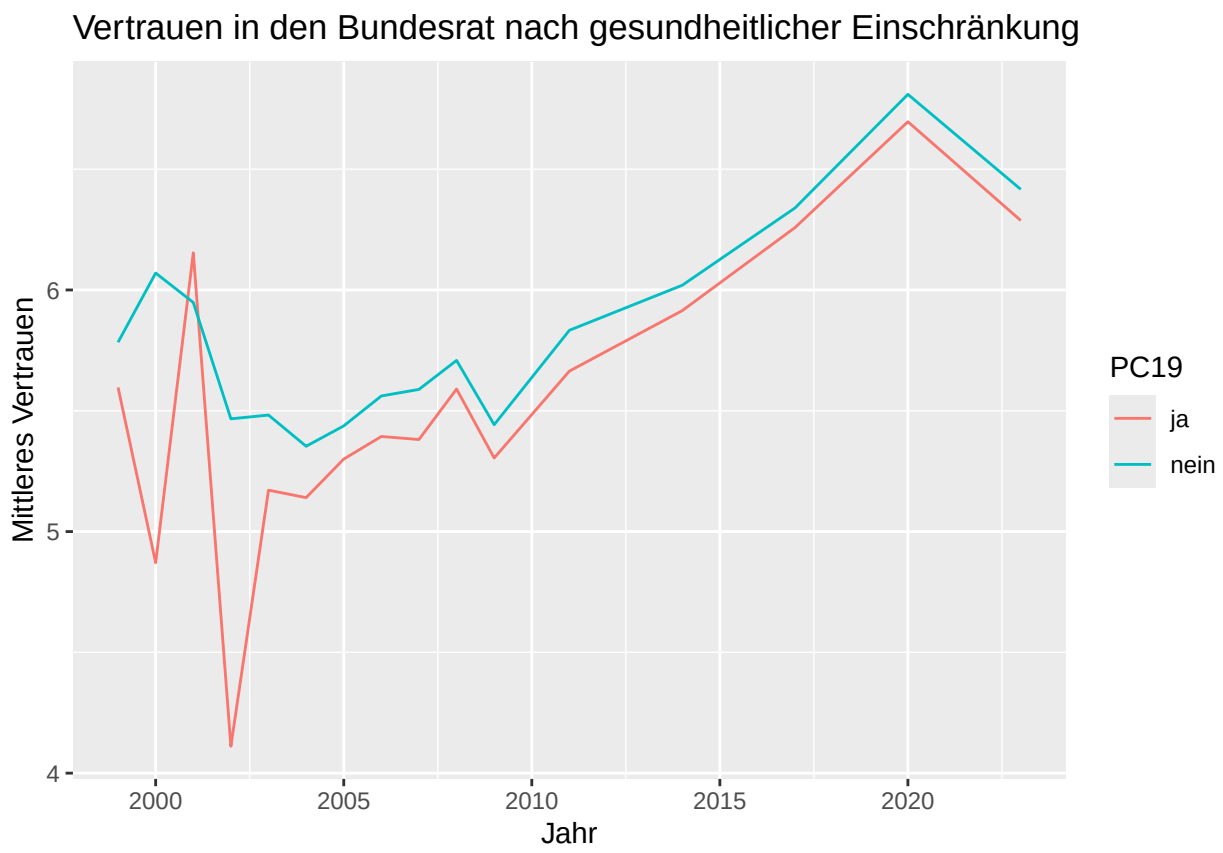

Grafik 6: nach Zivilstand

```
panel_imputed %>%
  dplyr::filter(!is.na(CIVSTA)) %>%
  dplyr::group_by(YEAR, CIVSTA) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot2::ggplot(ggplot2::aes(x = YEAR, y = mean_PP04, color = CIVSTA)) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Vertrauen in den Bundesrat nach Zivilstand",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

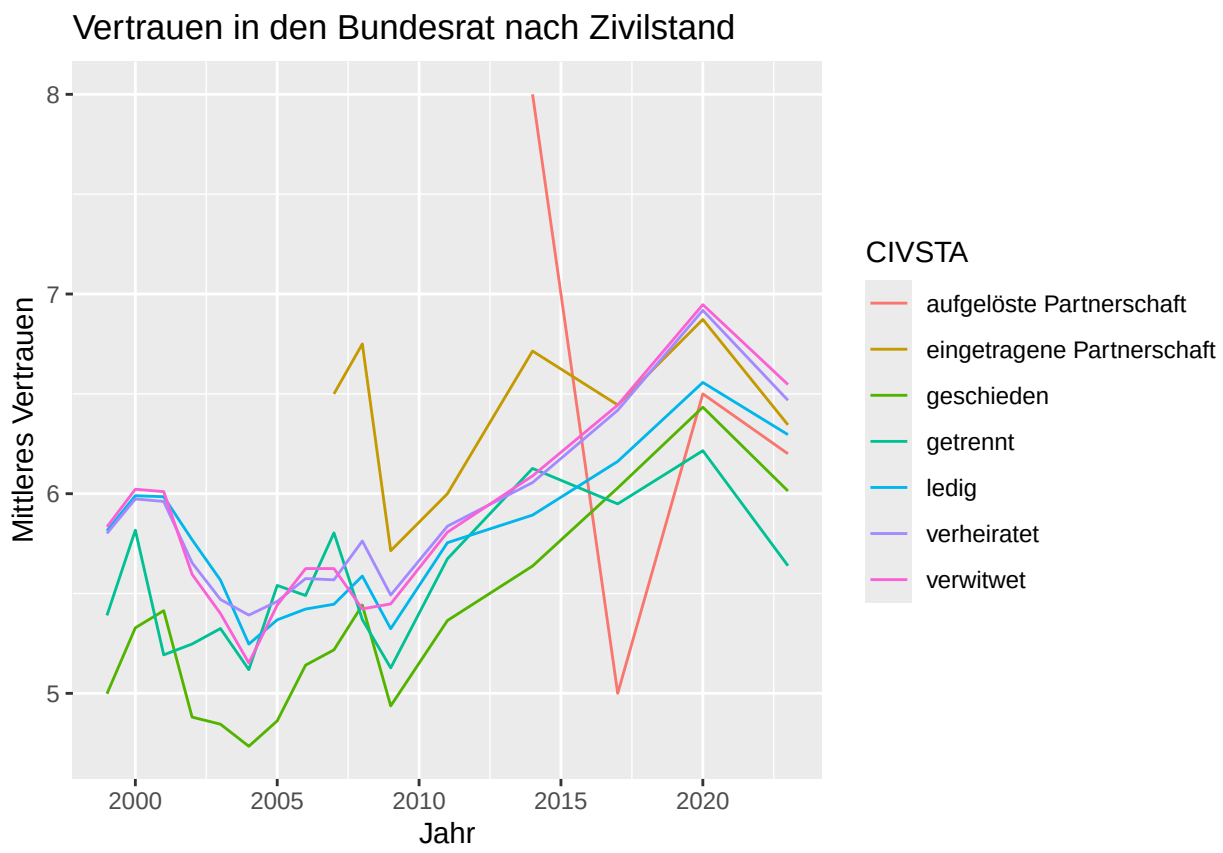

3.3 Zusatzhypothese zu `CIVSTA`

```
civsta_summary <- panel_imputed %>%
  dplyr::filter(!is.na(CIVSTA)) %>%
  dplyr::group_by(CIVSTA) %>%
  dplyr::summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    n = dplyr::n(),
    .groups = "drop"
  )

civsta_summary
```

```
## # A tibble: 7 x 4
##   CIVSTA                      mean_PP04 median_PP04     n
##   <chr>                           <dbl>       <dbl> <int>
## 1 aufgelöste Partnerschaft         6.36           6    11
## 2 eingetragene Partnerschaft       6.51           7   218
## 3 geschieden                       5.49           6 12488
## 4 getrennt                         5.61           6  2145
## 5 ledig                            5.86           6 45062
## 6 verheiratet                      5.96           6 95195
## 7 verwitwet                        5.94           6  7384
```

```r
civsta_summary %>%
  ggplot2::ggplot(ggplot2::aes(x = reorder(CIVSTA, mean_PP04), y = mean_PP04)) +
  ggplot2::geom_col() +
  ggplot2::coord_flip() +
  ggplot2::labs(
    title = "Mittleres Vertrauen in den Bundesrat nach Zivilstand",
    x = "Zivilstand",
    y = "Mittleres Vertrauen"
  )
```

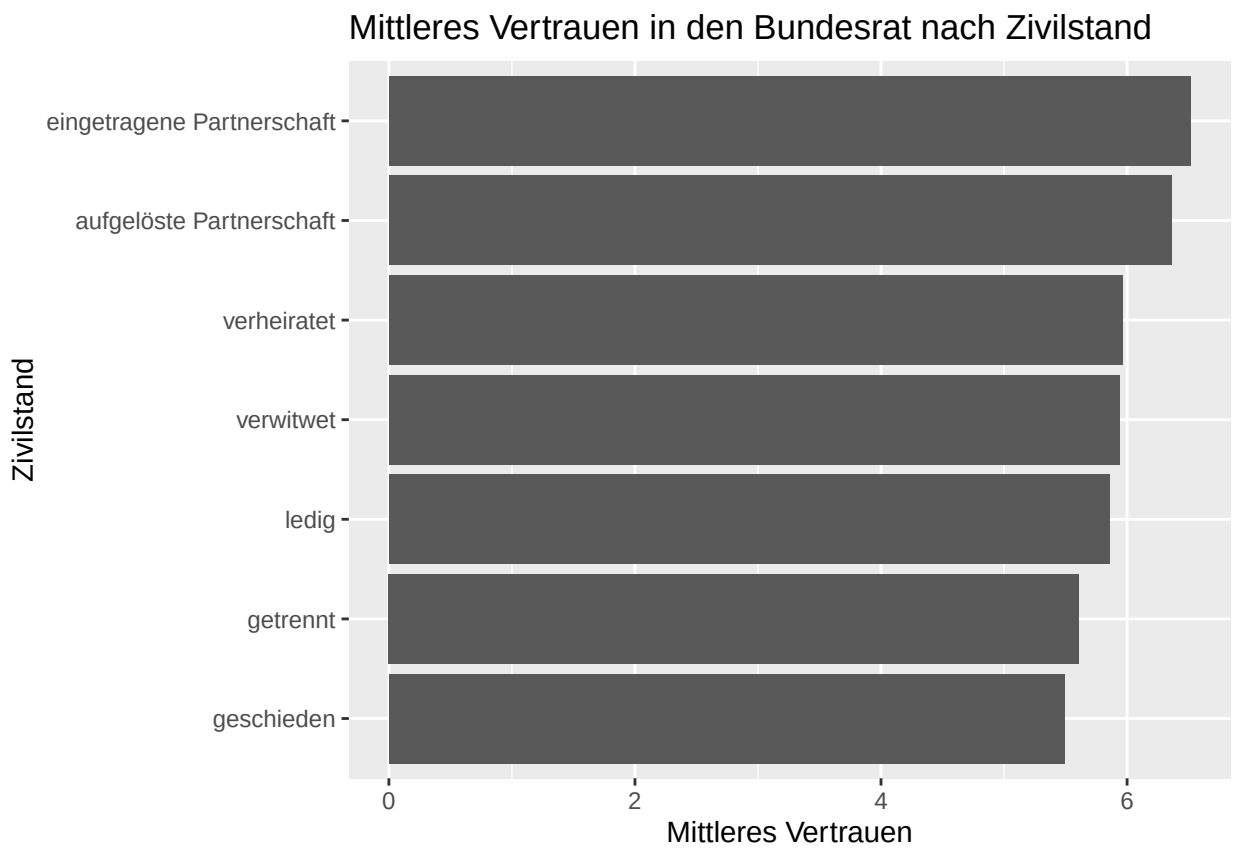

Daten für Woche 3 speichern

```r
if (!dir.exists("../data/processed")) dir.create("../data/processed", recursive = TRUE)

write_csv(panel_imputed, "../data/processed/shp_panel_week3_imputed.csv")
saveRDS(panel_imputed, "../data/processed/shp_panel_week3_imputed.rds")
```

Hinweise für den Bericht

Für den späteren Schlussbericht solltet ihr festhalten: - wie viele unvollständige Fälle es pro Jahr gab, - welche Variable in welchem Jahr den höchsten Missing-Anteil hatte, - wie die Imputation durchgeführt wurde, -

ob sich die Verteilungen von Geschlecht, Altersgruppen und Kanton nach Entfernen unvollständiger Fälle verschieben, - wie sich das Vertrauen in den Bundesrat über die Zeit entwickelt, - und ob die Hypothese zu `CIVSTA` gestützt wird.