Praktikum 2 - Swiss Household Panel

Datenaufbereitung, Datenqualität, Plausibilisierung und Auswertung

Phineas Berdelis / Valentin Schwarz

2026-04-24

Contents

1 Zusammenfassung **2**

2 Einleitung **2**

3 Zielsetzung **3**

4 Aufbau des Berichts **3**

5 Planung und Organisation **3**

6 Datensicherheit **4**

7 Eigener Einflussfaktor **4**

8 Pakete **4**

9 Pfade **4**

10 Hilfsfunktionen **5**

11 1. Datenaufbereitung **6**

11.1 Skizze zum Zusammenführen der Daten . . . 6

11.2 1.1 Rohdaten entpacken . . . 8

11.3 1.2 Benötigte SHP-Dateien laden . . . 8

11.4 1.3 Relevante Variablen auswählen . . . 8

11.5 1.4 Verwendete Befragungsjahre . . . 9

11.6 1.5 Daten bereinigen . . . 9

11.7 1.6 Daten zusammenführen . . . 10

11.8 1.7 Erwachsene filtern . . . 11

11.9 1.8 Zielvariablen konstruieren . . . 11

11.101.9 Enddatensatz . . . 13
11.111.10 Beschrieb der aufbereiteten Daten . . . 14
11.121.11 Speicherung . . . 15

12 2. Datenqualität 15
12.1 2.1 Hilfsvariablen . . . 15
12.2 2.2 Unvollständige Datensätze pro Jahr . . . 15
12.3 2.3 Missing Values pro Jahr und Variable . . . 17
12.4 2.4 Auswahl der Imputationsvariable . . . 18
12.5 2.5 Imputation . . . 18

13 3. Plausibilisierung 20
13.1 3.1 Vergleich vollständige vs. unvollständige Fälle . . . 20
13.2 3.2 BFS-Daten . . . 21

14 4. Auswertung 26
14.1 4.1 Zeitliche Entwicklung von `PP04` . . . 26
14.2 4.2 Zusätzliche Untergruppen-Grafiken . . . 27
14.3 4.3 Hypothese zu `CIVSTA` . . . 33

15 5. Speicherung der Ergebnisse 35

16 6. Fazit 35

17 7. Schlusswort 35

1 Zusammenfassung

Dieser Bericht dokumentiert die Aufbereitung und Analyse der Daten des Swiss Household Panel in einem zusammenhängenden R-Markdown-Dokument. Ausgehend von den SHP-Rohdaten in der bereitgestellten ZIP-Datei wird ein Paneldatensatz auf Personen-Jahr-Ebene aufgebaut, bereinigt und für die Auswertung vorbereitet. Anschliessend werden die Datenqualität, die Missing-Struktur, die Plausibilität der Verteilungen und die Entwicklung des Vertrauens in den Bundesrat untersucht.

Als zusätzliche Einflussvariable wird der Zivilstand (`CIVSTA`) betrachtet. Die Ergebnisse werden in Tabellen und Grafiken zusammengeführt und am Ende als aufbereitete Datensätze gespeichert. Die Auswertung zeigt, dass verheiratete Personen im Mittel ein etwas höheres Vertrauen in den Bundesrat aufweisen als die in der Hypothese definierten Vergleichsgruppen ledig, getrennt und geschieden.

2 Einleitung

Das Dokument fasst Datenaufbereitung, Missing-Analyse, Plausibilisierung und Auswertung in einer einzigen Darstellung zusammen. Die Bearbeitung folgt derselben Logik wie in den Arbeitsdateien `Datenaufbereitung.Rmd` und `Datenqualitaet_Plausibilisierung_Auswertung.Rmd`, bündelt die Schritte jedoch in einer durchgehenden Analyse.

3 Zielsetzung

1. die Erstellung eines Paneldatensatzes auf Personen-Jahr-Ebene,
2. die Konstruktion der benötigten Zielvariablen,
3. die Analyse unvollständiger Fälle und Missing Values,
4. die Imputation einer stark betroffenen Variable mit früheren Personenwerten,
5. die Plausibilisierung mit BFS-Vergleichen,
6. die grafische Auswertung von `PP04`,
7. die Untersuchung einer zusätzlichen Einflussvariable.

Als zusätzliche Einflussvariable wird `CIVSTA` verwendet.

Hypothese: Verheiratete Personen weisen im Durchschnitt ein höheres Vertrauen in den Bundesrat auf als ledige, getrennte oder geschiedene Personen.

4 Aufbau des Berichts

Der Bericht ist entlang der Arbeitsschritte strukturiert:

1. Planung, Organisation und Dateiverwaltung
2. Datensicherheit und Replizierbarkeit
3. Bestimmung und Begründung des zusätzlichen Einflussfaktors
4. Datenaufbereitung inklusive Join-Skizze und Beschrieb des Enddatensatzes
5. Datenqualität, Imputation, Plausibilisierung und Auswertung
6. Zusammenfassende Beurteilung der Ergebnisse in Fazit und Schlusswort

5 Planung und Organisation

Die Bearbeitung wurde in vier Arbeitsschritte gegliedert:

1. Sichtung der verfügbaren SHP-Dateien und Identifikation der benötigten Variablen.
2. Aufbau des Datensatzes auf Personen-Jahr-Ebene mit allen Zielvariablen.
3. Analyse der Datenqualität, Plausibilisierung und Auswertung.
4. Zusammenführung aller Teilarbeiten in einem einzigen dokumentierten R-Markdown-Bericht.

Die Verantwortlichkeiten wurden innerhalb der Gruppe arbeitsteilig organisiert:

- Koordination und Abstimmung der Arbeitsschritte gemeinsam
- Programmierung der Datenaufbereitung und Auswertung arbeitsteilig
- Prüfung, Bereinigung und Dokumentation der Ergebnisse gemeinsam

Die Projektorganisation im Repository ist funktional getrennt:

- `data/raw` enthält die bereitgestellte ZIP-Datei.
- `data/processed` enthält die erzeugten Zwischen- und Enddatensätze.
- `src` enthält die R-Markdown-Dateien für Arbeits- und Berichtsdokumente.
- `docs` enthält ergänzende Unterlagen sowie die separate Dokumentation für den Kommunikationsteil des Projekts.

Die Datenakquisition ist direkt in den Workflow eingebettet: Ausgangspunkt ist die lokal abgelegte ZIP-Datei `data/raw/Data_SPSS.zip`, aus der die benötigten SPSS-Dateien per R entpackt und anschliessend automatisiert eingelesen werden. Damit ist der Workflow ohne manuelle Zwischenschritte reproduzierbar.

6 Datensicherheit

Die Rohdaten werden lokal aus der ZIP-Datei gelesen und im Projektverzeichnis verarbeitet. Es werden keine Originaldaten verändert; alle erzeugten Datensätze werden in `data/processed` separat abgelegt. Die Verarbeitung erfolgt reproduzierbar aus den Quell-Dateien, sodass der finale Datensatz jederzeit neu erstellt werden kann.

Es werden nur die für die Analyse benötigten Variablen ausgewählt. Die BFS-Daten werden ausschliesslich für den Plausibilitätsvergleich verwendet und nur dann geladen, wenn der Zugriff in der Laufumgebung möglich ist.

7 Eigener Einflussfaktor

Als eigener Einflussfaktor wird `CIVSTA` gewählt. Die Variable ist inhaltlich plausibel, da politische Einstellungen und institutionelles Vertrauen mit Lebenssituation, Haushaltstyp und sozialer Einbindung zusammenhängen können.

Die Wahl von `CIVSTA` ist zudem methodisch sinnvoll:

- die Variable ist bereits im SHP vorhanden,
- sie kann verständlich interpretiert werden,
- und sie erlaubt eine inhaltlich nachvollziehbare Hypothese.

Als fachliche Grundlage für das Verständnis der Datenstruktur dient insbesondere der SHP User Guide von Voorpostel et al. (2021).

8 Pakete

```r
library(tidyverse)
library(foreign)
library(pxR)
library(knitr)

# Explizite Bindungen verhindern Konflikte mit plyr beim Knit.
select <- dplyr::select
filter <- dplyr::filter
mutate <- dplyr::mutate
arrange <- dplyr::arrange
rename <- dplyr::rename
count <- dplyr::count
group_by <- dplyr::group_by
summarise <- dplyr::summarise
summarize <- dplyr::summarize
left_join <- dplyr::left_join
pivot_longer <- tidyr::pivot_longer
```

9 Pfade

```r
zip_path <- "../data/raw/Data_SPSS.zip"
unzipped_dir <- "../data/raw/data_unzipped"
processed_dir <- "../data/processed"

if (!dir.exists(unzipped_dir)) dir.create(unzipped_dir, recursive = TRUE)
if (!dir.exists(processed_dir)) dir.create(processed_dir, recursive = TRUE)
```

10 Hilfsfunktionen

```r
read_spss_file <- function(path) {
  foreign::read.spss(
    file = path,
    to.data.frame = TRUE,
    use.value.labels = FALSE,
    use.missings = FALSE
  ) |>
    tibble::as_tibble()
}

find_single_file <- function(pattern) {
  files <- list.files(
    path = unzipped_dir,
    pattern = pattern,
    recursive = TRUE,
    full.names = TRUE
  )

  if (length(files) != 1) {
    stop("Datei nicht eindeutig gefunden für Pattern: ", pattern)
  }

  files
}

to_num <- function(x) {
  if (is.factor(x)) x <- as.character(x)
  suppressWarnings(as.numeric(x))
}

is_swiss <- function(x) {
  x %in% c(8100, 756)
}

fill_from_past <- function(data, varname, target_year) {
  # Sortierung ist notwendig, damit der letzte frühere Wert korrekt übernommen wird.
  data <- data[order(data$IDPERS, data$YEAR), ]
  split_data <- split(data, data$IDPERS)

  split_data <- lapply(split_data, function(df_person) {
    values <- df_person[[varname]]
```

```r
    last_seen <- NA
    filled <- values

    for (i in seq_along(values)) {
      if (!is.na(values[i])) {
        last_seen <- values[i]
      } else if (df_person$YEAR[i] == target_year && !is.na(last_seen)) {
        filled[i] <- last_seen
      }
    }

    df_person[[varname]] <- filled
    df_person
  })

  bind_rows(split_data) |>
    arrange(IDPERS, YEAR)
}
```

11 1. Datenaufbereitung

11.1 Skizze zum Zusammenführen der Daten

Die Zusammenführung erfolgt über Personen- und Haushaltskennungen. Das folgende Diagramm zeigt verwendete Tabellen, Join-Typen und Schlüsselvariablen:

```r
plot.new()
plot.window(xlim = c(0, 10), ylim = c(0, 10))

draw_box <- function(xleft, ybottom, xright, ytop, label, fill = "#E8F1F8") {
  rect(xleft, ybottom, xright, ytop, col = fill, border = "#2F5D7E", lwd = 2)
  text((xleft + xright) / 2, (ybottom + ytop) / 2, label, cex = 0.95)
}

draw_box(
  3.2, 7.7, 6.8, 9.1,
  "SHPLONG_P_USER\nBasis: idpers, idhous, year"
)
draw_box(
  0.4, 5.0, 3.4, 6.3,
  "SHPLONG_H_USER\nLEFT JOIN über\nidhous + year",
  fill = "#F6E8EA"
)
draw_box(
  3.5, 5.0, 6.5, 6.3,
  "SHP_MP\nLEFT JOIN über\nidpers",
  fill = "#EAF4E6"
)
draw_box(
  6.6, 5.0, 9.6, 6.3,
  "SHP_SO\nLEFT JOIN über\nidpers",
  fill = "#F8F1DD"
```

```r
)
draw_box(
  2.2, 2.0, 7.8, 3.6,
  "panel_final\nFilter auf relevante Jahre und Erwachsene\nKonstruktion der Zielvariablen\nSpeicherung i
  fill = "#EDE7F6"
)

arrows(5.0, 7.7, 1.9, 6.35, length = 0.1, lwd = 2, col = "#4D4D4D")
arrows(5.0, 7.7, 5.0, 6.35, length = 0.1, lwd = 2, col = "#4D4D4D")
arrows(5.0, 7.7, 8.1, 6.35, length = 0.1, lwd = 2, col = "#4D4D4D")
arrows(1.9, 5.0, 4.2, 3.65, length = 0.1, lwd = 2, col = "#4D4D4D")
arrows(5.0, 5.0, 5.0, 3.65, length = 0.1, lwd = 2, col = "#4D4D4D")
arrows(8.1, 5.0, 5.8, 3.65, length = 0.1, lwd = 2, col = "#4D4D4D")

text(5, 1.1, "Schematische Darstellung der Datenzusammenführung", cex = 0.95)
```

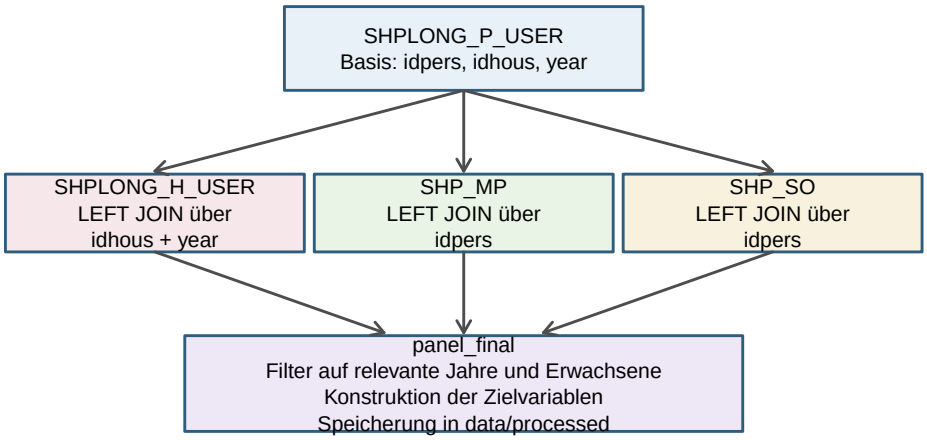

Schematische Darstellung der Datenzusammenführung

Ergänzend fasst die folgende textliche Skizze die gleiche Logik zusammen:

```
SHPLONG_P_USER
  Basisdatei auf Personen-Jahr-Ebene
  Schlüssel: idpers, idhous, year

  LEFT JOIN SHPLONG_H_USER
    Schlüssel: (idhous, year)
```

```
    Inhalt: Haushaltsmerkmale wie CANTON, IHTYN, NBPERS

  LEFT JOIN SHP_MP
    Schlüssel: idpers
    Inhalt: zeitinvariante Personenmerkmale wie BIRTHY, SEX

  LEFT JOIN SHP_SO
    Schlüssel: idpers
    Inhalt: retrospektive Angabe zu PO58

  Danach:
    Filter auf relevante Jahre
    Filter auf Erwachsene
    Konstruktion der Zielvariablen
    Speicherung als panel_final
```

11.2 1.1 Rohdaten entpacken

```r
if (!file.exists(zip_path)) {
  stop("ZIP-Datei nicht gefunden: ", zip_path)
}

unzip(zipfile = zip_path, exdir = unzipped_dir)
```

11.3 1.2 Benötigte SHP-Dateien laden

Für die Lösung werden vier Dateien benötigt:

- SHPLONG_P_USER.sav
- SHPLONG_H_USER.sav
- SHP_MP.sav
- SHP_SO.sav

```r
p_long_path <- find_single_file("^SHPLONG_P_USER\\.sav$")
h_long_path <- find_single_file("^SHPLONG_H_USER\\.sav$")
mp_path <- find_single_file("^SHP_MP\\.sav$")
so_path <- find_single_file("^SHP_SO\\.sav$")
```

```r
p_long_raw <- read_spss_file(p_long_path)
h_long_raw <- read_spss_file(h_long_path)
mp_raw <- read_spss_file(mp_path)
so_raw <- read_spss_file(so_path)
```

11.4 1.3 Relevante Variablen auswählen

```r
p_long <- p_long_raw |>
  select(
```

```r
    idpers, year, idhous,
    sex, civsta, ownkid, educat,
    nat_1_, nat_2_, nat_3_,
    pp04, pp10, pc19, pc19a
  )

h_long <- h_long_raw |>
  select(idhous, year, canton, ihtyn, nbpers)

mp <- mp_raw |>
  select(IDPERS, BIRTHY, SEX)

o58_candidates <- names(so_raw)[grepl("O58", names(so_raw), ignore.case = TRUE)]

if (length(o58_candidates) == 0) {
  stop("Keine O58-Variable in SHP_SO gefunden.")
}

so_var <- o58_candidates[[1]]

so <- so_raw |>
  select(IDPERS, all_of(so_var)) |>
  dplyr::rename(PO58 = all_of(so_var))
```

11.5 1.4 Verwendete Befragungsjahre

Es werden nur Jahre berücksichtigt, in denen `PP04` erhoben wurde. Die Auswahl basiert auf den SHP-Hinweisen zur Variablenverfügbarkeit und wird im Datensatz zusätzlich dadurch plausibilisiert, dass nur Wellen mit inhaltlich verwendbarer Zielvariable in die Analyse übernommen werden.

```r
years_use <- c(
  1999L, 2000L, 2001L, 2002L, 2003L, 2004L, 2005L, 2006L,
  2007L, 2008L, 2009L, 2011L, 2014L, 2017L, 2020L, 2023L
)

years_use
#>  [1] 1999 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009 2011 2014 2017 2020
#> [16] 2023
```

11.6 1.5 Daten bereinigen

```r
p_long_clean <- p_long |>
  mutate(
    idpers = to_num(idpers),
    year = to_num(year),
    idhous = to_num(idhous),
    sex = to_num(sex),
    civsta = to_num(civsta),
    ownkid = to_num(ownkid),
    educat = to_num(educat),
```

```r
    nat_1_ = to_num(nat_1_),
    nat_2_ = to_num(nat_2_),
    nat_3_ = to_num(nat_3_),
    pp04 = to_num(pp04),
    pp10 = to_num(pp10),
    pc19 = to_num(pc19),
    pc19a = to_num(pc19a)
  ) |>
  mutate(
    across(
      c(sex, civsta, ownkid, educat, nat_1_, nat_2_, nat_3_, pp04, pp10, pc19, pc19a),
      ~ if_else(. < 0, NA_real_, .)
    )
  ) |>
  filter(year %in% years_use)

h_long_clean <- h_long |>
  mutate(
    idhous = to_num(idhous),
    year = to_num(year),
    canton = to_num(canton),
    ihtyn = to_num(ihtyn),
    nbpers = to_num(nbpers)
  ) |>
  mutate(
    across(c(canton, ihtyn, nbpers), ~ if_else(. < 0, NA_real_, .))
  ) |>
  filter(year %in% years_use)

mp_clean <- mp |>
  mutate(
    IDPERS = to_num(IDPERS),
    BIRTHY = to_num(BIRTHY),
    SEX = to_num(SEX)
  ) |>
  mutate(
    across(c(BIRTHY, SEX), ~ if_else(. < 0, NA_real_, .))
  )

so_clean <- so |>
  mutate(
    IDPERS = to_num(IDPERS),
    PO58 = to_num(PO58)
  ) |>
  mutate(
    PO58 = if_else(PO58 < 0, NA_real_, PO58)
  )
```

11.7 1.6 Daten zusammenführen

```r
# Personen-Jahr-Daten werden um Haushalts-, Personenstamm- und Herkunftsangaben ergänzt.
panel_joined <- p_long_clean |>
```

```r
  left_join(h_long_clean, by = c("idhous", "year")) |>
  left_join(mp_clean, by = c("idpers" = "IDPERS")) |>
  left_join(so_clean, by = c("idpers" = "IDPERS"))
```

11.8 1.7 Erwachsene filtern

```r
panel_adults <- panel_joined |>
  mutate(
    YEAR = as.integer(year),
    IDPERS = as.integer(idpers),
    IDHOUS = as.integer(idhous),
    BIRTHY = as.integer(BIRTHY),
    AGE = YEAR - BIRTHY
  ) |>
  filter(!is.na(AGE), AGE >= 18)

dim(panel_adults)
#> [1] 162593     24
```

Es verbleiben 162'593 Beobachtungen auf Personen-Jahr-Ebene.

11.9 1.8 Zielvariablen konstruieren

```r
canton_map <- c(
  `1` = "AG", `2` = "AI", `3` = "AR", `4` = "BE", `5` = "BS", `6` = "BL",
  `7` = "FR", `8` = "GE", `9` = "GL", `10` = "GR", `11` = "JU", `12` = "LU",
  `13` = "NE", `14` = "NW", `15` = "OW", `16` = "SG", `17` = "SH", `18` = "SO",
  `19` = "SZ", `20` = "TG", `21` = "TI", `22` = "UR", `23` = "VD", `24` = "VS",
  `25` = "ZG", `26` = "ZH"
)

panel_adults <- panel_adults |>
  mutate(
    BIRTHYGEN = case_when(
      BIRTHY >= 1904 & BIRTHY < 1950 ~ "[1904,1950)",
      BIRTHY >= 1950 & BIRTHY < 1960 ~ "[1950,1960)",
      BIRTHY >= 1960 & BIRTHY < 1970 ~ "[1960,1970)",
      BIRTHY >= 1970 & BIRTHY < 1980 ~ "[1970,1980)",
      BIRTHY >= 1980 & BIRTHY < 1990 ~ "[1980,1990)",
      BIRTHY >= 1990 & BIRTHY < 2000 ~ "[1990,2000)",
      BIRTHY >= 2000 & BIRTHY < 2010 ~ "[2000,2010)",
      BIRTHY >= 2010 & BIRTHY <= YEAR ~ "[2010,2026]",
      TRUE ~ NA_character_
    ),
    SEX = case_when(
      SEX == 1 ~ "männlich",
      SEX == 2 ~ "weiblich",
      SEX == 3 ~ "andere",
      TRUE ~ NA_character_
```

```r
  ),
  CIVSTA = case_when(
    civsta == 1 ~ "ledig",
    civsta == 2 ~ "verheiratet",
    civsta == 3 ~ "getrennt",
    civsta == 4 ~ "geschieden",
    civsta == 5 ~ "verwitwet",
    civsta == 6 ~ "eingetragene Partnerschaft",
    civsta == 7 ~ "aufgelöste Partnerschaft",
    TRUE ~ NA_character_
  ),
  CANTON = recode(as.character(canton), !!!canton_map, .default = NA_character_),
  EDUCAT = case_when(
    educat == 0 ~ "Unvollständige obligatorische Schulbildung",
    educat == 1 ~ "Obligatorische Schule grundlegende berufliche Ausbildung",
    educat == 2 ~ "Hauswirtschaftskurs; einjährige Handelsschule",
    educat == 3 ~ "Allgemeine Ausbildungsschule",
    educat == 4 ~ "Lehre (EFZ)",
    educat == 5 ~ "Vollzeit-Berufsfachschule",
    educat == 6 ~ "Maturität / Bachelor",
    educat == 7 ~ "Berufshochschule mit Meisterdiplom, eidgenössisches Zertifikat",
    educat == 8 ~ "Technische oder berufliche Schule",
    educat == 9 ~ "Hochschule für Technik (ETS, HTL usw.)",
    educat == 10 ~ "Universität, akademische Mittelschule, PH, HEP, HES, FH",
    TRUE ~ NA_character_
  ),
  HASKID = case_when(
    ownkid == 0 ~ "nein",
    ownkid >= 1 ~ "ja",
    TRUE ~ NA_character_
  ),
  n_ch = as.integer(replace_na(is_swiss(nat_1_), FALSE)) +
    as.integer(replace_na(is_swiss(nat_2_), FALSE)) +
    as.integer(replace_na(is_swiss(nat_3_), FALSE)),
  n_nat = as.integer(!is.na(nat_1_)) +
    as.integer(!is.na(nat_2_)) +
    as.integer(!is.na(nat_3_)),
  NAT = case_when(
    n_ch >= 1 & n_nat == n_ch ~ "CH",
    n_ch >= 1 & n_nat > n_ch ~ "CH+Andere",
    n_ch == 0 & n_nat >= 1 ~ "Andere",
    TRUE ~ NA_character_
  ),
  pc19_raw = coalesce(pc19, pc19a),
  PC19 = case_when(
    pc19_raw == 1 ~ "ja",
    pc19_raw == 2 ~ "nein",
    TRUE ~ NA_character_
  ),
  PP04 = pp04,
  PP10 = pp10,
  NETHHINCPP = if_else(
    !is.na(ihtyn) & !is.na(nbpers) & nbpers > 0,
```

```r
      ihtyn / nbpers,
      NA_real_
    ),
    PO58 = case_when(
      PO58 == 1 ~ "ja",
      PO58 == 2 ~ "nein",
      TRUE ~ NA_character_
    )
  ) |>
  select(-n_ch, -n_nat, -pc19_raw)
```

11.10 1.9 Enddatensatz

```r
complete_vars <- c(
  "PP04", "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP", "PO58", "CIVSTA"
)
```

```r
panel_final <- panel_adults |>
  select(
    IDPERS, IDHOUS, YEAR, PP04,
    BIRTHY, BIRTHYGEN, SEX, CANTON, EDUCAT, HASKID, NAT,
    PC19, PP10, NETHHINCPP, PO58, CIVSTA
  )

# COMPLETE markiert Beobachtungen ohne fehlende Werte in den Analysevariablen.
panel_final$COMPLETE <- rowSums(is.na(panel_final[complete_vars])) == 0

panel_final <- panel_final |>
  select(
    IDPERS, IDHOUS, YEAR, PP04,
    BIRTHY, BIRTHYGEN, SEX, CANTON, EDUCAT, HASKID, NAT,
    PC19, PP10, NETHHINCPP, PO58, COMPLETE, CIVSTA
  )

glimpse(panel_final)
#> Rows: 162,593
#> Columns: 17
#> $ IDPERS     <int> 4101, 4102, 4101, 4102, 4102, 4101, 4102, 4101, 4101, 4102,~
#> $ IDHOUS     <int> 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41,~
#> $ YEAR       <int> 1999, 1999, 2000, 2000, 2001, 2001, 2002, 2002, 2003, 2003,~
#> $ PP04       <dbl> 4, 10, 5, 10, 8, 5, 8, 6, 6, 8, 8, 4, 7, NA, 7, 6, 7, 7, 7,~
#> $ BIRTHY     <int> 1965, 1968, 1965, 1968, 1968, 1965, 1968, 1965, 1965, 1968,~
#> $ BIRTHYGEN  <chr> "[1960,1970)", "[1960,1970)", "[1960,1970)", "[1960,1970)",~
#> $ SEX        <chr> "männlich", "weiblich", "männlich", "weiblich", "weiblich",~
#> $ CANTON     <chr> "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE",~
#> $ EDUCAT     <chr> "Technische oder berufliche Schule", "Obligatorische Schule~
#> $ HASKID     <chr> "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja",~
#> $ NAT        <chr> "CH", "CH+Andere", "CH", "CH", "CH", "CH", "CH", "CH", "CH"~
#> $ PC19       <chr> "nein", "ja", NA, NA, NA, NA, NA, NA, NA, NA, "ja", "nein",~
#> $ PP10       <dbl> 4, 5, 4, NA, 3, 7, 4, 4, 4, 5, 5, 6, 6, 4, 4, 4, 5, 4, 5, 4~
```

```
#> $ NETHHINCPP <dbl> 23140, 23140, 16940, 16940, 18140, 18140, 17480, 17480, 190~
#> $ PO58       <chr> "nein", "ja", "nein", "ja", "ja", "nein", "ja", "nein", "ne~
#> $ COMPLETE   <lgl> TRUE, TRUE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE~
#> $ CIVSTA     <chr> "verheiratet", "verheiratet", "verheiratet", "verheiratet",~
```

Der Enddatensatz enthält 17 Variablen und 162'593 Beobachtungen.

11.11 1.10 Beschrieb der aufbereiteten Daten

Der aufbereitete Datensatz liegt auf Personen-Jahr-Ebene vor. Jede Zeile beschreibt eine Person in einem bestimmten Befragungsjahr.

Die wichtigsten Eigenschaften des Datensatzes sind:

- Beobachtungseinheit: Person in einem Jahr
- Zeitabdeckung: 1999 bis 2023
- Anzahl Beobachtungen: 162'593
- Anzahl Personen: 39'307
- Anzahl Variablen: 17

```r
variable_description <- tibble::tribble(
  ~Variable, ~Beschreibung,
  "IDPERS", "Personen-ID",
  "IDHOUS", "Haushalts-ID",
  "YEAR", "Befragungsjahr",
  "PP04", "Vertrauen in den Bundesrat",
  "BIRTHY", "Geburtsjahr",
  "BIRTHYGEN", "Geburtskohorte",
  "SEX", "Geschlecht",
  "CANTON", "Wohnkanton",
  "EDUCAT", "Bildungskategorie",
  "HASKID", "Eigene Kinder: ja/nein",
  "NAT", "Nationalitätengruppe",
  "PC19", "Gesundheitliche Einschränkung",
  "PP10", "Links-Rechts-Selbsteinstufung",
  "NETHHINCPP", "Netto-Haushaltseinkommen pro Haushaltsmitglied",
  "PO58", "Soziale Herkunft",
  "COMPLETE", "Vollständiger Datensatz: TRUE/FALSE",
  "CIVSTA", "Zivilstand"
)

knitr::kable(variable_description)
```

Variable	Beschreibung
IDPERS	Personen-ID
IDHOUS	Haushalts-ID
YEAR	Befragungsjahr
PP04	Vertrauen in den Bundesrat
BIRTHY	Geburtsjahr
BIRTHYGEN	Geburtskohorte
SEX	Geschlecht

Variable	Beschreibung
CANTON	Wohnkanton
EDUCAT	Bildungskategorie
HASKID	Eigene Kinder: ja/nein
NAT	Nationalitätengruppe
PC19	Gesundheitliche Einschränkung
PP10	Links-Rechts-Selbsteinstufung
NETHHINCPP	Netto-Haushaltseinkommen pro Haushaltsmitglied
PO58	Soziale Herkunft
COMPLETE	Vollständiger Datensatz: TRUE/FALSE
CIVSTA	Zivilstand

11.12 1.11 Speicherung

```
write_csv(panel_final, file.path(processed_dir, "shp_panel_week2_longfiles.csv"))
saveRDS(panel_final, file.path(processed_dir, "shp_panel_week2_longfiles.rds"))
```

12 2. Datenqualität

12.1 2.1 Hilfsvariablen

```
panel_final <- panel_final |>
  mutate(
    AGE = YEAR - BIRTHY,
    AGEGROUP_CURRENT = case_when(
      AGE >= 18 & AGE < 30 ~ "18-29",
      AGE >= 30 & AGE < 45 ~ "30-44",
      AGE >= 45 & AGE < 60 ~ "45-59",
      AGE >= 60 & AGE < 75 ~ "60-74",
      AGE >= 75 ~ "75+",
      TRUE ~ NA_character_
    )
  )
```

12.2 2.2 Unvollständige Datensätze pro Jahr

```
missing_rows_by_year <- panel_final |>
  group_by(YEAR) |>
  summarise(
    n_total = n(),
    n_incomplete = sum(!COMPLETE, na.rm = TRUE),
    share_incomplete = n_incomplete / n_total,
    .groups = "drop"
  )

missing_rows_by_year
```

```
#> # A tibble: 16 x 4
#>     YEAR n_total n_incomplete share_incomplete
#>    <int>   <int>        <int>            <dbl>
#>  1  1999    9633         4621            0.480
#>  2  2000    8719         8366            0.960
#>  3  2001    8325         8200            0.985
#>  4  2002    7127         7055            0.990
#>  5  2003    6344         6281            0.990
#>  6  2004   10759         5466            0.508
#>  7  2005    8556         4064            0.475
#>  8  2006    8379         3741            0.446
#>  9  2007    8575         3709            0.433
#> 10  2008    8562         3698            0.432
#> 11  2009    8860         3741            0.422
#> 12  2011    8989         3689            0.410
#> 13  2014   14565         9618            0.660
#> 14  2017   11509         4495            0.391
#> 15  2020   20220        10308            0.510
#> 16  2023   13471         6010            0.446
```

Die Tabelle zeigt den Anteil von Personen-Jahr-Beobachtungen mit mindestens einem fehlenden Wert. Damit werden sowohl die absoluten Fallzahlen als auch die jährlichen Anteile der unvollständigen Beobachtungen sichtbar.

```r
missing_rows_by_year |>
  ggplot(aes(x = YEAR, y = share_incomplete)) +
  geom_col(fill = "#4C78A8") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = "Anteil unvollständiger Datensätze pro Jahr",
    x = "Jahr",
    y = "Anteil"
  )
```

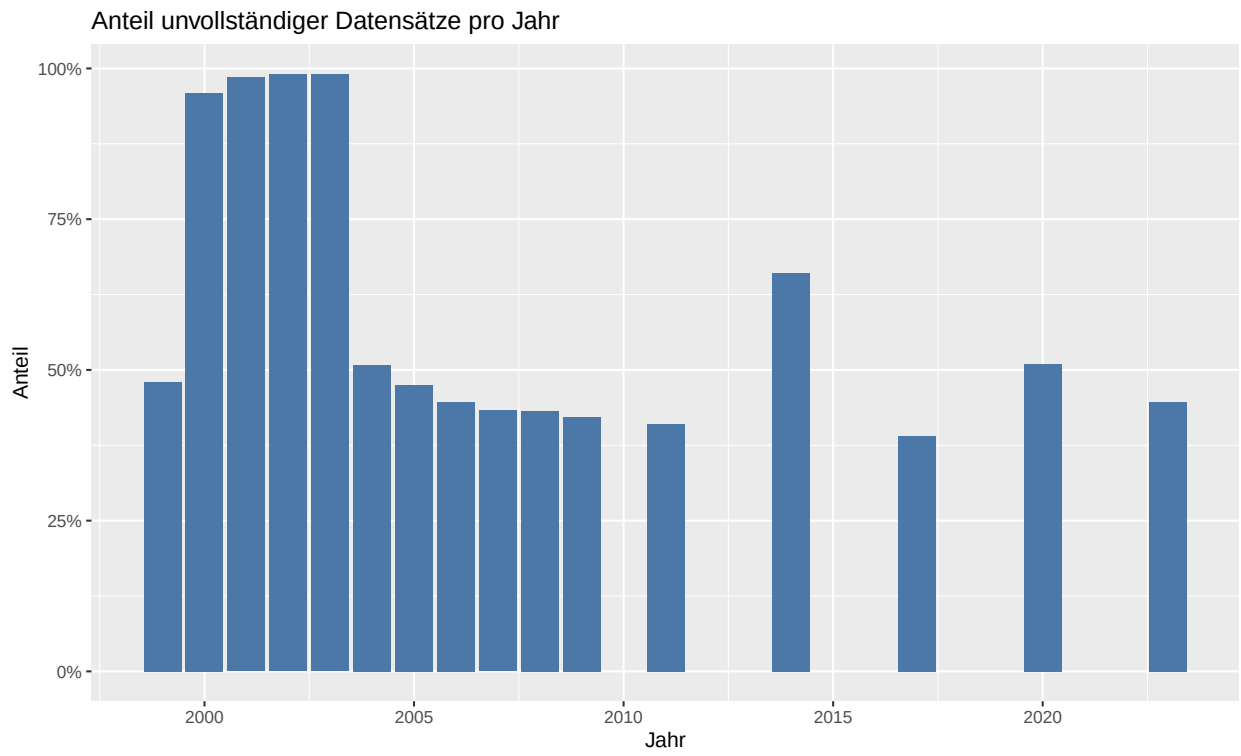

12.3 2.3 Missing Values pro Jahr und Variable

```
analysis_vars <- c(
  "PP04", "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP", "PO58",
  "CIVSTA"
)

missing_by_var_year <- panel_final |>
  mutate(across(all_of(analysis_vars), as.character)) |>
  pivot_longer(
    cols = all_of(analysis_vars),
    names_to = "variable",
    values_to = "value"
  ) |>
  group_by(YEAR, variable) |>
  summarise(
    n_total = n(),
    n_missing = sum(is.na(value)),
    share_missing = n_missing / n_total,
    .groups = "drop"
  ) |>
  arrange(desc(share_missing), YEAR, variable)

missing_by_var_year
#> # A tibble: 208 x 5
#>     YEAR variable n_total n_missing share_missing
```

```
#>    <int> <chr>      <int>     <int>         <dbl>
#>  1  2003 PC19        6344      6262         0.987
#>  2  2002 PC19        7127      7023         0.985
#>  3  2001 PC19        8325      8130         0.977
#>  4  2000 PC19        8719      8174         0.937
#>  5  2014 PP04       14565      7919         0.544
#>  6  2004 PP10       10759      4301         0.400
#>  7  2001 PP10        8325      3114         0.374
#>  8  2005 PP10        8556      3190         0.373
#>  9  2020 PP10       20220      7344         0.363
#> 10  1999 PP10        9633      3473         0.361
#> # i 198 more rows
```

Diese Übersicht macht sichtbar, in welchen Jahren einzelne Variablen besonders stark von Missing Values betroffen sind. Sie dient als Grundlage für die Auswahl der Variable, die im nächsten Schritt imputiert wird.

12.4 2.4 Auswahl der Imputationsvariable

```
missing_over_90 <- missing_by_var_year |>
  filter(share_missing > 0.9) |>
  arrange(desc(share_missing), YEAR, variable)

if (nrow(missing_over_90) > 0) {
  target_info <- missing_over_90 |>
    slice(1) |>
    mutate(selection_rule = "> 90% Missing")
} else {
  target_info <- missing_by_var_year |>
    slice(1) |>
    mutate(selection_rule = "höchster Missing-Anteil")
}

target_info
#> # A tibble: 1 x 6
#>    YEAR variable n_total n_missing share_missing selection_rule
#>   <int> <chr>      <int>     <int>         <dbl> <chr>
#> 1  2003 PC19        6344      6262         0.987 > 90% Missing
```

Die Imputation wird für PC19 im Jahr 2003 durchgeführt. Im vorliegenden Datensatz ist dies PC19 im Jahr 2003.

12.5 2.5 Imputation

```
# Imputiert wird ausschliesslich die ausgewählte Variable im ausgewählten Jahr.
panel_imputed <- fill_from_past(
  data = panel_final,
  varname = as.character(target_info$variable[[1]]),
  target_year = as.integer(target_info$YEAR[[1]])
)
```

```r
panel_imputed$COMPLETE <- rowSums(is.na(panel_imputed[complete_vars])) == 0
```

```r
missing_by_var_year_after <- panel_imputed |>
  mutate(across(all_of(analysis_vars), as.character)) |>
  pivot_longer(
    cols = all_of(analysis_vars),
    names_to = "variable",
    values_to = "value"
  ) |>
  group_by(YEAR, variable) |>
  summarise(
    n_total = n(),
    n_missing = sum(is.na(value)),
    share_missing = n_missing / n_total,
    .groups = "drop"
  )

comparison_missing <- missing_by_var_year |>
  dplyr::rename(
    n_missing_before = n_missing,
    share_missing_before = share_missing
  ) |>
  select(YEAR, variable, n_missing_before, share_missing_before) |>
  left_join(
    missing_by_var_year_after |>
      dplyr::rename(
        n_missing_after = n_missing,
        share_missing_after = share_missing
      ) |>
      select(YEAR, variable, n_missing_after, share_missing_after),
    by = c("YEAR", "variable")
  )

comparison_missing |>
  filter(variable == target_info$variable[[1]], YEAR == target_info$YEAR[[1]])
#> # A tibble: 1 x 6
#>    YEAR variable n_missing_before share_missing_before n_missing_after
#>   <int> <chr>               <int>                <dbl>           <int>
#> 1  2003 PC19                 6262                0.987            1189
#> # i 1 more variable: share_missing_after <dbl>
```

Die Imputation ersetzt fehlende Werte nicht generell, sondern nur für die ausgewählte Zielvariable im Zieljahr durch den jeweils letzten früheren verfügbaren Personenwert. Dadurch bleibt der Eingriff methodisch eng begrenzt und nachvollziehbar. Gleichzeitig entspricht dieses Vorgehen der Idee, fehlende Werte einer stark betroffenen Variable mit dem neuesten früheren Personenwert zu ersetzen.

13 3. Plausibilisierung

13.1 3.1 Vergleich vollständige vs. unvollständige Fälle

```
panel_all <- panel_imputed
panel_complete <- panel_imputed |>
  filter(COMPLETE)
```

```
sex_all <- panel_all |>
  filter(SEX %in% c("männlich", "weiblich")) |>
  count(SEX) |>
  mutate(dataset = "Alle Fälle", share = n / sum(n))

sex_complete <- panel_complete |>
  filter(SEX %in% c("männlich", "weiblich")) |>
  count(SEX) |>
  mutate(dataset = "Nur vollständige Fälle", share = n / sum(n))

bind_rows(sex_all, sex_complete)
#> # A tibble: 4 x 4
#>   SEX          n dataset                share
#>   <chr>    <int> <chr>                  <dbl>
#> 1 männlich 78220 Alle Fälle             0.481
#> 2 weiblich 84369 Alle Fälle             0.519
#> 3 männlich 34600 Nur vollständige Fälle 0.474
#> 4 weiblich 38442 Nur vollständige Fälle 0.526
```

```
age_all <- panel_all |>
  filter(!is.na(AGEGROUP_CURRENT)) |>
  count(AGEGROUP_CURRENT) |>
  mutate(dataset = "Alle Fälle", share = n / sum(n))

age_complete <- panel_complete |>
  filter(!is.na(AGEGROUP_CURRENT)) |>
  count(AGEGROUP_CURRENT) |>
  mutate(dataset = "Nur vollständige Fälle", share = n / sum(n))

bind_rows(age_all, age_complete)
#> # A tibble: 10 x 4
#>    AGEGROUP_CURRENT     n dataset                 share
#>    <chr>            <int> <chr>                   <dbl>
#>  1 18-29            29414 Alle Fälle             0.181
#>  2 30-44            41198 Alle Fälle             0.253
#>  3 45-59            47463 Alle Fälle             0.292
#>  4 60-74            32013 Alle Fälle             0.197
#>  5 75+              12505 Alle Fälle             0.0769
#>  6 18-29             8193 Nur vollständige Fälle 0.112
#>  7 30-44            18777 Nur vollständige Fälle 0.257
#>  8 45-59            23191 Nur vollständige Fälle 0.317
#>  9 60-74            16752 Nur vollständige Fälle 0.229
#> 10 75+               6130 Nur vollständige Fälle 0.0839
```

```r
canton_all <- panel_all |>
  filter(!is.na(CANTON)) |>
  count(CANTON) |>
  mutate(dataset = "Alle Fälle", share = n / sum(n))

canton_complete <- panel_complete |>
  filter(!is.na(CANTON)) |>
  count(CANTON) |>
  mutate(dataset = "Nur vollständige Fälle", share = n / sum(n))

bind_rows(canton_all, canton_complete)
#> # A tibble: 52 x 4
#>    CANTON     n dataset      share
#>    <chr>  <int> <chr>        <dbl>
#>  1 AG     13745 Alle Fälle 0.0845
#>  2 AI       238 Alle Fälle 0.00146
#>  3 AR      1302 Alle Fälle 0.00801
#>  4 BE     20217 Alle Fälle 0.124
#>  5 BL      5692 Alle Fälle 0.0350
#>  6 BS      3268 Alle Fälle 0.0201
#>  7 FR      6121 Alle Fälle 0.0376
#>  8 GE      7046 Alle Fälle 0.0433
#>  9 GL       880 Alle Fälle 0.00541
#> 10 GR      3512 Alle Fälle 0.0216
#> # i 42 more rows
```

13.2 3.2 BFS-Daten

Falls die BFS-Daten nicht geladen werden können, bleibt der Bericht trotzdem lauffähig.

```r
bfs_raw <- tryCatch(
  read.px(
    filename = "https://dam-api.bfs.admin.ch/hub/api/dam/assets/36021707/master",
    encoding = "utf-8"
  ),
  error = function(e) NULL
)

bfs_tbl <- if (is.null(bfs_raw)) NULL else tryCatch(as.data.frame(bfs_raw), error = function(e) NULL)
bfs_available <- !is.null(bfs_tbl)
bfs_year_ref <- 2023L

bfs_available
#> [1] TRUE
```

```r
bfs_canton_map <- c(
  "Zürich" = "ZH",
  "Bern / Berne" = "BE",
  "Luzern" = "LU",
  "Uri" = "UR",
  "Schwyz" = "SZ",
  "Obwalden" = "OW",
```

```r
  "Nidwalden" = "NW",
  "Glarus" = "GL",
  "Zug" = "ZG",
  "Fribourg / Freiburg" = "FR",
  "Solothurn" = "SO",
  "Basel-Stadt" = "BS",
  "Basel-Landschaft" = "BL",
  "Schaffhausen" = "SH",
  "Appenzell Ausserrhoden" = "AR",
  "Appenzell Innerrhoden" = "AI",
  "St. Gallen" = "SG",
  "Graubünden / Grigioni / Grischun" = "GR",
  "Aargau" = "AG",
  "Thurgau" = "TG",
  "Ticino" = "TI",
  "Vaud" = "VD",
  "Valais / Wallis" = "VS",
  "Neuchâtel" = "NE",
  "Genève" = "GE",
  "Jura" = "JU"
)

if (bfs_available) {
  bfs_sex <- bfs_tbl |>
    filter(
      as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
      as.character(Alter) == "Alter - Total",
      as.character(Zivilstand) == "Zivilstand - Total",
      as.character(Kanton) == "Schweiz",
      as.integer(as.character(Jahr)) == bfs_year_ref,
      as.character(Geschlecht) != "Geschlecht - Total"
    ) |>
    mutate(
      SEX = case_when(
        as.character(Geschlecht) == "Mann" ~ "männlich",
        as.character(Geschlecht) == "Frau" ~ "weiblich",
        TRUE ~ NA_character_
      )
    ) |>
    filter(!is.na(SEX)) |>
    group_by(SEX) |>
    summarise(n = sum(value, na.rm = TRUE), .groups = "drop") |>
    mutate(dataset = "BFS", share = n / sum(n))

  bfs_age <- bfs_tbl |>
    filter(
      as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
      as.character(Geschlecht) == "Geschlecht - Total",
      as.character(Zivilstand) == "Zivilstand - Total",
      as.character(Kanton) == "Schweiz",
      as.integer(as.character(Jahr)) == bfs_year_ref,
      as.character(Alter) != "Alter - Total"
    ) |>
```

```r
    mutate(age_num = readr::parse_number(as.character(Alter))) |>
    filter(!is.na(age_num), age_num >= 18) |>
    mutate(
      AGEGROUP_CURRENT = case_when(
        age_num >= 18 & age_num < 30 ~ "18-29",
        age_num >= 30 & age_num < 45 ~ "30-44",
        age_num >= 45 & age_num < 60 ~ "45-59",
        age_num >= 60 & age_num < 75 ~ "60-74",
        age_num >= 75 ~ "75+",
        TRUE ~ NA_character_
      )
    ) |>
    group_by(AGEGROUP_CURRENT) |>
    summarise(n = sum(value, na.rm = TRUE), .groups = "drop") |>
    mutate(dataset = "BFS", share = n / sum(n))

  bfs_canton <- bfs_tbl |>
    filter(
      as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
      as.character(Alter) == "Alter - Total",
      as.character(Geschlecht) == "Geschlecht - Total",
      as.character(Zivilstand) == "Zivilstand - Total",
      as.integer(as.character(Jahr)) == bfs_year_ref,
      as.character(Kanton) != "Schweiz"
    ) |>
    mutate(
      CANTON = recode(as.character(Kanton), !!!bfs_canton_map, .default = NA_character_)
    ) |>
    filter(!is.na(CANTON)) |>
    group_by(CANTON) |>
    summarise(n = sum(value, na.rm = TRUE), .groups = "drop") |>
    mutate(dataset = "BFS", share = n / sum(n))
} else {
  bfs_sex <- tibble(SEX = character(), n = numeric(), dataset = character(), share = numeric())
  bfs_age <- tibble(AGEGROUP_CURRENT = character(), n = numeric(), dataset = character(), share = numeri
  bfs_canton <- tibble(CANTON = character(), n = numeric(), dataset = character(), share = numeric())
}
```

```r
bind_rows(sex_all, sex_complete, bfs_sex) |>
  ggplot(aes(x = SEX, y = share, fill = dataset)) +
  geom_col(position = "dodge") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = paste0("Geschlechtsverteilung: SHP vs. BFS (", bfs_year_ref, ")"),
    x = "Geschlecht",
    y = "Anteil"
  )
```

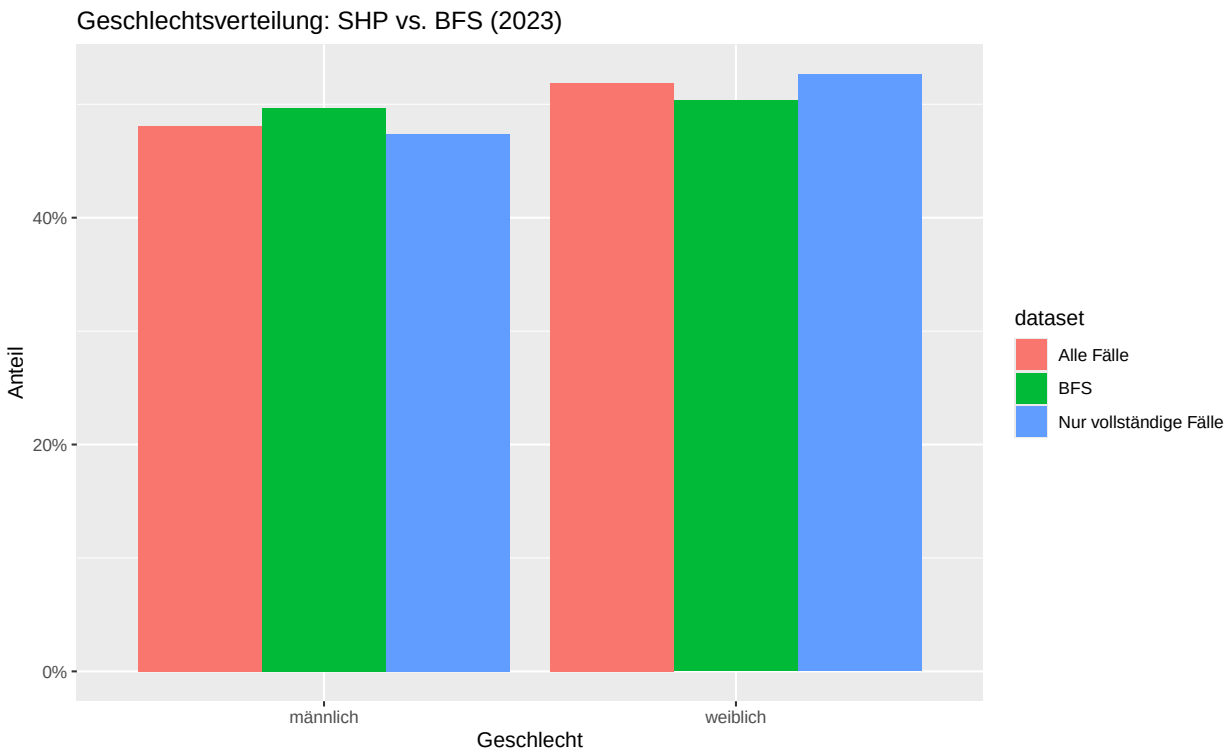


```r
bind_rows(age_all, age_complete, bfs_age) |>
  ggplot(aes(x = AGEGROUP_CURRENT, y = share, fill = dataset)) +
  geom_col(position = "dodge") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = paste0("Altersverteilung: SHP vs. BFS (", bfs_year_ref, ")"),
    x = "Altersgruppe",
    y = "Anteil"
  )
```

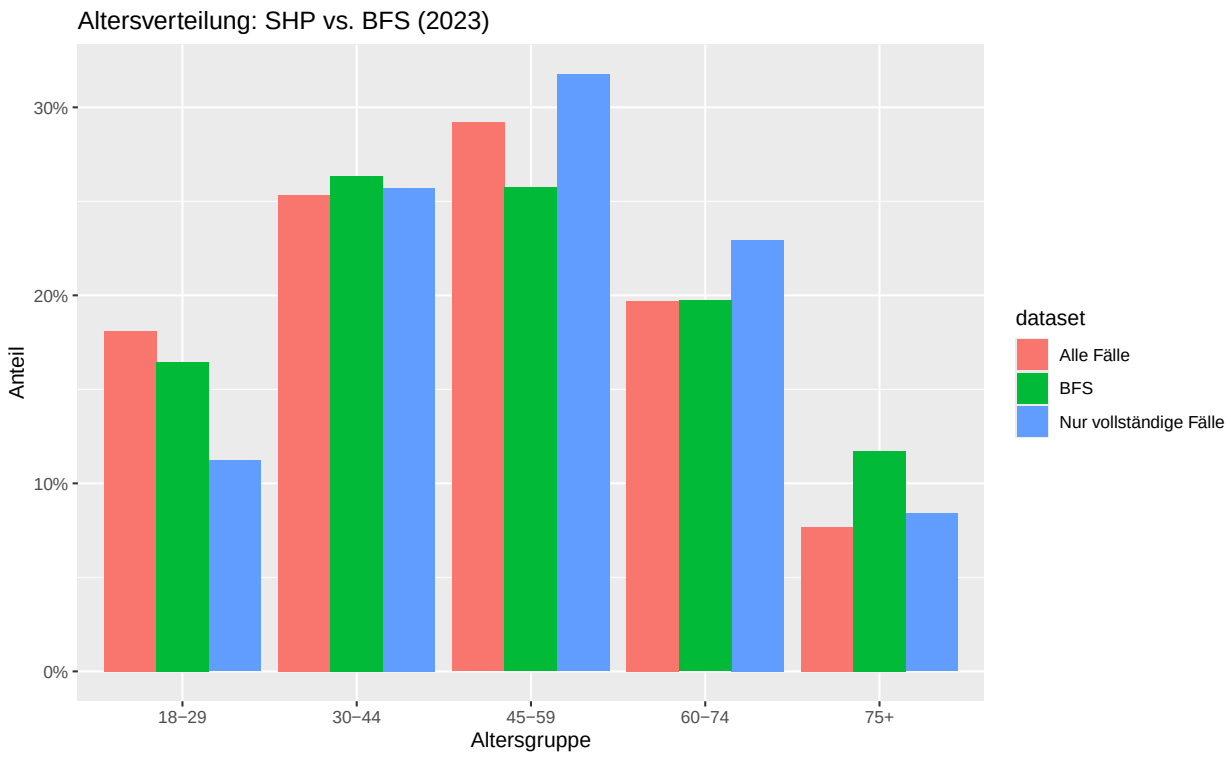


```r
bind_rows(canton_all, canton_complete, bfs_canton) |>
  ggplot(aes(x = reorder(CANTON, share), y = share, fill = dataset)) +
  geom_col(position = "dodge") +
  coord_flip() +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = paste0("Kantonsverteilung: SHP vs. BFS (", bfs_year_ref, ")"),
    x = "Kanton",
    y = "Anteil"
  )
```

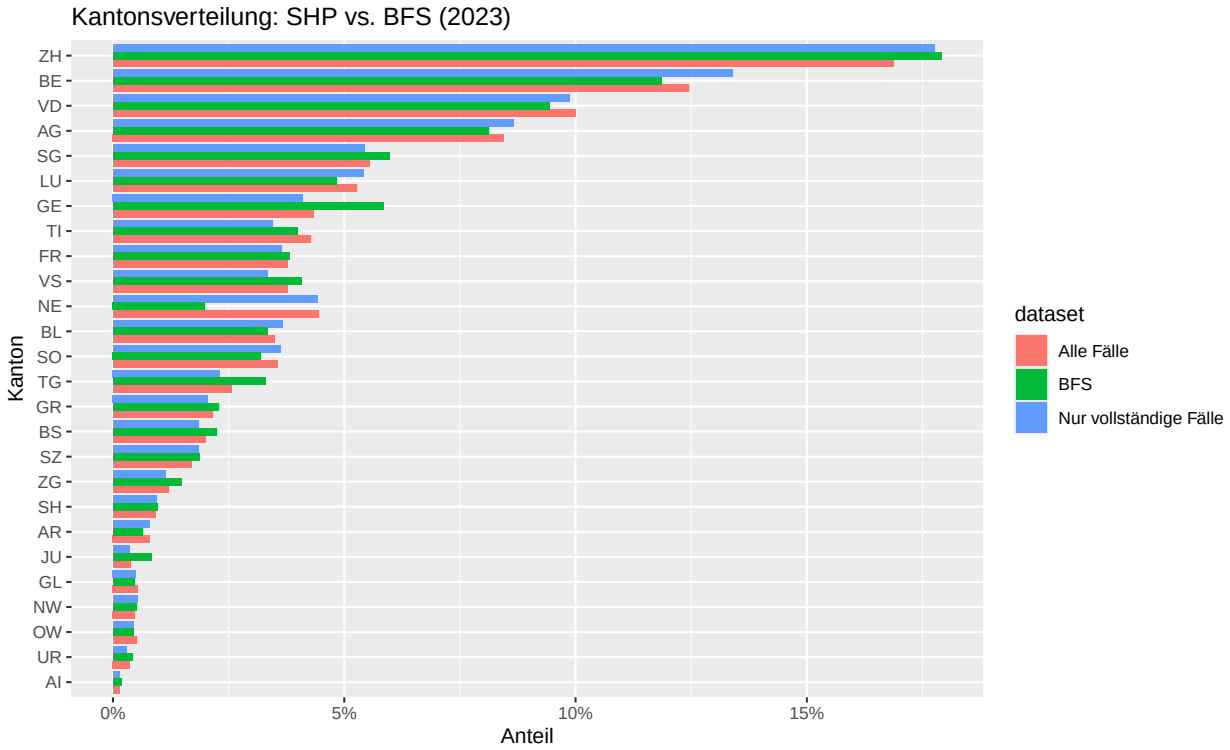

Die Plausibilisierung vergleicht die SHP-Verteilungen mit externen BFS-Referenzwerten für Geschlecht, Altersgruppen und Kantone. Zusätzlich wird geprüft, ob sich die Verteilungen nach dem Entfernen unvollständiger Fälle merklich verschieben. So lässt sich beurteilen, ob bestimmte Gruppen im Analysebestand systematisch unter- oder übervertreten sind.

14 4. Auswertung

14.1 4.1 Zeitliche Entwicklung von PP04

```
trust_over_time <- panel_imputed |>
  group_by(YEAR) |>
  summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    .groups = "drop"
  )

trust_over_time
#> # A tibble: 16 x 3
#>     YEAR mean_PP04 median_PP04
#>    <int>     <dbl>       <dbl>
#>  1  1999      5.74           6
#>  2  2000      5.93           6
#>  3  2001      5.92           6
#>  4  2002      5.62           6
#>  5  2003      5.44           6
#>  6  2004      5.28           5
```

```
#>  7  2005      5.39          5
#>  8  2006      5.50          6
#>  9  2007      5.51          6
#> 10  2008      5.67          6
#> 11  2009      5.39          5
#> 12  2011      5.77          6
#> 13  2014      5.98          6
#> 14  2017      6.31          7
#> 15  2020      6.76          7
#> 16  2023      6.36          7
```

```
trust_over_time |>
  ggplot(aes(x = YEAR, y = mean_PP04)) +
  geom_line(color = "#4C78A8") +
  geom_point(color = "#4C78A8") +
  labs(
    title = "Vertrauen in den Bundesrat über die Zeit",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

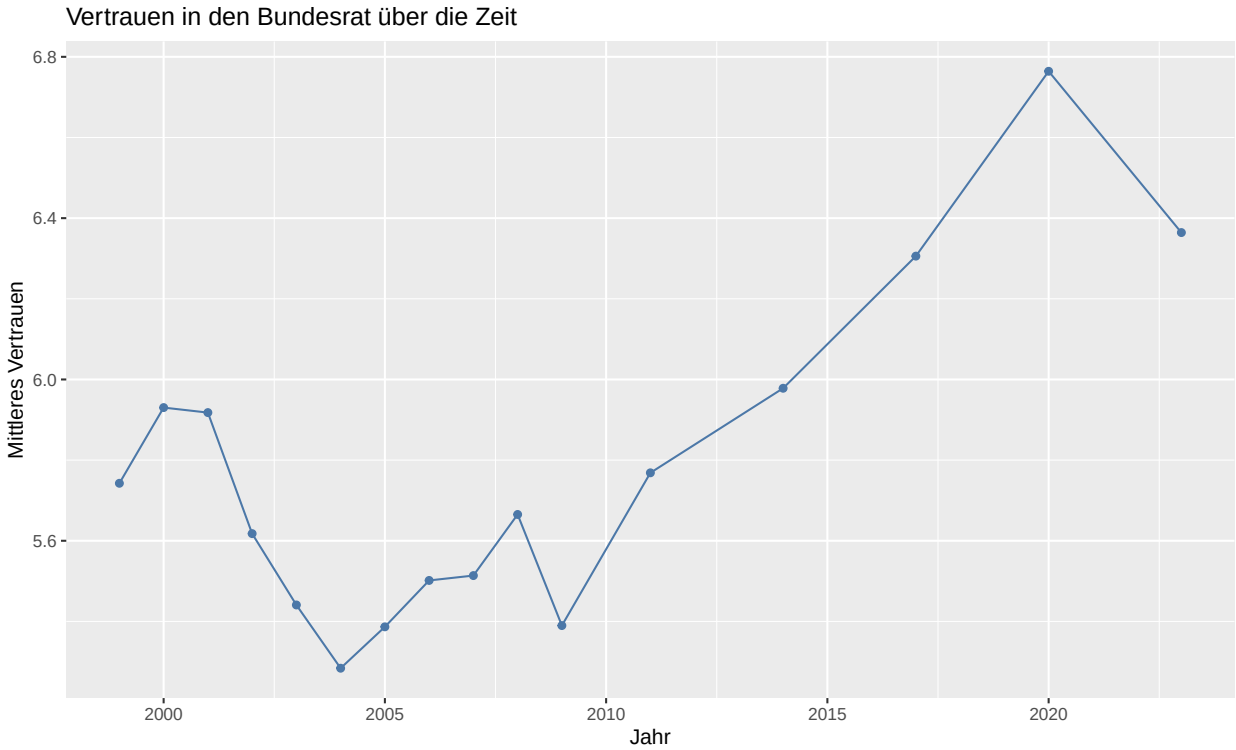

Die Zeitreihe liefert einen Überblick über die Entwicklung der Zielgrösse `PP04` seit 1999. Die anschliessenden Untergruppen-Grafiken vertiefen diese Entwicklung für mehrere potenzielle Einflussfaktoren.

14.2 4.2 Zusätzliche Untergruppen-Grafiken

```r
panel_imputed |>
  filter(!is.na(SEX)) |>
  group_by(YEAR, SEX) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = SEX)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Geschlecht",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

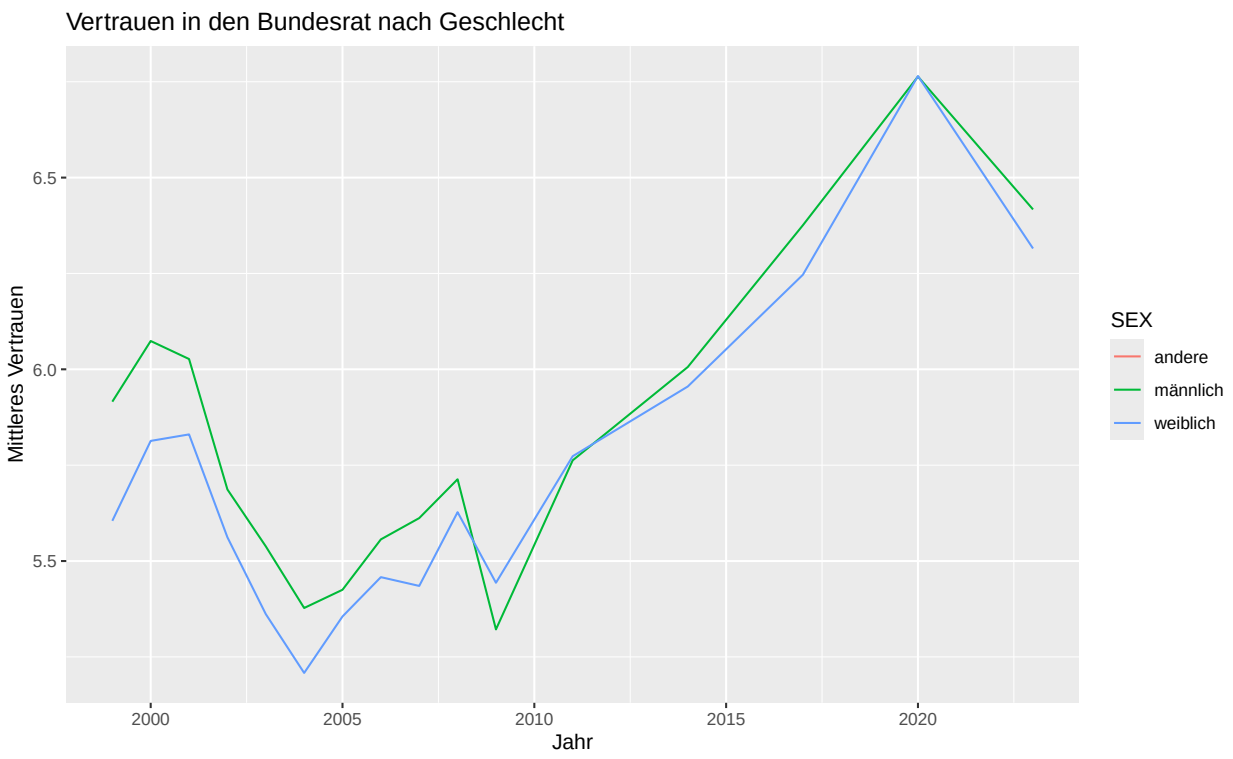


```r
panel_imputed |>
  filter(!is.na(BIRTHYGEN)) |>
  group_by(YEAR, BIRTHYGEN) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = BIRTHYGEN)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Geburtskohorte",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

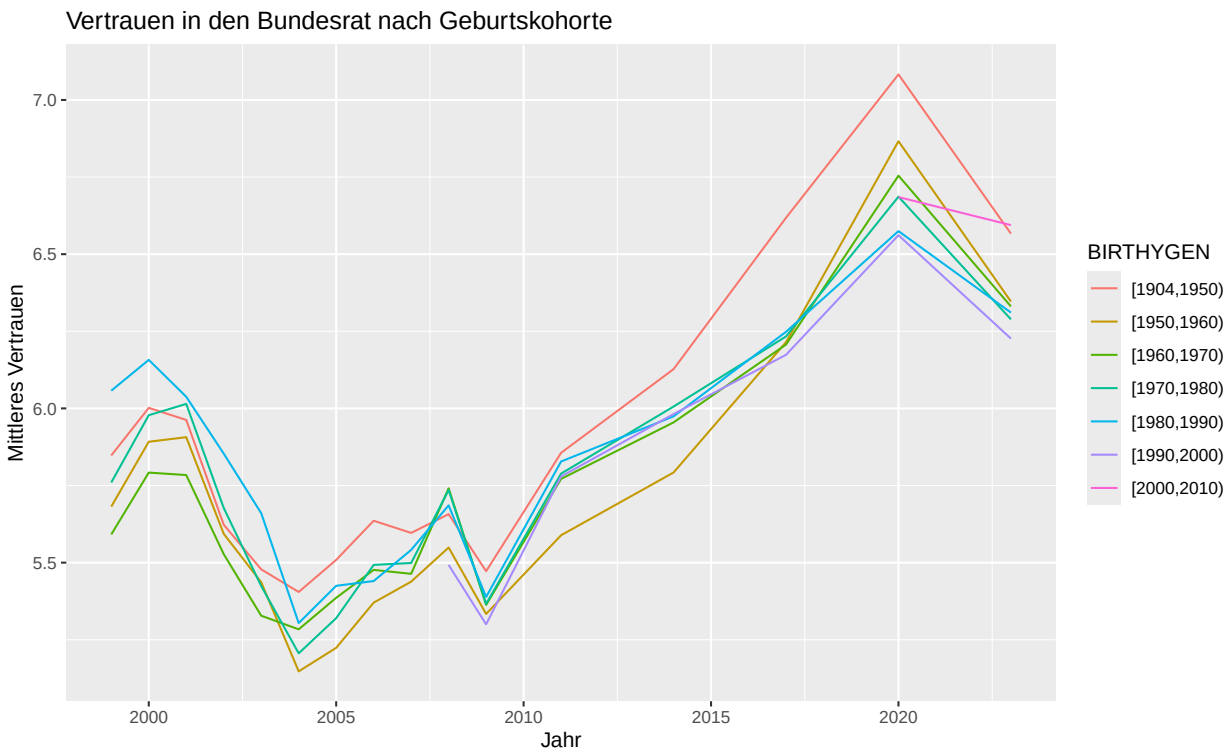


```r
panel_imputed |>
  filter(!is.na(NAT)) |>
  group_by(YEAR, NAT) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = NAT)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Nationalität",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

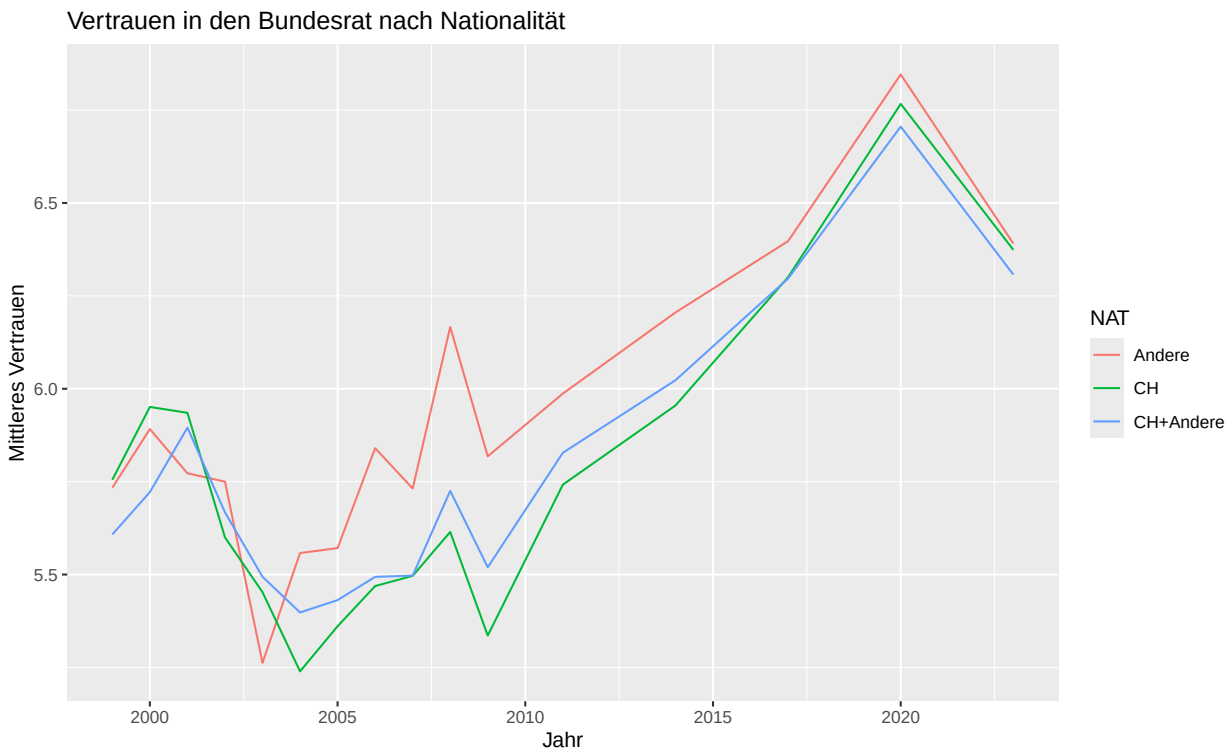


```
panel_imputed |>
  filter(!is.na(HASKID)) |>
  group_by(YEAR, HASKID) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = HASKID)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Kindern",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

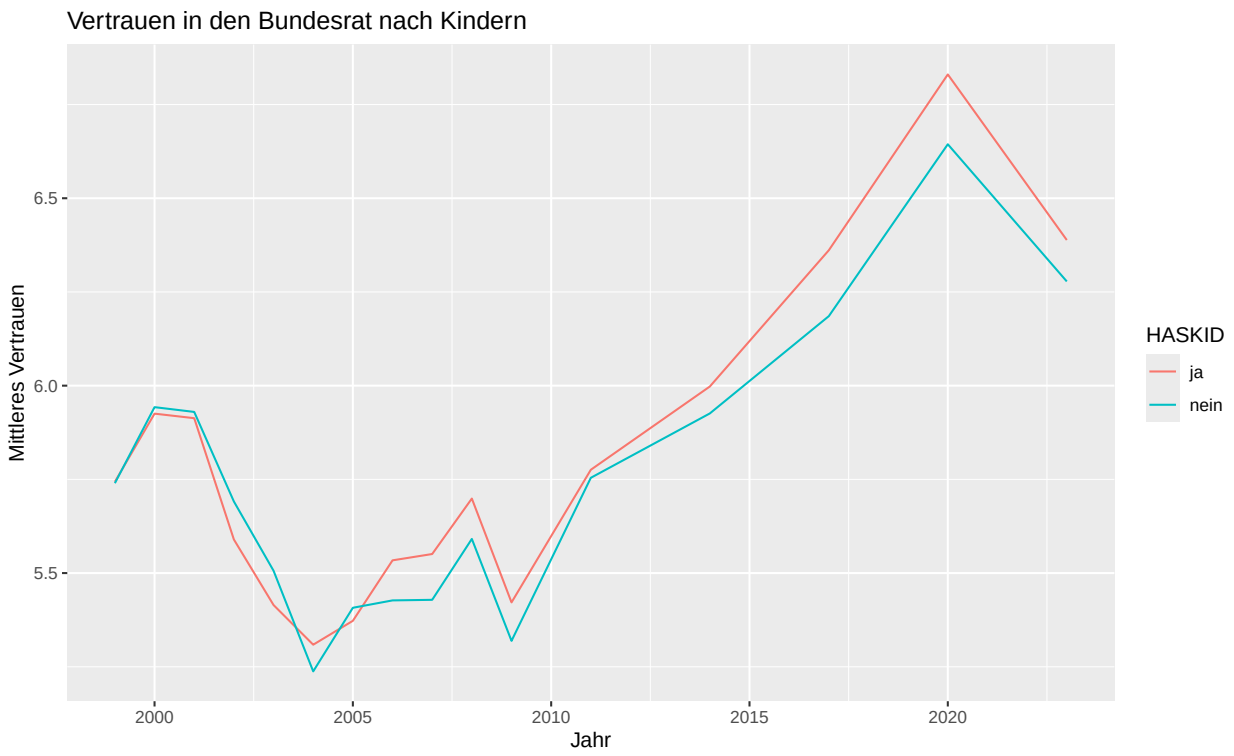


```
panel_imputed |>
  filter(!is.na(PC19)) |>
  group_by(YEAR, PC19) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = PC19)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach gesundheitlicher Einschränkung",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

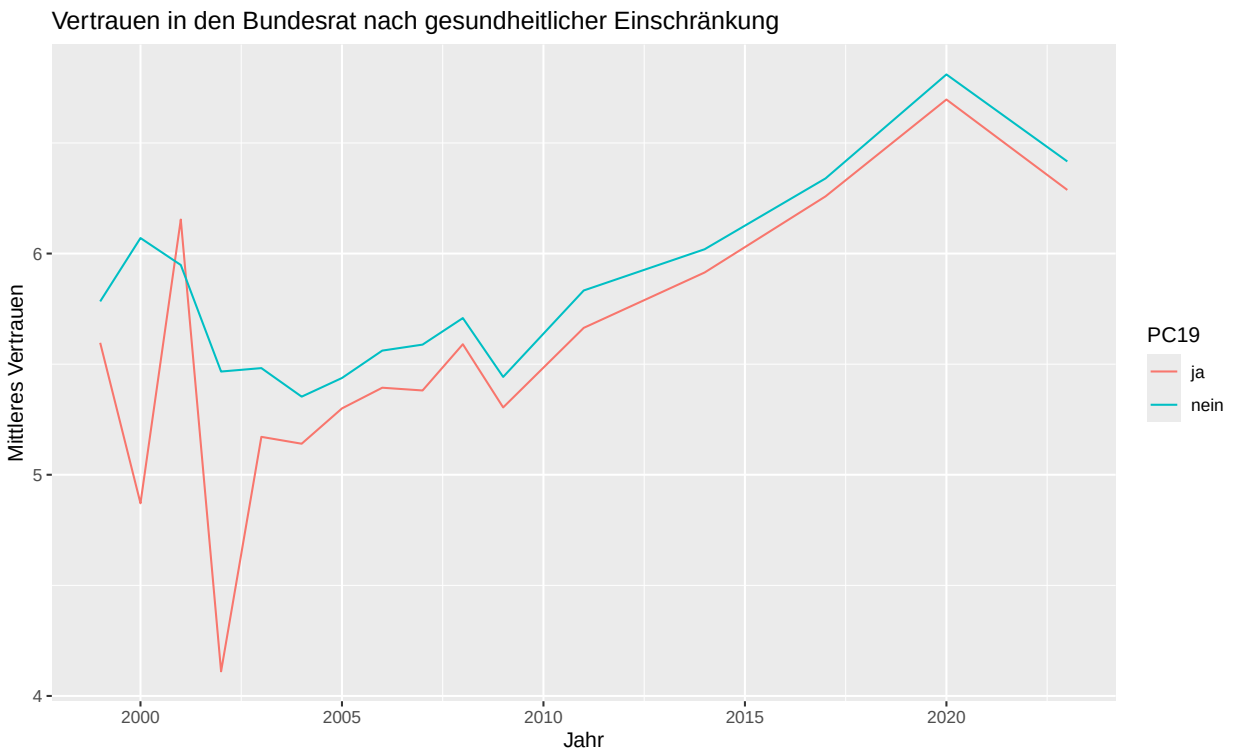


```
panel_imputed |>
  filter(!is.na(CIVSTA)) |>
  group_by(YEAR, CIVSTA) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = CIVSTA)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Zivilstand",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

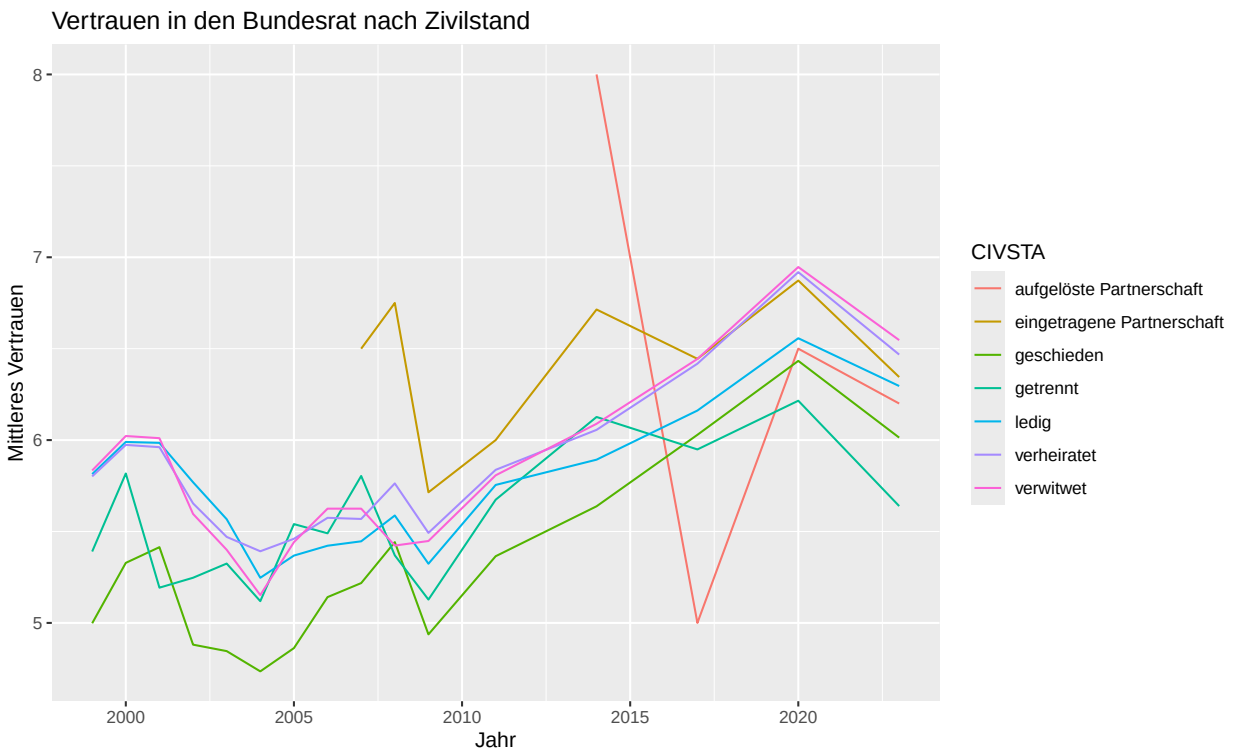

14.3 4.3 Hypothese zu CIVSTA

```
civsta_summary <- panel_imputed |>
  filter(!is.na(CIVSTA)) |>
  group_by(CIVSTA) |>
  summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    n = n(),
    .groups = "drop"
  ) |>
  arrange(desc(mean_PP04))

civsta_summary
#> # A tibble: 7 x 4
#>   CIVSTA                      mean_PP04 median_PP04     n
#>   <chr>                           <dbl>       <dbl> <int>
#> 1 eingetragene Partnerschaft       6.51           7   218
#> 2 aufgelöste Partnerschaft         6.36           6    11
#> 3 verheiratet                      5.96           6 95195
#> 4 verwitwet                        5.94           6  7384
#> 5 ledig                            5.86           6 45062
#> 6 getrennt                         5.61           6  2145
#> 7 geschieden                       5.49           6 12488
```

```r
civsta_summary |>
  ggplot(aes(x = reorder(CIVSTA, mean_PP04), y = mean_PP04)) +
  geom_col(fill = "#F58518") +
  coord_flip() +
  labs(
    title = "Mittleres Vertrauen in den Bundesrat nach Zivilstand",
    x = "Zivilstand",
    y = "Mittleres Vertrauen"
  )
```

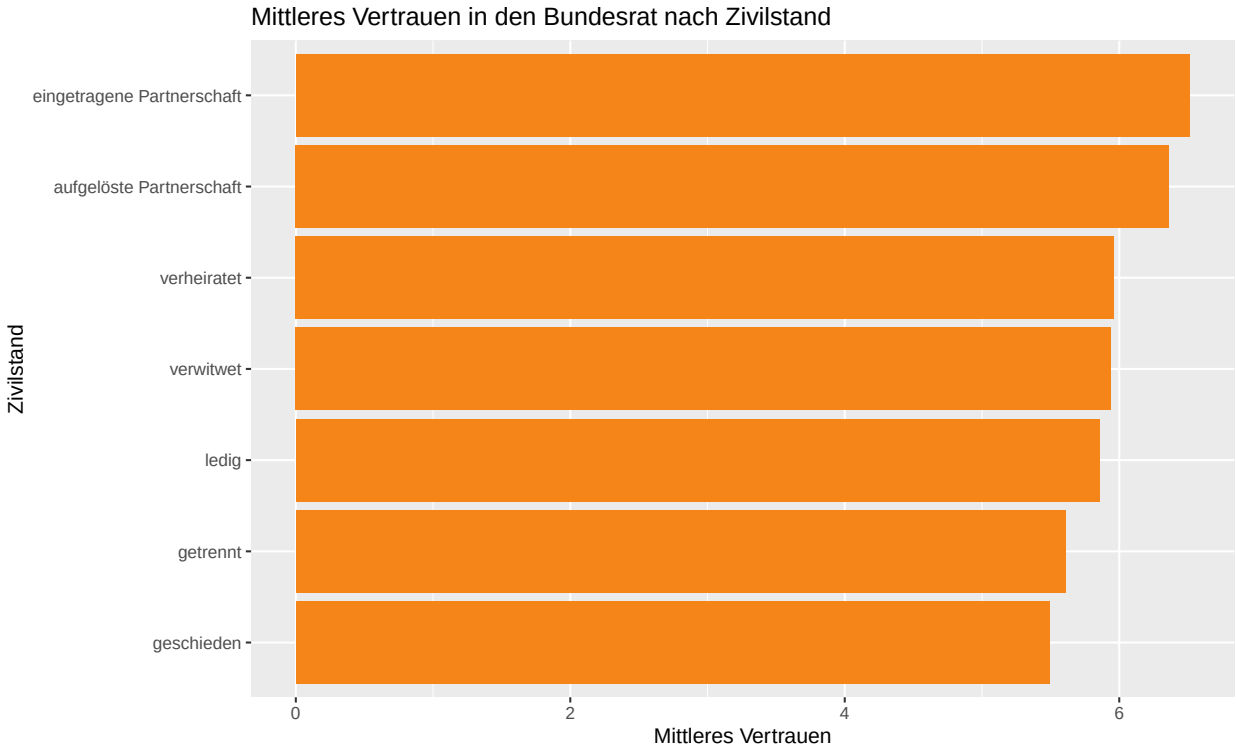

Die höchste mittlere Ausprägung von PP04 zeigt in dieser Auswertung die Kategorie eingetragene Partnerschaft.

```r
hypothesis_check <- panel_imputed |>
  filter(CIVSTA %in% c("verheiratet", "ledig", "getrennt", "geschieden")) |>
  mutate(
    hypothesis_group = if_else(CIVSTA == "verheiratet", "verheiratet", "Vergleichsgruppe")
  ) |>
  group_by(hypothesis_group) |>
  summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    n = n(),
    .groups = "drop"
  )

hypothesis_check
#> # A tibble: 2 x 4
#>   hypothesis_group mean_PP04 median_PP04     n
```

```
#>   <chr>                <dbl>       <dbl> <int>
#> 1 Vergleichsgruppe      5.76           6 59695
#> 2 verheiratet           5.96           6 95195
```

Die Hypothese wird anhand der gruppenspezifischen Mittelwerte geprüft. Verheiratete Personen erreichen im Mittel einen `PP04`-Wert von 5.96, während die zusammengefasste Vergleichsgruppe aus ledigen, getrennten und geschiedenen Personen einen Mittelwert von 5.76 aufweist.

Damit ist die formulierte Hypothese in den vorliegenden Daten deskriptiv **gestützt**. Die Differenz ist nicht sehr gross, aber in der erwarteten Richtung. Es wird keine kausale oder inferenzstatistische Prüfung vorgenommen; die Beurteilung bleibt daher bewusst deskriptiv.

15 5. Speicherung der Ergebnisse

```r
write_csv(panel_imputed, file.path(processed_dir, "shp_panel_week3_imputed.csv"))
saveRDS(panel_imputed, file.path(processed_dir, "shp_panel_week3_imputed.rds"))
```

16 6. Fazit

Der Datensatz wurde erfolgreich aufgebaut und enthält alle benötigten Variablen auf Personen-Jahr-Ebene. Anschliessend wurden die unvollständigen Fälle pro Jahr bestimmt, Missing Values systematisch ausgewertet, eine stark betroffene Variable mit früheren Personenwerten imputiert, die Plausibilität mit BFS-Verteilungen verglichen und die Entwicklung von `PP04` über mehrere Untergruppen hinweg untersucht.

Die Dokumentation umfasst Planung, Organisation, Datensicherheit, eigenen Einflussfaktor, Datenzusammenführung, Beschrieb der aufbereiteten Daten, Datenqualität, Plausibilisierung und Auswertung. Besonders wichtig für die Nachvollziehbarkeit ist, dass alle Schritte direkt aus der ZIP-Datei reproduzierbar sind und die erzeugten Datensätze automatisiert gespeichert werden.

Inhaltlich zeigt die Analyse, dass das Vertrauen in den Bundesrat über die Zeit variiert und sich zwischen Untergruppen unterscheidet. Für den zusätzlich gewählten Einflussfaktor `CIVSTA` ergibt sich ein deskriptiver Befund zugunsten der Hypothese: Verheiratete Personen weisen im Mittel ein höheres Vertrauen auf als ledige, getrennte und geschiedene Personen.

17 7. Schlusswort

Der Bericht bündelt alle Arbeitsschritte in einem einzigen reproduzierbaren R-Markdown-Dokument. Damit liegt eine technisch nachvollziehbare und inhaltlich geschlossene Darstellung der Datenaufbereitung und Auswertung vor.