# Praktikum 2 - Swiss Household Panel

Datenaufbereitung, Datenqualität, Plausibilisierung und Auswertung

Phineas Berdelis / Valentin Schwarz

2026-04-23

## Contents

**1 Zusammenfassung** **2**

**2 Einleitung** **2**

**3 Zielsetzung** **3**

**4 Planung und Organisation** **3**

**5 Datensicherheit** **3**

**6 Eigener Einflussfaktor** **4**

**7 Pakete** **4**

**8 Pfade** **4**

**9 Hilfsfunktionen** **4**

**10 1. Datenaufbereitung** **6**

10.1 Skizze zum Zusammenführen der Daten . . . . . 6

10.2 1.1 Rohdaten entpacken . . . . . 6

10.3 1.2 Benötigte SHP-Dateien laden . . . . . 6

10.4 1.3 Relevante Variablen auswählen . . . . . 7

10.5 1.4 Verwendete Befragungsjahre . . . . . 7

10.6 1.5 Daten bereinigen . . . . . 7

10.7 1.6 Daten zusammenführen . . . . . 9

10.8 1.7 Erwachsene filtern . . . . . 9

10.9 1.8 Zielvariablen konstruieren . . . . . 9

10.10 1.9 Enddatensatz . . . . . 11

10.11 1.10 Beschrieb der aufbereiteten Daten . . . . . 12

10.12 1.11 Speicherung . . . . . 13

**11 2. Datenqualität** **13**

11.1 2.1 Hilfsvariablen . . . . . 13

11.2 2.2 Unvollständige Datensätze pro Jahr . . . . . 13

11.3 2.3 Missing Values pro Jahr und Variable . . . . . 15

11.4 2.4 Auswahl der Imputationsvariable . . . . . 16

11.5 2.5 Imputation . . . . . 16

**12 3. Plausibilisierung** **17**

12.1 3.1 Vergleich vollständige vs. unvollständige Fälle . . . . . 17

12.2 3.2 BFS-Daten . . . . . 19

**13 4. Auswertung** **24**

13.1 4.1 Zeitliche Entwicklung von `PP04` . . . . . 24

13.2 4.2 Zusätzliche Untergruppen-Grafiken . . . . . 25

13.3 4.3 Hypothese zu `CIVSTA` . . . . . 31

**14 5. Speicherung der Ergebnisse** **32**

**15 6. Fazit** **32**

# 1 Zusammenfassung

In diesem Bericht wird Praktikum 2 als zusammenhängende R-Markdown-Dokumentation dargestellt. Ausgehend von den SHP-Rohdaten in der bereitgestellten ZIP-Datei wird ein Paneldatensatz auf Personen-Jahr-Ebene aufgebaut, bereinigt und für die Auswertung vorbereitet. Anschliessend werden die Datenqualität, die Missing-Struktur, die Plausibilität der Verteilungen und die Entwicklung des Vertrauens in den Bundesrat untersucht.

Als zusätzliche Einflussvariable wird der Zivilstand (`CIVSTA`) betrachtet. Die Ergebnisse werden in Tabellen und Grafiken zusammengeführt und am Ende als aufbereitete Datensätze für Woche 2 und Woche 3 gespeichert.

# 2 Einleitung

Dieses Dokument fasst die Bearbeitung von Praktikum 2 in einem einzigen R-Markdown-Bericht zusammen. Der Bericht deckt die Datenaufbereitung aus Woche 2 sowie die Missing-Analyse, Plausibilisierung und Auswertung aus Woche 3 ab.

Die Bearbeitung folgt derselben Logik wie in den Arbeitsdateien `Datenaufbereitung.Rmd` und `Datenqualitaet_Plausibilisierung_Auswertung.Rmd`, ist hier aber als vollständige Abgabe zusammengeführt.

# 3 Zielsetzung

Die Aufgabenstellung verlangt:

1. die Erstellung eines Paneldatensatzes auf Personen-Jahr-Ebene,
2. die Konstruktion der geforderten Zielvariablen,
3. die Analyse unvollständiger Fälle und Missing Values,
4. die Imputation einer stark betroffenen Variable mit früheren Personenwerten,
5. die Plausibilisierung mit BFS-Vergleichen,
6. die grafische Auswertung von `PP04`,
7. die Untersuchung einer zusätzlichen Einflussvariable.

Als zusätzliche Einflussvariable wird `CIVSTA` verwendet.

**Hypothese:** Verheiratete Personen weisen im Durchschnitt ein höheres Vertrauen in den Bundesrat auf als ledige, getrennte oder geschiedene Personen.

# 4 Planung und Organisation

Die Bearbeitung wurde in vier Arbeitsschritte gegliedert:

1. Sichtung der Aufgabenstellung und Identifikation der benötigten SHP-Dateien.
2. Aufbau des Datensatzes für Woche 2 mit allen geforderten Zielvariablen.
3. Analyse der Datenqualität, Plausibilisierung und Auswertung für Woche 3.
4. Zusammenführung aller Teilarbeiten in einem einzigen dokumentierten R-Markdown-Bericht.

Die Verantwortlichkeiten wurden innerhalb der Gruppe arbeitsteilig organisiert:

- Koordination und Abstimmung der Arbeitsschritte gemeinsam
- Programmierung der Datenaufbereitung und Auswertung arbeitsteilig
- Prüfung, Bereinigung und Dokumentation der Ergebnisse gemeinsam

Die Projektorganisation im Repository ist funktional getrennt:

- `data/raw` enthält die bereitgestellte ZIP-Datei.
- `data/processed` enthält die erzeugten Zwischen- und Enddatensätze.
- `src` enthält die R-Markdown-Dateien für Arbeits- und Abgabedokumente.
- `docs` bleibt für diese Abgabe unberücksichtigt, da es die Dokumentation für den Kommunikationsteil.

# 5 Datensicherheit

Die Rohdaten werden lokal aus der ZIP-Datei gelesen und im Projektverzeichnis verarbeitet. Es werden keine Originaldaten verändert; alle erzeugten Datensätze werden in `data/processed` separat abgelegt. Die Verarbeitung erfolgt reproduzierbar aus den Quell-Dateien, sodass der finale Datensatz jederzeit neu erstellt werden kann.

Für den Bericht werden nur die für die Aufgabenstellung benötigten Variablen ausgewählt. Die BFS-Daten werden ausschliesslich für den Plausibilitätsvergleich verwendet und nur dann geladen, wenn der Zugriff in der Laufumgebung möglich ist.

# 6 Eigener Einflussfaktor

Als eigener Einflussfaktor wird `CIVSTA` gewählt. Die Variable ist inhaltlich plausibel, da politische Einstellungen und institutionelles Vertrauen mit Lebenssituation, Haushaltstyp und sozialer Einbindung zusammenhängen können.

Die Wahl von `CIVSTA` ist zudem methodisch sinnvoll:

- die Variable ist bereits im SHP vorhanden,
- sie kann verständlich interpretiert werden,
- und sie erlaubt eine inhaltlich nachvollziehbare Hypothese.

Als fachliche Grundlage für das Verständnis der Datenstruktur dient insbesondere der SHP User Guide von Voorpostel et al. (2021).

# 7 Pakete

```r
library(tidyverse)
library(foreign)
library(pxR)
library(knitr)

# Explizite Bindungen verhindern Konflikte mit plyr beim Knit.
select <- dplyr::select
filter <- dplyr::filter
mutate <- dplyr::mutate
arrange <- dplyr::arrange
rename <- dplyr::rename
count <- dplyr::count
group_by <- dplyr::group_by
summarise <- dplyr::summarise
summarize <- dplyr::summarize
left_join <- dplyr::left_join
pivot_longer <- tidyr::pivot_longer
```

# 8 Pfade

```r
zip_path <- "../data/raw/Data_SPSS.zip"
unzipped_dir <- "../data/raw/data_unzipped"
processed_dir <- "../data/processed"

if (!dir.exists(unzipped_dir)) dir.create(unzipped_dir, recursive = TRUE)
if (!dir.exists(processed_dir)) dir.create(processed_dir, recursive = TRUE)
```

# 9 Hilfsfunktionen

```r
read_spss_file <- function(path) {
  foreign::read.spss(
    file = path,
    to.data.frame = TRUE,
    use.value.labels = FALSE,
    use.missings = FALSE
  ) |>
    tibble::as_tibble()
}

find_single_file <- function(pattern) {
  files <- list.files(
    path = unzipped_dir,
    pattern = pattern,
    recursive = TRUE,
    full.names = TRUE
  )

  if (length(files) != 1) {
    stop("Datei nicht eindeutig gefunden für Pattern: ", pattern)
  }

  files
}

to_num <- function(x) {
  if (is.factor(x)) x <- as.character(x)
  suppressWarnings(as.numeric(x))
}

is_swiss <- function(x) {
  x %in% c(8100, 756)
}

fill_from_past <- function(data, varname, target_year) {
  data <- data[order(data$IDPERS, data$YEAR), ]
  split_data <- split(data, data$IDPERS)

  split_data <- lapply(split_data, function(df_person) {
    values <- df_person[[varname]]
    last_seen <- NA
    filled <- values

    for (i in seq_along(values)) {
      if (!is.na(values[i])) {
        last_seen <- values[i]
      } else if (df_person$YEAR[i] == target_year && !is.na(last_seen)) {
        filled[i] <- last_seen
      }
    }

    df_person[[varname]] <- filled
    df_person
```

```
  })

  bind_rows(split_data) |>
    arrange(IDPERS, YEAR)
}
```

# 10 1. Datenaufbereitung

## 10.1 Skizze zum Zusammenführen der Daten

Die Zusammenführung erfolgt in vier Schritten:

```
SHPLONG_P_USER
  -> Auswahl der personen- und wellenspezifischen Variablen
  -> LEFT JOIN mit SHPLONG_H_USER über (idhous, year)
  -> LEFT JOIN mit SHP_MP über idpers
  -> LEFT JOIN mit SHP_SO über idpers
  -> Filter auf relevante Jahre und Erwachsene
  -> Konstruktion der Zielvariablen
  -> Speicherung als panel_final
```

## 10.2 1.1 Rohdaten entpacken

```
if (!file.exists(zip_path)) {
  stop("ZIP-Datei nicht gefunden: ", zip_path)
}

unzip(zipfile = zip_path, exdir = unzipped_dir)
```

## 10.3 1.2 Benötigte SHP-Dateien laden

Für die Lösung werden vier Dateien benötigt:

- SHPLONG_P_USER.sav
- SHPLONG_H_USER.sav
- SHP_MP.sav
- SHP_SO.sav

```
p_long_path <- find_single_file("^SHPLONG_P_USER\\.sav$")
h_long_path <- find_single_file("^SHPLONG_H_USER\\.sav$")
mp_path <- find_single_file("^SHP_MP\\.sav$")
so_path <- find_single_file("^SHP_SO\\.sav$")
```

```
p_long_raw <- read_spss_file(p_long_path)
h_long_raw <- read_spss_file(h_long_path)
mp_raw <- read_spss_file(mp_path)
so_raw <- read_spss_file(so_path)
```

## 10.4 1.3 Relevante Variablen auswählen

```
p_long <- p_long_raw |>
  select(
    idpers, year, idhous,
    sex, civsta, ownkid, educat,
    nat_1_, nat_2_, nat_3_,
    pp04, pp10, pc19, pc19a
  )

h_long <- h_long_raw |>
  select(idhous, year, canton, ihtyn, nbpers)

mp <- mp_raw |>
  select(IDPERS, BIRTHY, SEX)

o58_candidates <- names(so_raw)[grepl("O58", names(so_raw), ignore.case = TRUE)]

if (length(o58_candidates) == 0) {
  stop("Keine O58-Variable in SHP_SO gefunden.")
}

so_var <- o58_candidates[[1]]

so <- so_raw |>
  select(IDPERS, all_of(so_var)) |>
  dplyr::rename(PO58 = all_of(so_var))
```

## 10.5 1.4 Verwendete Befragungsjahre

Es werden nur Jahre berücksichtigt, in denen `PP04` erhoben wurde.

```
years_use <- c(
  1999L, 2000L, 2001L, 2002L, 2003L, 2004L, 2005L, 2006L,
  2007L, 2008L, 2009L, 2011L, 2014L, 2017L, 2020L, 2023L
)

years_use
```

```
##  [1] 1999 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009 2011 2014 2017 2020
## [16] 2023
```

## 10.6 1.5 Daten bereinigen

```
p_long_clean <- p_long |>
  mutate(
    idpers = to_num(idpers),
    year = to_num(year),
    idhous = to_num(idhous),
```

```r
    sex = to_num(sex),
    civsta = to_num(civsta),
    ownkid = to_num(ownkid),
    educat = to_num(educat),
    nat_1_ = to_num(nat_1_),
    nat_2_ = to_num(nat_2_),
    nat_3_ = to_num(nat_3_),
    pp04 = to_num(pp04),
    pp10 = to_num(pp10),
    pc19 = to_num(pc19),
    pc19a = to_num(pc19a)
  ) |>
  mutate(
    across(
      c(sex, civsta, ownkid, educat, nat_1_, nat_2_, nat_3_, pp04, pp10, pc19, pc19a),
      ~ if_else(. < 0, NA_real_, .)
    )
  ) |>
  filter(year %in% years_use)

h_long_clean <- h_long |>
  mutate(
    idhous = to_num(idhous),
    year = to_num(year),
    canton = to_num(canton),
    ihtyn = to_num(ihtyn),
    nbpers = to_num(nbpers)
  ) |>
  mutate(
    across(c(canton, ihtyn, nbpers), ~ if_else(. < 0, NA_real_, .))
  ) |>
  filter(year %in% years_use)

mp_clean <- mp |>
  mutate(
    IDPERS = to_num(IDPERS),
    BIRTHY = to_num(BIRTHY),
    SEX = to_num(SEX)
  ) |>
  mutate(
    across(c(BIRTHY, SEX), ~ if_else(. < 0, NA_real_, .))
  )

so_clean <- so |>
  mutate(
    IDPERS = to_num(IDPERS),
    PO58 = to_num(PO58)
  ) |>
  mutate(
    PO58 = if_else(PO58 < 0, NA_real_, PO58)
  )
```

## 10.7 1.6 Daten zusammenführen

```
panel_joined <- p_long_clean |>
  left_join(h_long_clean, by = c("idhous", "year")) |>
  left_join(mp_clean, by = c("idpers" = "IDPERS")) |>
  left_join(so_clean, by = c("idpers" = "IDPERS"))
```

## 10.8 1.7 Erwachsene filtern

```
panel_adults <- panel_joined |>
  mutate(
    YEAR = as.integer(year),
    IDPERS = as.integer(idpers),
    IDHOUS = as.integer(idhous),
    BIRTHY = as.integer(BIRTHY),
    AGE = YEAR - BIRTHY
  ) |>
  filter(!is.na(AGE), AGE >= 18)

dim(panel_adults)
```

```
## [1] 162593     24
```

Es verbleiben 162'593 Beobachtungen auf Personen-Jahr-Ebene.

## 10.9 1.8 Zielvariablen konstruieren

```
canton_map <- c(
  `1` = "AG", `2` = "AI", `3` = "AR", `4` = "BE", `5` = "BS", `6` = "BL",
  `7` = "FR", `8` = "GE", `9` = "GL", `10` = "GR", `11` = "JU", `12` = "LU",
  `13` = "NE", `14` = "NW", `15` = "OW", `16` = "SG", `17` = "SH", `18` = "SO",
  `19` = "SZ", `20` = "TG", `21` = "TI", `22` = "UR", `23` = "VD", `24` = "VS",
  `25` = "ZG", `26` = "ZH"
)

panel_adults <- panel_adults |>
  mutate(
    BIRTHYGEN = case_when(
      BIRTHY >= 1904 & BIRTHY < 1950 ~ "[1904,1950)",
      BIRTHY >= 1950 & BIRTHY < 1960 ~ "[1950,1960)",
      BIRTHY >= 1960 & BIRTHY < 1970 ~ "[1960,1970)",
      BIRTHY >= 1970 & BIRTHY < 1980 ~ "[1970,1980)",
      BIRTHY >= 1980 & BIRTHY < 1990 ~ "[1980,1990)",
      BIRTHY >= 1990 & BIRTHY < 2000 ~ "[1990,2000)",
      BIRTHY >= 2000 & BIRTHY < 2010 ~ "[2000,2010)",
      BIRTHY >= 2010 & BIRTHY <= YEAR ~ "[2010,2026]",
      TRUE ~ NA_character_
    ),
```

```r
  SEX = case_when(
    SEX == 1 ~ "männlich",
    SEX == 2 ~ "weiblich",
    SEX == 3 ~ "andere",
    TRUE ~ NA_character_
  ),
  CIVSTA = case_when(
    civsta == 1 ~ "ledig",
    civsta == 2 ~ "verheiratet",
    civsta == 3 ~ "getrennt",
    civsta == 4 ~ "geschieden",
    civsta == 5 ~ "verwitwet",
    civsta == 6 ~ "eingetragene Partnerschaft",
    civsta == 7 ~ "aufgelöste Partnerschaft",
    TRUE ~ NA_character_
  ),
  CANTON = recode(as.character(canton), !!!canton_map, .default = NA_character_),
  EDUCAT = case_when(
    educat == 0 ~ "Unvollständige obligatorische Schulbildung",
    educat == 1 ~ "Obligatorische Schule grundlegende berufliche Ausbildung",
    educat == 2 ~ "Hauswirtschaftskurs; einjährige Handelsschule",
    educat == 3 ~ "Allgemeine Ausbildungsschule",
    educat == 4 ~ "Lehre (EFZ)",
    educat == 5 ~ "Vollzeit-Berufsfachschule",
    educat == 6 ~ "Maturität / Bachelor",
    educat == 7 ~ "Berufshochschule mit Meisterdiplom, eidgenössisches Zertifikat",
    educat == 8 ~ "Technische oder berufliche Schule",
    educat == 9 ~ "Hochschule für Technik (ETS, HTL usw.)",
    educat == 10 ~ "Universität, akademische Mittelschule, PH, HEP, HES, FH",
    TRUE ~ NA_character_
  ),
  HASKID = case_when(
    ownkid == 0 ~ "nein",
    ownkid >= 1 ~ "ja",
    TRUE ~ NA_character_
  ),
  n_ch = as.integer(replace_na(is_swiss(nat_1_), FALSE)) +
    as.integer(replace_na(is_swiss(nat_2_), FALSE)) +
    as.integer(replace_na(is_swiss(nat_3_), FALSE)),
  n_nat = as.integer(!is.na(nat_1_)) +
    as.integer(!is.na(nat_2_)) +
    as.integer(!is.na(nat_3_)),
  NAT = case_when(
    n_ch >= 1 & n_nat == n_ch ~ "CH",
    n_ch >= 1 & n_nat > n_ch ~ "CH+Andere",
    n_ch == 0 & n_nat >= 1 ~ "Andere",
    TRUE ~ NA_character_
  ),
  pc19_raw = coalesce(pc19, pc19a),
  PC19 = case_when(
    pc19_raw == 1 ~ "ja",
    pc19_raw == 2 ~ "nein",
    TRUE ~ NA_character_
```

```r
    ),
    PP04 = pp04,
    PP10 = pp10,
    NETHHINCPP = if_else(
      !is.na(ihtyn) & !is.na(nbpers) & nbpers > 0,
      ihtyn / nbpers,
      NA_real_
    ),
    PO58 = case_when(
      PO58 == 1 ~ "ja",
      PO58 == 2 ~ "nein",
      TRUE ~ NA_character_
    )
  ) |>
  select(-n_ch, -n_nat, -pc19_raw)
```

## 10.10 1.9 Enddatensatz

```r
complete_vars <- c(
  "PP04", "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP", "PO58", "CIVSTA"
)
```

```r
panel_final <- panel_adults |>
  select(
    IDPERS, IDHOUS, YEAR, PP04,
    BIRTHY, BIRTHYGEN, SEX, CANTON, EDUCAT, HASKID, NAT,
    PC19, PP10, NETHHINCPP, PO58, CIVSTA
  )

panel_final$COMPLETE <- rowSums(is.na(panel_final[complete_vars])) == 0

panel_final <- panel_final |>
  select(
    IDPERS, IDHOUS, YEAR, PP04,
    BIRTHY, BIRTHYGEN, SEX, CANTON, EDUCAT, HASKID, NAT,
    PC19, PP10, NETHHINCPP, PO58, COMPLETE, CIVSTA
  )

glimpse(panel_final)
```

```
## Rows: 162,593
## Columns: 17
## $ IDPERS     <int> 4101, 4102, 4101, 4102, 4102, 4101, 4102, 4101, 4101, 4102,~
## $ IDHOUS     <int> 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41, 41,~
## $ YEAR       <int> 1999, 1999, 2000, 2000, 2001, 2001, 2002, 2002, 2003, 2003,~
## $ PP04       <dbl> 4, 10, 5, 10, 8, 5, 8, 6, 6, 8, 8, 4, 7, NA, 7, 6, 7, 7, 7,~
## $ BIRTHY     <int> 1965, 1968, 1965, 1968, 1968, 1965, 1968, 1965, 1965, 1968,~
## $ BIRTHYGEN  <chr> "[1960,1970)", "[1960,1970)", "[1960,1970)", "[1960,1970)",~
## $ SEX        <chr> "männlich", "weiblich", "männlich", "weiblich", "weiblich",~
## $ CANTON     <chr> "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE", "GE",~
```

```
## $ EDUCAT     <chr> "Technische oder berufliche Schule", "Obligatorische Schule~
## $ HASKID     <chr> "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja", "ja",~
## $ NAT        <chr> "CH", "CH+Andere", "CH", "CH", "CH", "CH", "CH", "CH", "CH"~
## $ PC19       <chr> "nein", "ja", NA, NA, NA, NA, NA, NA, NA, NA, "ja", "nein",~
## $ PP10       <dbl> 4, 5, 4, NA, 3, 7, 4, 4, 4, 5, 5, 6, 6, 4, 4, 4, 5, 4, 5, 4~
## $ NETHHINCPP <dbl> 23140, 23140, 16940, 16940, 18140, 18140, 17480, 17480, 190~
## $ PO58       <chr> "nein", "ja", "nein", "ja", "ja", "nein", "ja", "nein", "ne~
## $ COMPLETE   <lgl> TRUE, TRUE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE~
## $ CIVSTA     <chr> "verheiratet", "verheiratet", "verheiratet", "verheiratet",~
```

Der Enddatensatz enthält 17 Variablen und 162'593 Beobachtungen.

## 10.11 1.10 Beschrieb der aufbereiteten Daten

Der aufbereitete Datensatz liegt auf Personen-Jahr-Ebene vor. Jede Zeile beschreibt eine Person in einem bestimmten Befragungsjahr.

Die wichtigsten Eigenschaften des Datensatzes sind:

- Beobachtungseinheit: Person in einem Jahr
- Zeitabdeckung: 1999 bis 2023
- Anzahl Beobachtungen: 162'593
- Anzahl Personen: 39'307
- Anzahl Variablen: 17

```r
variable_description <- tibble::tribble(
  ~Variable, ~Beschreibung,
  "IDPERS", "Personen-ID",
  "IDHOUS", "Haushalts-ID",
  "YEAR", "Befragungsjahr",
  "PP04", "Vertrauen in den Bundesrat",
  "BIRTHY", "Geburtsjahr",
  "BIRTHYGEN", "Geburtskohorte",
  "SEX", "Geschlecht",
  "CANTON", "Wohnkanton",
  "EDUCAT", "Bildungskategorie",
  "HASKID", "Eigene Kinder: ja/nein",
  "NAT", "Nationalitätengruppe",
  "PC19", "Gesundheitliche Einschränkung",
  "PP10", "Links-Rechts-Selbsteinstufung",
  "NETHHINCPP", "Netto-Haushaltseinkommen pro Haushaltsmitglied",
  "PO58", "Soziale Herkunft",
  "COMPLETE", "Vollständiger Datensatz: TRUE/FALSE",
  "CIVSTA", "Zivilstand"
)

knitr::kable(variable_description)
```

| Variable | Beschreibung |
|---|---|
| IDPERS | Personen-ID |
| IDHOUS | Haushalts-ID |

| Variable | Beschreibung |
|---|---|
| YEAR | Befragungsjahr |
| PP04 | Vertrauen in den Bundesrat |
| BIRTHY | Geburtsjahr |
| BIRTHYGEN | Geburtskohorte |
| SEX | Geschlecht |
| CANTON | Wohnkanton |
| EDUCAT | Bildungskategorie |
| HASKID | Eigene Kinder: ja/nein |
| NAT | Nationalitätengruppe |
| PC19 | Gesundheitliche Einschränkung |
| PP10 | Links-Rechts-Selbsteinstufung |
| NETHHINCPP | Netto-Haushaltseinkommen pro Haushaltsmitglied |
| PO58 | Soziale Herkunft |
| COMPLETE | Vollständiger Datensatz: TRUE/FALSE |
| CIVSTA | Zivilstand |

### 10.12 1.11 Speicherung

```
write_csv(panel_final, file.path(processed_dir, "shp_panel_week2_longfiles.csv"))
saveRDS(panel_final, file.path(processed_dir, "shp_panel_week2_longfiles.rds"))
```

## 11 2. Datenqualität

### 11.1 2.1 Hilfsvariablen

```
panel_final <- panel_final |>
  mutate(
    AGE = YEAR - BIRTHY,
    AGEGROUP_CURRENT = case_when(
      AGE >= 18 & AGE < 30 ~ "18-29",
      AGE >= 30 & AGE < 45 ~ "30-44",
      AGE >= 45 & AGE < 60 ~ "45-59",
      AGE >= 60 & AGE < 75 ~ "60-74",
      AGE >= 75 ~ "75+",
      TRUE ~ NA_character_
    )
  )
```

### 11.2 2.2 Unvollständige Datensätze pro Jahr

```
missing_rows_by_year <- panel_final |>
  group_by(YEAR) |>
  summarise(
    n_total = n(),
    n_incomplete = sum(!COMPLETE, na.rm = TRUE),
```

```r
    share_incomplete = n_incomplete / n_total,
    .groups = "drop"
  )

missing_rows_by_year
```

```
## # A tibble: 16 x 4
##     YEAR n_total n_incomplete share_incomplete
##    <int>   <int>        <int>            <dbl>
##  1  1999    9633         4621            0.480
##  2  2000    8719         8366            0.960
##  3  2001    8325         8200            0.985
##  4  2002    7127         7055            0.990
##  5  2003    6344         6281            0.990
##  6  2004   10759         5466            0.508
##  7  2005    8556         4064            0.475
##  8  2006    8379         3741            0.446
##  9  2007    8575         3709            0.433
## 10  2008    8562         3698            0.432
## 11  2009    8860         3741            0.422
## 12  2011    8989         3689            0.410
## 13  2014   14565         9618            0.660
## 14  2017   11509         4495            0.391
## 15  2020   20220        10308            0.510
## 16  2023   13471         6010            0.446
```

```r
missing_rows_by_year |>
  ggplot(aes(x = YEAR, y = share_incomplete)) +
  geom_col(fill = "#4C78A8") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = "Anteil unvollständiger Datensätze pro Jahr",
    x = "Jahr",
    y = "Anteil"
  )
```

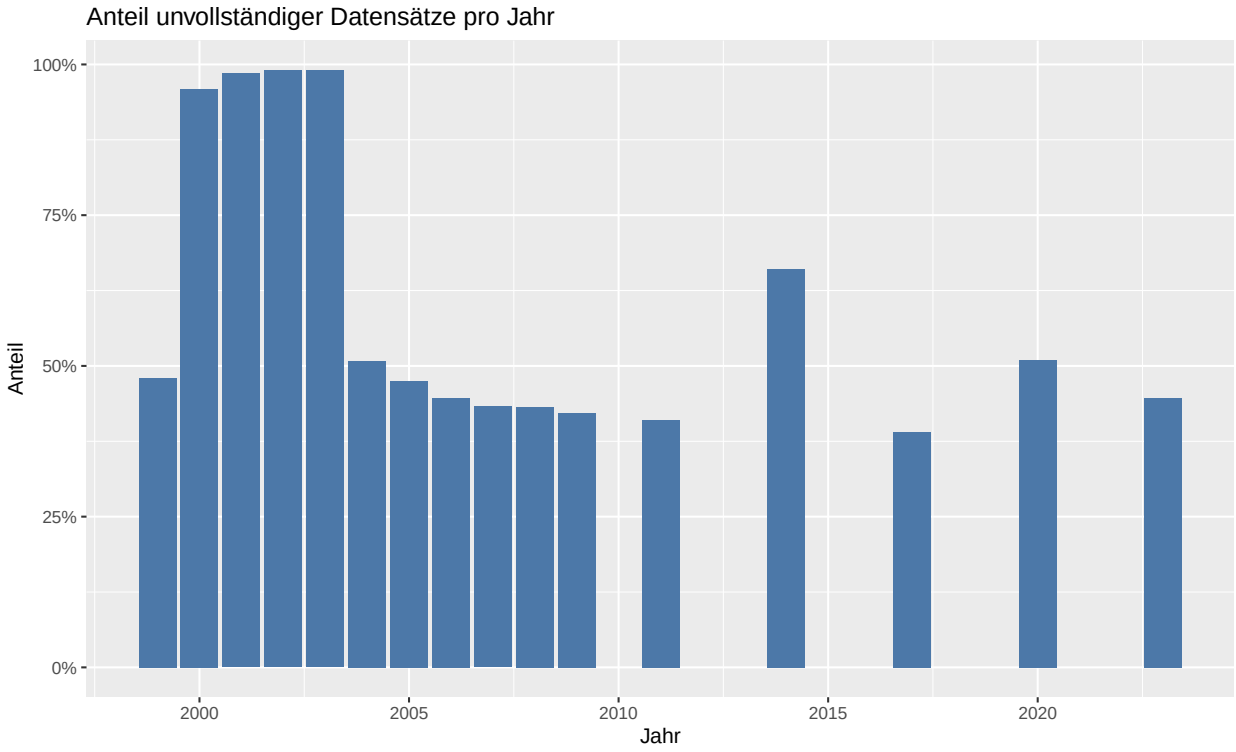


## 11.3 2.3 Missing Values pro Jahr und Variable

```
analysis_vars <- c(
  "PP04", "BIRTHY", "BIRTHYGEN", "SEX", "CANTON", "EDUCAT",
  "HASKID", "NAT", "PC19", "PP10", "NETHHINCPP", "PO58",
  "CIVSTA"
)

missing_by_var_year <- panel_final |>
  mutate(across(all_of(analysis_vars), as.character)) |>
  pivot_longer(
    cols = all_of(analysis_vars),
    names_to = "variable",
    values_to = "value"
  ) |>
  group_by(YEAR, variable) |>
  summarise(
    n_total = n(),
    n_missing = sum(is.na(value)),
    share_missing = n_missing / n_total,
    .groups = "drop"
  ) |>
  arrange(desc(share_missing), YEAR, variable)

missing_by_var_year
```

```
## # A tibble: 208 x 5
```

```
##     YEAR variable n_total n_missing share_missing
##    <int> <chr>      <int>     <int>         <dbl>
##  1  2003 PC19        6344      6262         0.987
##  2  2002 PC19        7127      7023         0.985
##  3  2001 PC19        8325      8130         0.977
##  4  2000 PC19        8719      8174         0.937
##  5  2014 PP04       14565      7919         0.544
##  6  2004 PP10       10759      4301         0.400
##  7  2001 PP10        8325      3114         0.374
##  8  2005 PP10        8556      3190         0.373
##  9  2020 PP10       20220      7344         0.363
## 10  1999 PP10        9633      3473         0.361
## # i 198 more rows
```

## 11.4 2.4 Auswahl der Imputationsvariable

```
missing_over_90 <- missing_by_var_year |>
  filter(share_missing > 0.9) |>
  arrange(desc(share_missing), YEAR, variable)

if (nrow(missing_over_90) > 0) {
  target_info <- missing_over_90 |>
    slice(1) |>
    mutate(selection_rule = "> 90% Missing")
} else {
  target_info <- missing_by_var_year |>
    slice(1) |>
    mutate(selection_rule = "höchster Missing-Anteil")
}

target_info
```

```
## # A tibble: 1 x 6
##    YEAR variable n_total n_missing share_missing selection_rule
##   <int> <chr>      <int>     <int>         <dbl> <chr>
## 1  2003 PC19        6344      6262         0.987 > 90% Missing
```

Die Imputation wird für PC19 im Jahr 2003 durchgeführt.

## 11.5 2.5 Imputation

```
panel_imputed <- fill_from_past(
  data = panel_final,
  varname = as.character(target_info$variable[[1]]),
  target_year = as.integer(target_info$YEAR[[1]])
)

panel_imputed$COMPLETE <- rowSums(is.na(panel_imputed[complete_vars])) == 0
```

```r
missing_by_var_year_after <- panel_imputed |>
  mutate(across(all_of(analysis_vars), as.character)) |>
  pivot_longer(
    cols = all_of(analysis_vars),
    names_to = "variable",
    values_to = "value"
  ) |>
  group_by(YEAR, variable) |>
  summarise(
    n_total = n(),
    n_missing = sum(is.na(value)),
    share_missing = n_missing / n_total,
    .groups = "drop"
  )

comparison_missing <- missing_by_var_year |>
  dplyr::rename(
    n_missing_before = n_missing,
    share_missing_before = share_missing
  ) |>
  select(YEAR, variable, n_missing_before, share_missing_before) |>
  left_join(
    missing_by_var_year_after |>
      dplyr::rename(
        n_missing_after = n_missing,
        share_missing_after = share_missing
      ) |>
      select(YEAR, variable, n_missing_after, share_missing_after),
    by = c("YEAR", "variable")
  )

comparison_missing |>
  filter(variable == target_info$variable[[1]], YEAR == target_info$YEAR[[1]])
```

```
## # A tibble: 1 x 6
##    YEAR variable n_missing_before share_missing_before n_missing_after
##   <int> <chr>               <int>                <dbl>           <int>
## 1  2003 PC19                 6262                0.987            1189
## # i 1 more variable: share_missing_after <dbl>
```

Die Imputation ersetzt fehlende Werte nicht generell, sondern nur für die ausgewählte Zielvariable im Zieljahr durch den jeweils letzten früheren verfügbaren Personenwert. Dadurch bleibt der Eingriff methodisch eng begrenzt und nachvollziehbar.

# 12 3. Plausibilisierung

## 12.1 3.1 Vergleich vollständige vs. unvollständige Fälle

```r
panel_all <- panel_imputed
panel_complete <- panel_imputed |>
  filter(COMPLETE)
```

```r
sex_all <- panel_all |>
  filter(SEX %in% c("männlich", "weiblich")) |>
  count(SEX) |>
  mutate(dataset = "Alle Fälle", share = n / sum(n))

sex_complete <- panel_complete |>
  filter(SEX %in% c("männlich", "weiblich")) |>
  count(SEX) |>
  mutate(dataset = "Nur vollständige Fälle", share = n / sum(n))

bind_rows(sex_all, sex_complete)
```

```
## # A tibble: 4 x 4
##   SEX          n dataset                share
##   <chr>    <int> <chr>                  <dbl>
## 1 männlich 78220 Alle Fälle             0.481
## 2 weiblich 84369 Alle Fälle             0.519
## 3 männlich 34600 Nur vollständige Fälle 0.474
## 4 weiblich 38442 Nur vollständige Fälle 0.526
```

```r
age_all <- panel_all |>
  filter(!is.na(AGEGROUP_CURRENT)) |>
  count(AGEGROUP_CURRENT) |>
  mutate(dataset = "Alle Fälle", share = n / sum(n))

age_complete <- panel_complete |>
  filter(!is.na(AGEGROUP_CURRENT)) |>
  count(AGEGROUP_CURRENT) |>
  mutate(dataset = "Nur vollständige Fälle", share = n / sum(n))

bind_rows(age_all, age_complete)
```

```
## # A tibble: 10 x 4
##    AGEGROUP_CURRENT     n dataset                 share
##    <chr>            <int> <chr>                   <dbl>
##  1 18-29            29414 Alle Fälle             0.181
##  2 30-44            41198 Alle Fälle             0.253
##  3 45-59            47463 Alle Fälle             0.292
##  4 60-74            32013 Alle Fälle             0.197
##  5 75+              12505 Alle Fälle             0.0769
##  6 18-29             8193 Nur vollständige Fälle 0.112
##  7 30-44            18777 Nur vollständige Fälle 0.257
##  8 45-59            23191 Nur vollständige Fälle 0.317
##  9 60-74            16752 Nur vollständige Fälle 0.229
## 10 75+               6130 Nur vollständige Fälle 0.0839
```

```r
canton_all <- panel_all |>
  filter(!is.na(CANTON)) |>
  count(CANTON) |>
  mutate(dataset = "Alle Fälle", share = n / sum(n))

canton_complete <- panel_complete |>
```

```r
  filter(!is.na(CANTON)) |>
  count(CANTON) |>
  mutate(dataset = "Nur vollständige Fälle", share = n / sum(n))

bind_rows(canton_all, canton_complete)
```

```
## # A tibble: 52 x 4
##    CANTON     n dataset      share
##    <chr>  <int> <chr>        <dbl>
##  1 AG     13745 Alle Fälle 0.0845
##  2 AI       238 Alle Fälle 0.00146
##  3 AR      1302 Alle Fälle 0.00801
##  4 BE     20217 Alle Fälle 0.124
##  5 BL      5692 Alle Fälle 0.0350
##  6 BS      3268 Alle Fälle 0.0201
##  7 FR      6121 Alle Fälle 0.0376
##  8 GE      7046 Alle Fälle 0.0433
##  9 GL       880 Alle Fälle 0.00541
## 10 GR      3512 Alle Fälle 0.0216
## # i 42 more rows
```

## 12.2 3.2 BFS-Daten

Falls die BFS-Daten nicht geladen werden können, bleibt der Bericht trotzdem lauffähig.

```r
bfs_raw <- tryCatch(
  read.px(
    filename = "https://dam-api.bfs.admin.ch/hub/api/dam/assets/36021707/master",
    encoding = "utf-8"
  ),
  error = function(e) NULL
)

bfs_tbl <- if (is.null(bfs_raw)) NULL else tryCatch(as.data.frame(bfs_raw), error = function(e) NULL)
bfs_available <- !is.null(bfs_tbl)
bfs_year_ref <- 2023L

bfs_available
```

```
## [1] TRUE
```

```r
bfs_canton_map <- c(
  "Zürich" = "ZH",
  "Bern / Berne" = "BE",
  "Luzern" = "LU",
  "Uri" = "UR",
  "Schwyz" = "SZ",
  "Obwalden" = "OW",
  "Nidwalden" = "NW",
  "Glarus" = "GL",
  "Zug" = "ZG",
```

```r
  "Fribourg / Freiburg" = "FR",
  "Solothurn" = "SO",
  "Basel-Stadt" = "BS",
  "Basel-Landschaft" = "BL",
  "Schaffhausen" = "SH",
  "Appenzell Ausserrhoden" = "AR",
  "Appenzell Innerrhoden" = "AI",
  "St. Gallen" = "SG",
  "Graubünden / Grigioni / Grischun" = "GR",
  "Aargau" = "AG",
  "Thurgau" = "TG",
  "Ticino" = "TI",
  "Vaud" = "VD",
  "Valais / Wallis" = "VS",
  "Neuchâtel" = "NE",
  "Genève" = "GE",
  "Jura" = "JU"
)

if (bfs_available) {
  bfs_sex <- bfs_tbl |>
    filter(
      as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
      as.character(Alter) == "Alter - Total",
      as.character(Zivilstand) == "Zivilstand - Total",
      as.character(Kanton) == "Schweiz",
      as.integer(as.character(Jahr)) == bfs_year_ref,
      as.character(Geschlecht) != "Geschlecht - Total"
    ) |>
    mutate(
      SEX = case_when(
        as.character(Geschlecht) == "Mann" ~ "männlich",
        as.character(Geschlecht) == "Frau" ~ "weiblich",
        TRUE ~ NA_character_
      )
    ) |>
    filter(!is.na(SEX)) |>
    group_by(SEX) |>
    summarise(n = sum(value, na.rm = TRUE), .groups = "drop") |>
    mutate(dataset = "BFS", share = n / sum(n))

  bfs_age <- bfs_tbl |>
    filter(
      as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
      as.character(Geschlecht) == "Geschlecht - Total",
      as.character(Zivilstand) == "Zivilstand - Total",
      as.character(Kanton) == "Schweiz",
      as.integer(as.character(Jahr)) == bfs_year_ref,
      as.character(Alter) != "Alter - Total"
    ) |>
    mutate(age_num = readr::parse_number(as.character(Alter))) |>
    filter(!is.na(age_num), age_num >= 18) |>
    mutate(
```

```r
      AGEGROUP_CURRENT = case_when(
        age_num >= 18 & age_num < 30 ~ "18-29",
        age_num >= 30 & age_num < 45 ~ "30-44",
        age_num >= 45 & age_num < 60 ~ "45-59",
        age_num >= 60 & age_num < 75 ~ "60-74",
        age_num >= 75 ~ "75+",
        TRUE ~ NA_character_
      )
    ) |>
    group_by(AGEGROUP_CURRENT) |>
    summarise(n = sum(value, na.rm = TRUE), .groups = "drop") |>
    mutate(dataset = "BFS", share = n / sum(n))

  bfs_canton <- bfs_tbl |>
    filter(
      as.character(Bevölkerungstyp) == "Ständige Wohnbevölkerung",
      as.character(Alter) == "Alter - Total",
      as.character(Geschlecht) == "Geschlecht - Total",
      as.character(Zivilstand) == "Zivilstand - Total",
      as.integer(as.character(Jahr)) == bfs_year_ref,
      as.character(Kanton) != "Schweiz"
    ) |>
    mutate(
      CANTON = recode(as.character(Kanton), !!!bfs_canton_map, .default = NA_character_)
    ) |>
    filter(!is.na(CANTON)) |>
    group_by(CANTON) |>
    summarise(n = sum(value, na.rm = TRUE), .groups = "drop") |>
    mutate(dataset = "BFS", share = n / sum(n))
} else {
  bfs_sex <- tibble(SEX = character(), n = numeric(), dataset = character(), share = numeric())
  bfs_age <- tibble(AGEGROUP_CURRENT = character(), n = numeric(), dataset = character(), share = numeri
  bfs_canton <- tibble(CANTON = character(), n = numeric(), dataset = character(), share = numeric())
}
```

```r
bind_rows(sex_all, sex_complete, bfs_sex) |>
  ggplot(aes(x = SEX, y = share, fill = dataset)) +
  geom_col(position = "dodge") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = paste0("Geschlechtsverteilung: SHP vs. BFS (", bfs_year_ref, ")"),
    x = "Geschlecht",
    y = "Anteil"
  )
```

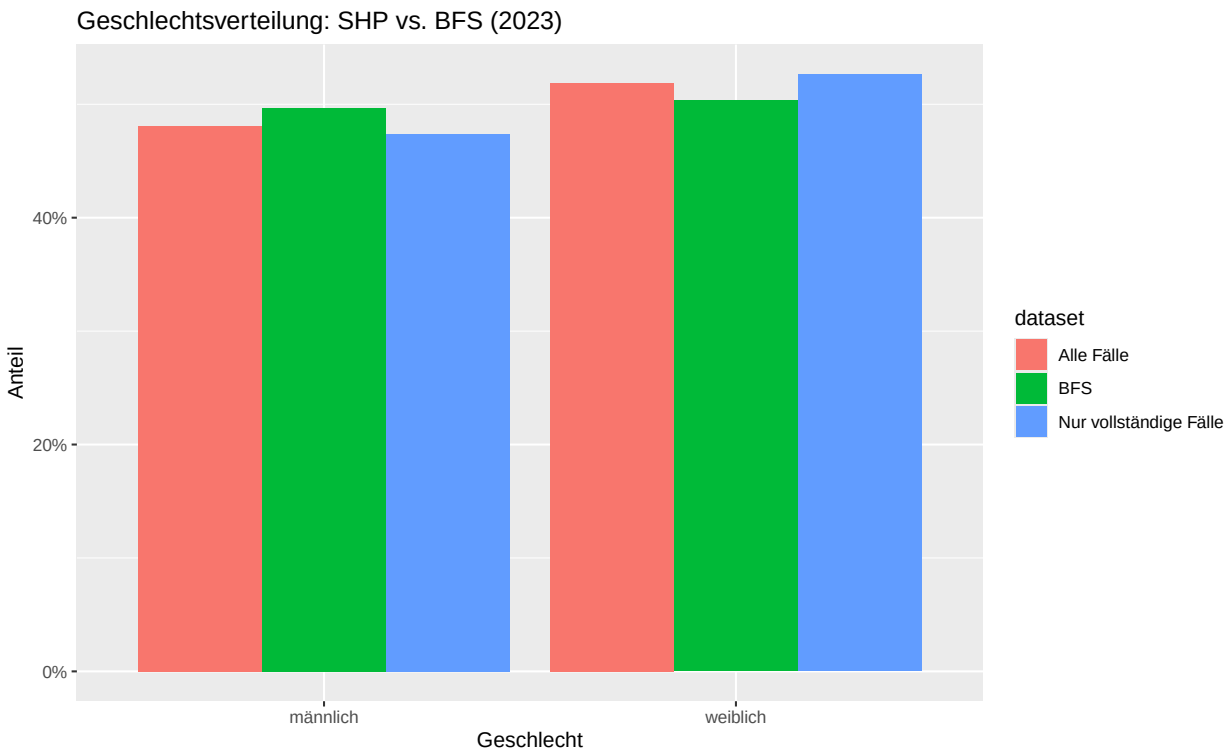


```r
bind_rows(age_all, age_complete, bfs_age) |>
  ggplot(aes(x = AGEGROUP_CURRENT, y = share, fill = dataset)) +
  geom_col(position = "dodge") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = paste0("Altersverteilung: SHP vs. BFS (", bfs_year_ref, ")"),
    x = "Altersgruppe",
    y = "Anteil"
  )
```

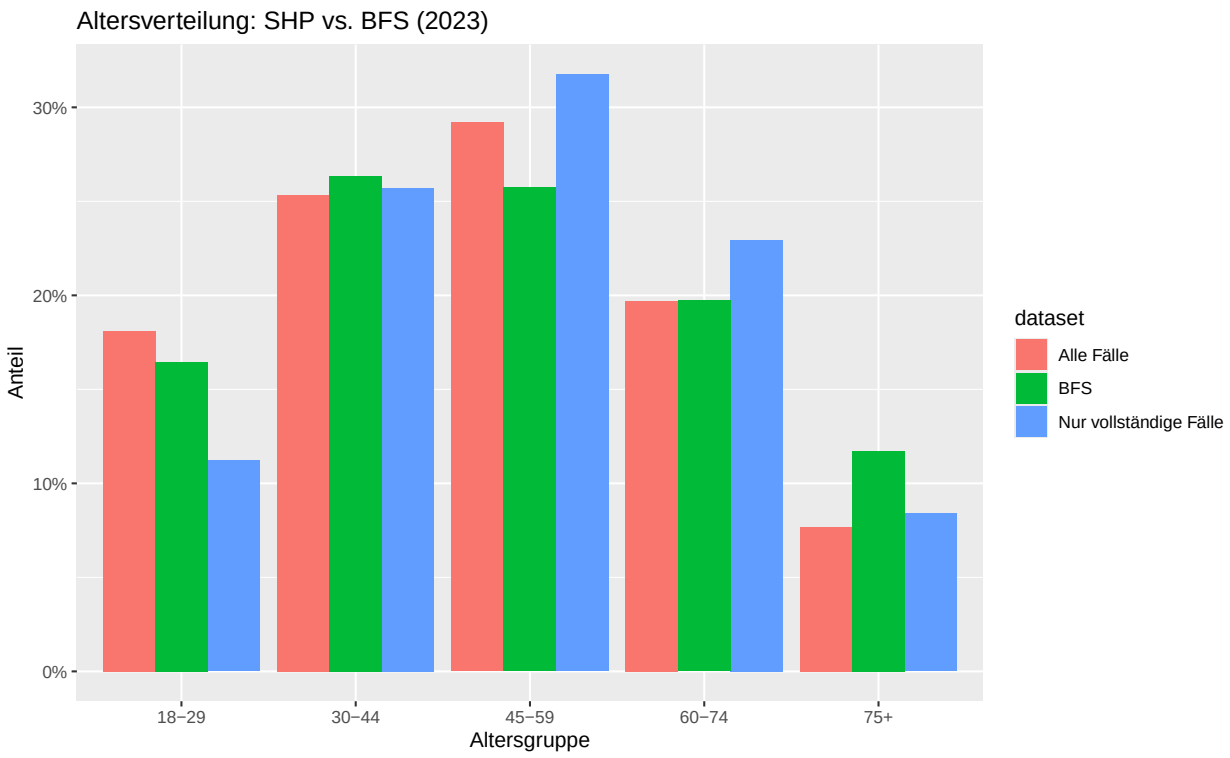


```r
bind_rows(canton_all, canton_complete, bfs_canton) |>
  ggplot(aes(x = reorder(CANTON, share), y = share, fill = dataset)) +
  geom_col(position = "dodge") +
  coord_flip() +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = paste0("Kantonsverteilung: SHP vs. BFS (", bfs_year_ref, ")"),
    x = "Kanton",
    y = "Anteil"
  )
```

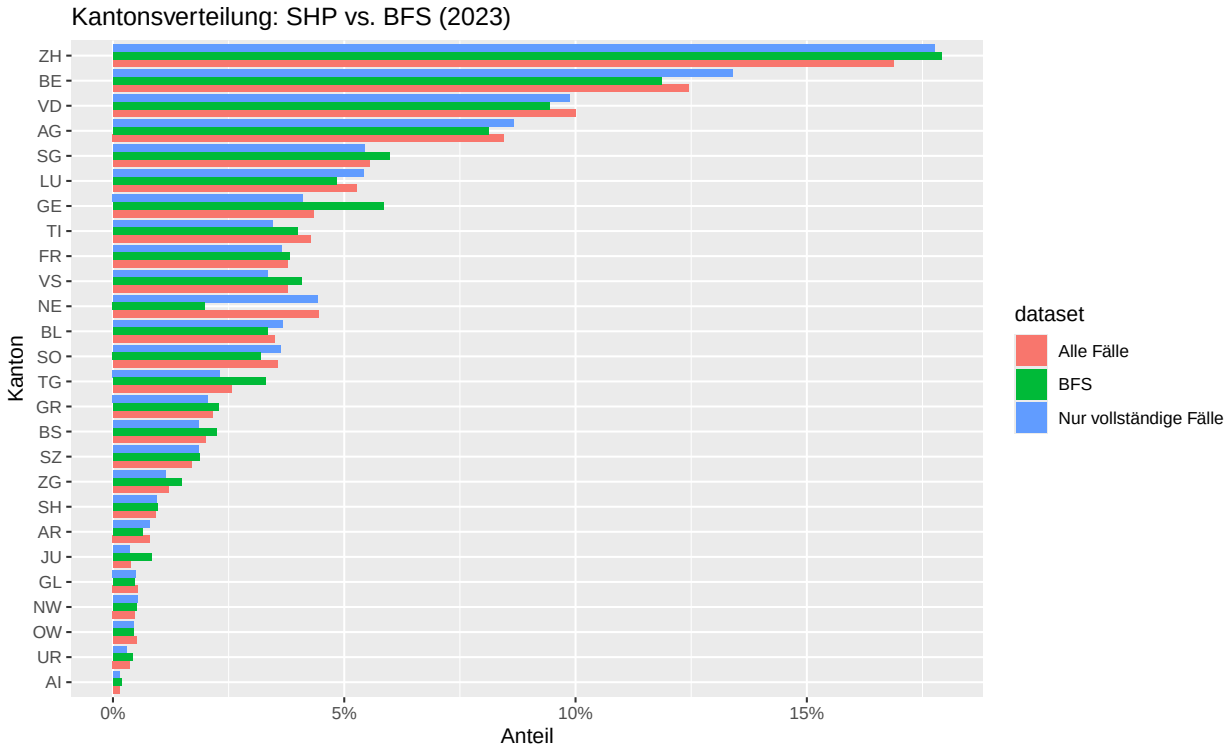


Die Plausibilisierung vergleicht die SHP-Verteilungen mit externen BFS-Referenzwerten für Geschlecht, Altersgruppen und Kantone. Zusätzlich wird geprüft, ob sich die Verteilungen nach dem Entfernen unvollständiger Fälle merklich verschieben.

# 13 4. Auswertung

## 13.1 4.1 Zeitliche Entwicklung von PP04

```
trust_over_time <- panel_imputed |>
  group_by(YEAR) |>
  summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    .groups = "drop"
  )

trust_over_time
```

```
## # A tibble: 16 x 3
##     YEAR mean_PP04 median_PP04
##    <int>     <dbl>       <dbl>
##  1  1999      5.74           6
##  2  2000      5.93           6
##  3  2001      5.92           6
##  4  2002      5.62           6
##  5  2003      5.44           6
```

```
##  6  2004      5.28           5
##  7  2005      5.39           5
##  8  2006      5.50           6
##  9  2007      5.51           6
## 10  2008      5.67           6
## 11  2009      5.39           5
## 12  2011      5.77           6
## 13  2014      5.98           6
## 14  2017      6.31           7
## 15  2020      6.76           7
## 16  2023      6.36           7
```

```
trust_over_time |>
  ggplot(aes(x = YEAR, y = mean_PP04)) +
  geom_line(color = "#4C78A8") +
  geom_point(color = "#4C78A8") +
  labs(
    title = "Vertrauen in den Bundesrat über die Zeit",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

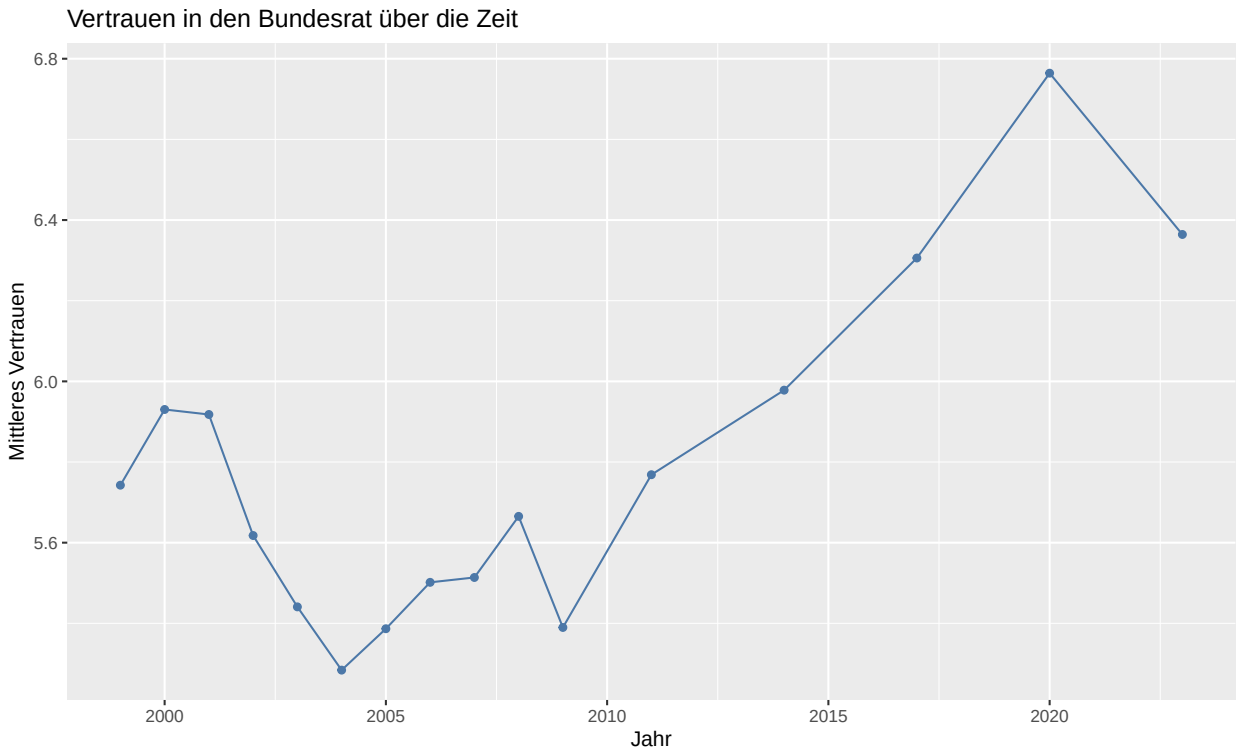


## 13.2 4.2 Zusätzliche Untergruppen-Grafiken

```
panel_imputed |>
  filter(!is.na(SEX)) |>
  group_by(YEAR, SEX) |>
```

```r
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = SEX)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Geschlecht",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

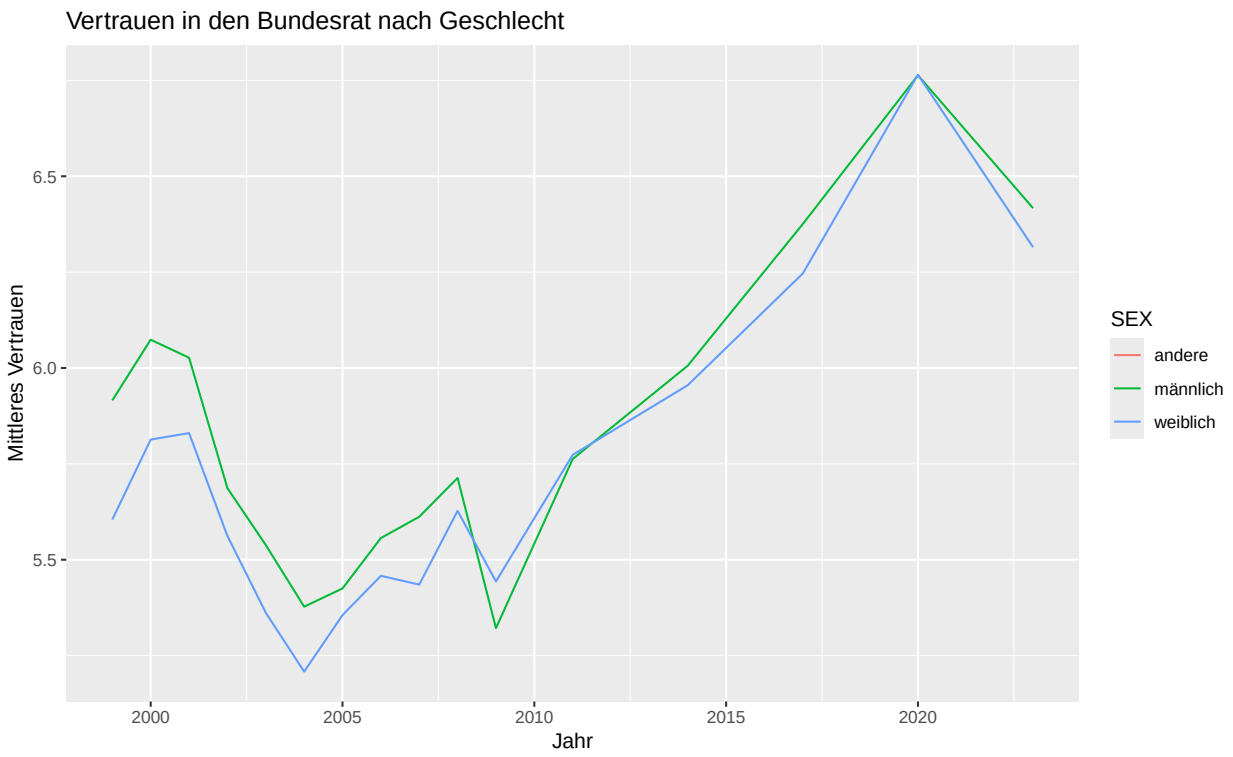


```r
panel_imputed |>
  filter(!is.na(BIRTHYGEN)) |>
  group_by(YEAR, BIRTHYGEN) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = BIRTHYGEN)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Geburtskohorte",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

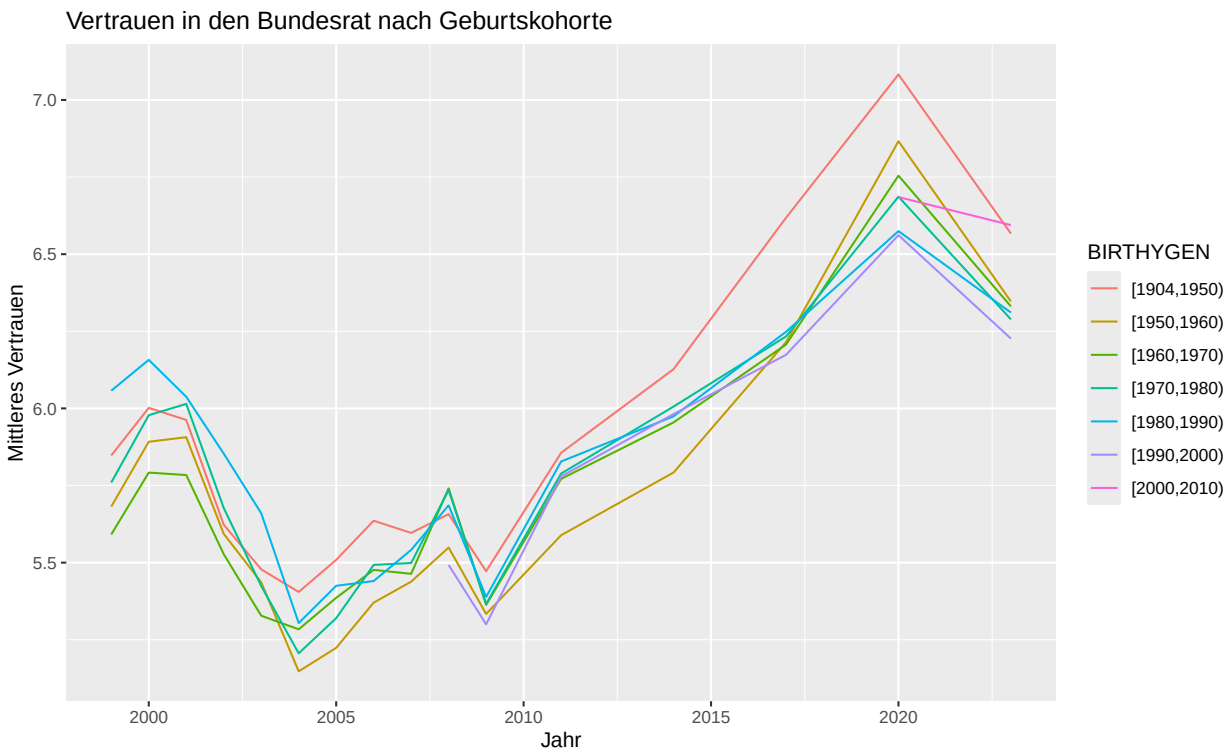


```
panel_imputed |>
  filter(!is.na(NAT)) |>
  group_by(YEAR, NAT) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = NAT)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Nationalität",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

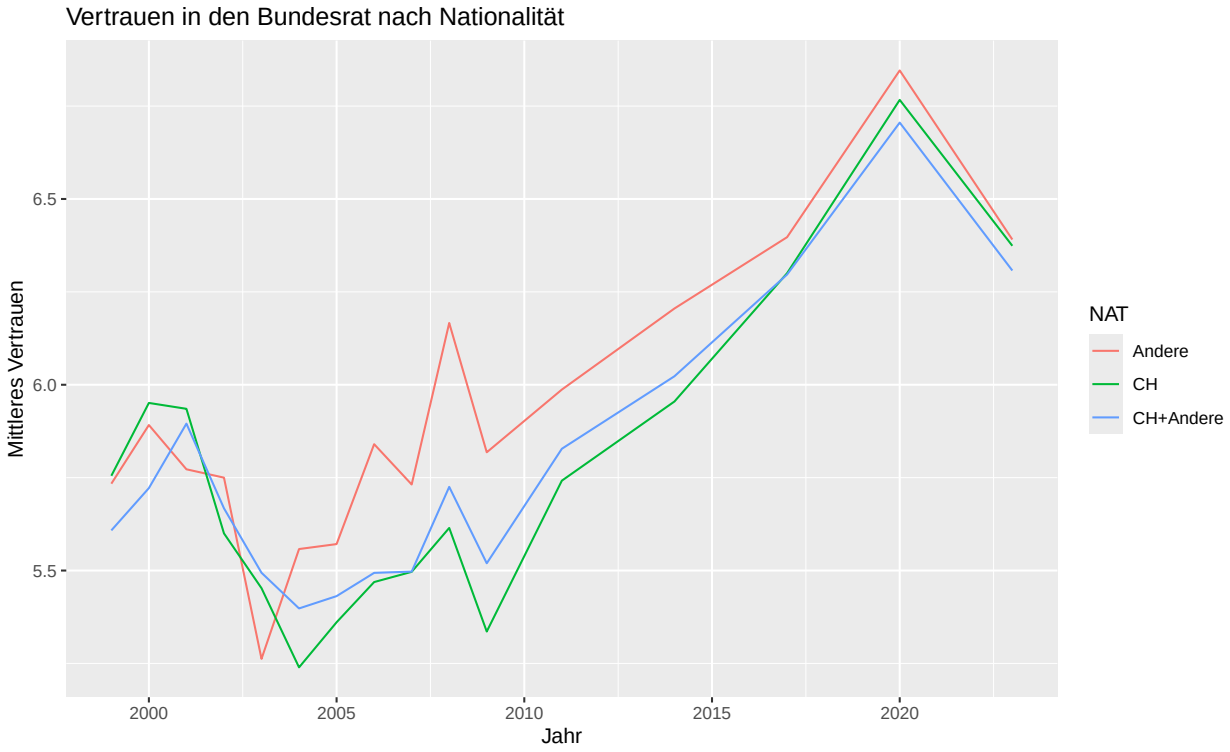


```r
panel_imputed |>
  filter(!is.na(HASKID)) |>
  group_by(YEAR, HASKID) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = HASKID)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Kindern",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

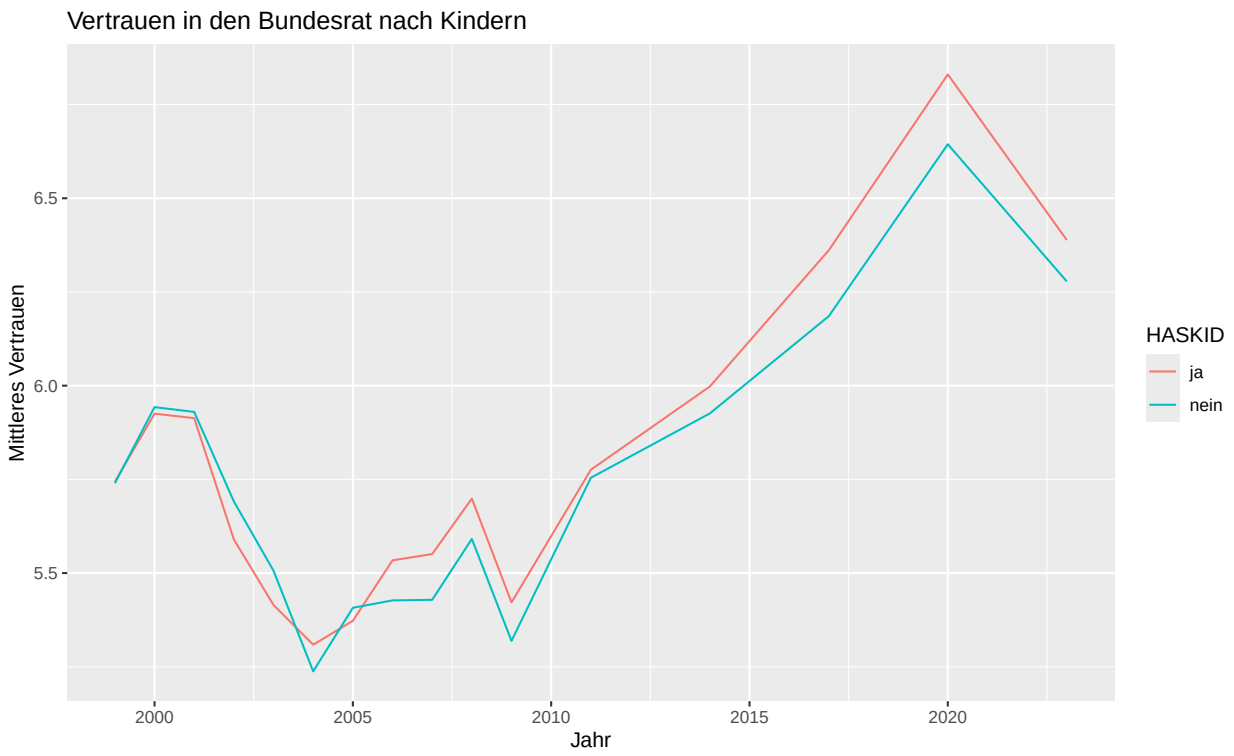


```r
panel_imputed |>
  filter(!is.na(PC19)) |>
  group_by(YEAR, PC19) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = PC19)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach gesundheitlicher Einschränkung",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

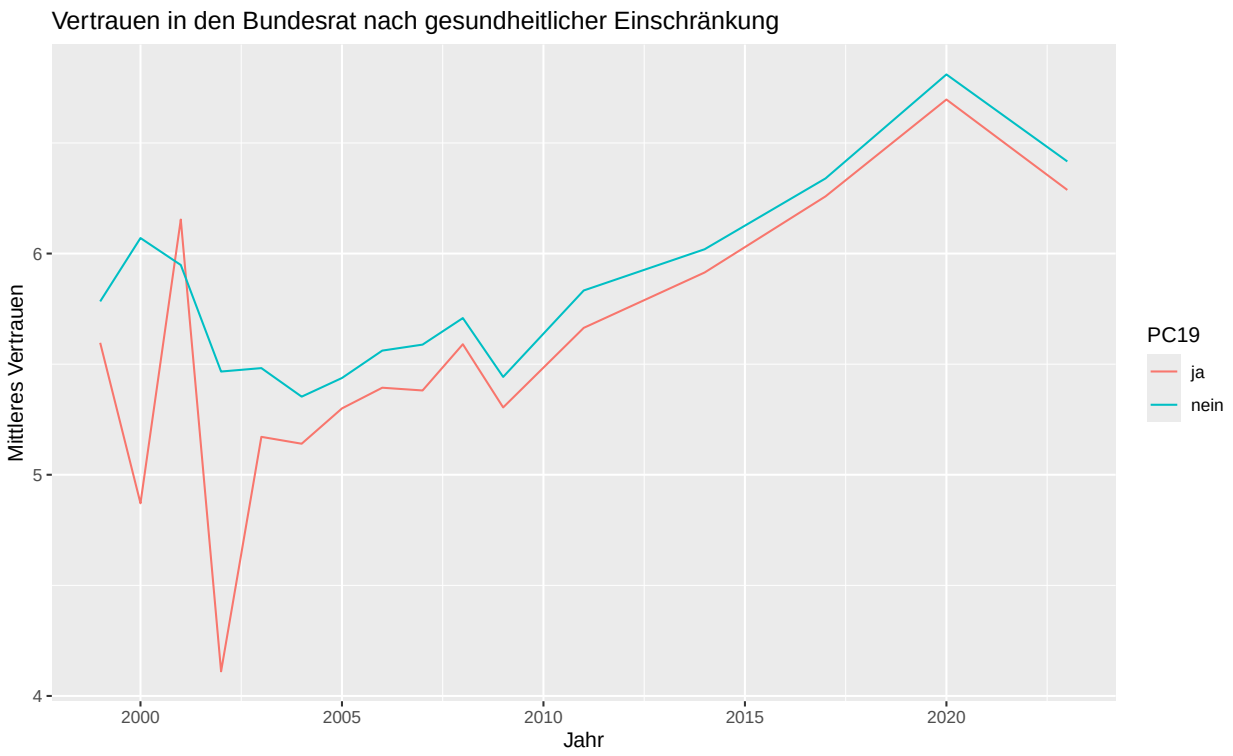


```
panel_imputed |>
  filter(!is.na(CIVSTA)) |>
  group_by(YEAR, CIVSTA) |>
  summarise(mean_PP04 = mean(PP04, na.rm = TRUE), .groups = "drop") |>
  ggplot(aes(x = YEAR, y = mean_PP04, color = CIVSTA)) +
  geom_line() +
  labs(
    title = "Vertrauen in den Bundesrat nach Zivilstand",
    x = "Jahr",
    y = "Mittleres Vertrauen"
  )
```

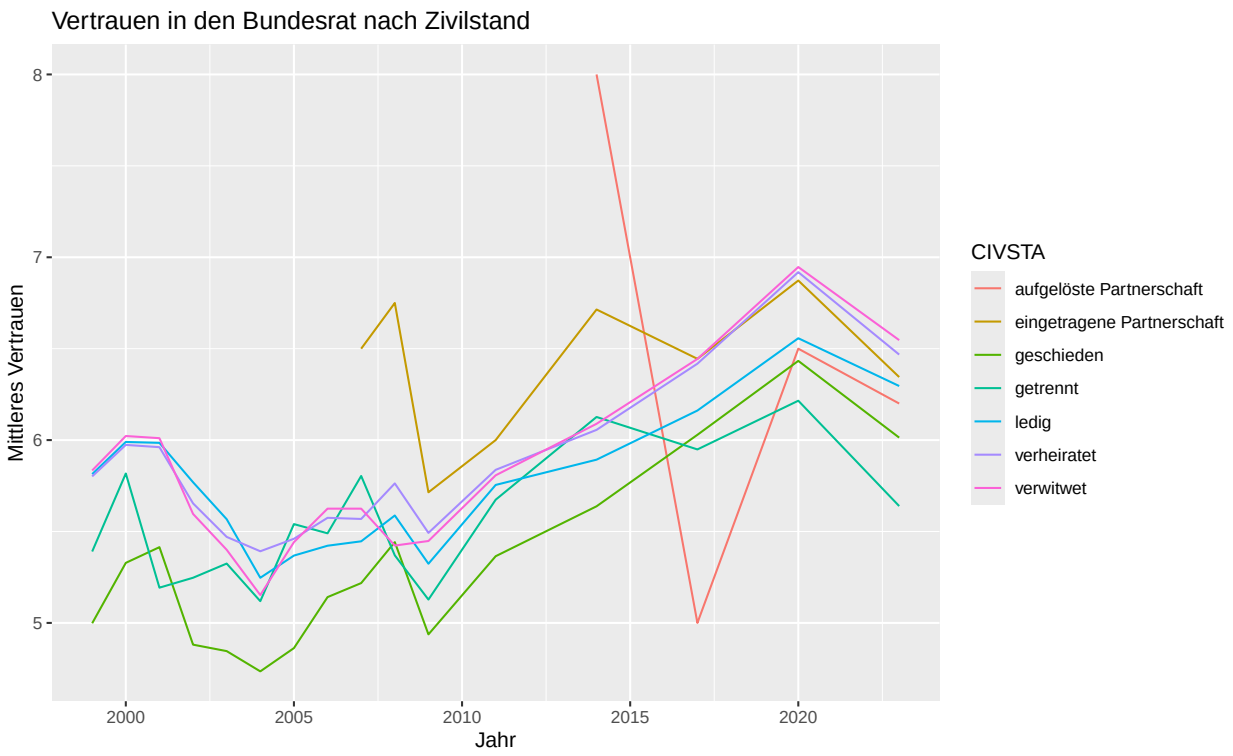


## 13.3 4.3 Hypothese zu CIVSTA

```
civsta_summary <- panel_imputed |>
  filter(!is.na(CIVSTA)) |>
  group_by(CIVSTA) |>
  summarise(
    mean_PP04 = mean(PP04, na.rm = TRUE),
    median_PP04 = median(PP04, na.rm = TRUE),
    n = n(),
    .groups = "drop"
  ) |>
  arrange(desc(mean_PP04))

civsta_summary
```

```
## # A tibble: 7 x 4
##   CIVSTA                     mean_PP04 median_PP04     n
##   <chr>                          <dbl>       <dbl> <int>
## 1 eingetragene Partnerschaft      6.51           7   218
## 2 aufgelöste Partnerschaft        6.36           6    11
## 3 verheiratet                     5.96           6 95195
## 4 verwitwet                       5.94           6  7384
## 5 ledig                           5.86           6 45062
## 6 getrennt                        5.61           6  2145
## 7 geschieden                      5.49           6 12488
```

```r
civsta_summary |>
  ggplot(aes(x = reorder(CIVSTA, mean_PP04), y = mean_PP04)) +
  geom_col(fill = "#F58518") +
  coord_flip() +
  labs(
    title = "Mittleres Vertrauen in den Bundesrat nach Zivilstand",
    x = "Zivilstand",
    y = "Mittleres Vertrauen"
  )
```

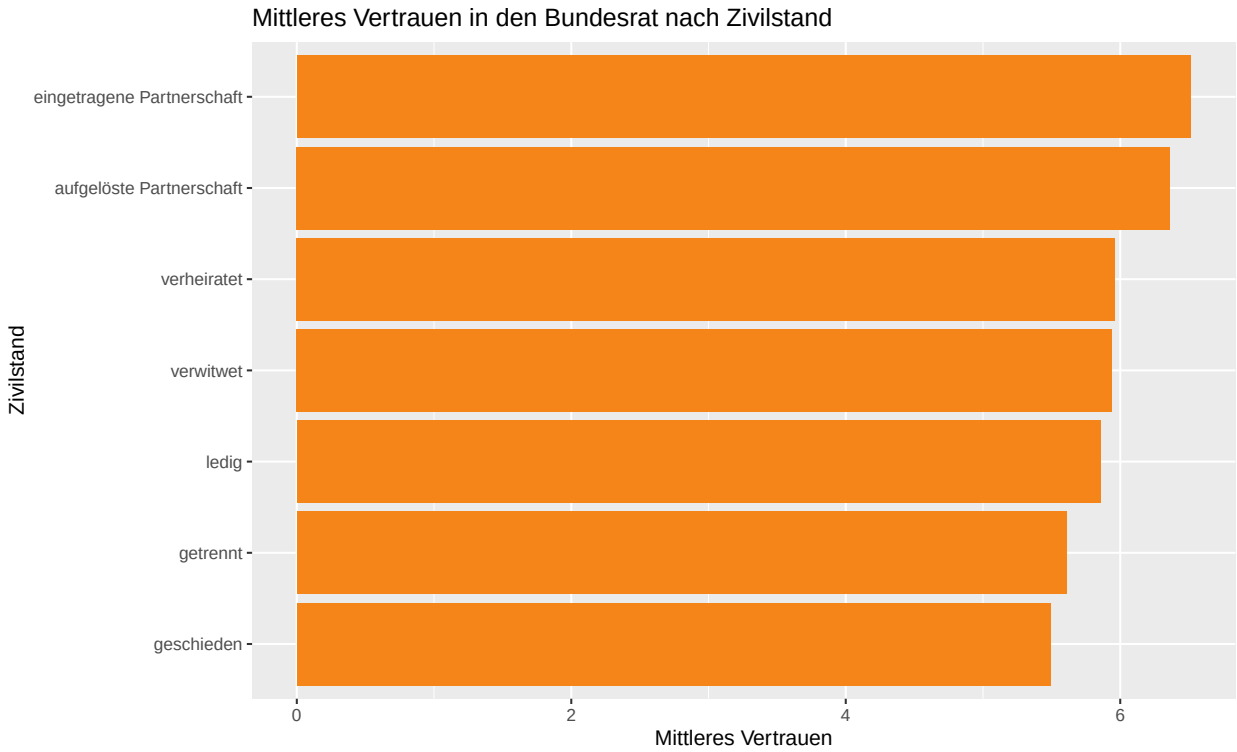


Die höchste mittlere Ausprägung von `PP04` zeigt in dieser Auswertung die Kategorie eingetragene Partnerschaft.

Die Hypothese wird anhand der gruppenspezifischen Mittelwerte geprüft. Ob sie vollständig gestützt wird, hängt von der konkreten Rangfolge der Zivilstandskategorien in den berechneten Ergebnissen ab.

# 14 5. Speicherung der Ergebnisse

```r
write_csv(panel_imputed, file.path(processed_dir, "shp_panel_week3_imputed.csv"))
saveRDS(panel_imputed, file.path(processed_dir, "shp_panel_week3_imputed.rds"))
```

# 15 6. Fazit

Der Datensatz für Woche 2 wurde erfolgreich aufgebaut und enthält alle geforderten Variablen auf Personen-Jahr-Ebene. In Woche 3 wurden die unvollständigen Fälle pro Jahr bestimmt, Missing Values systematisch

ausgewertet, eine stark betroffene Variable mit früheren Personenwerten imputiert, die Plausibilität mit BFS-Verteilungen verglichen und die Entwicklung von `PP04` über mehrere Untergruppen hinweg untersucht.